TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

.

ĐỒ ÁN MÔN HỌC

Đồ Án Chuyên Ngành Khoa Học Dữ Liệu

DỰ BÁO LƯỢNG MƯA VÀ NGUY CƠ LŨ LỤT TẠI KHU VỰC MIỀN TRUNG VIỆT NAM SỬ DỤNG MÔ HÌNH LSTM

Giảng viên hướng dẫn:	**ThS. Phạm Đình Tài**
Sinh viên thực hiện:	**Lê Chí Kha**
MSSV:	**2200002544**
Khoá:	**2022 - 2026**
Ngành:	**CÔNG NGHỆ THÔNG TIN**
Chuyên ngành:	**KHOA HỌC DỮ LIỆU**

TPHCM, tháng 8 năm 2025

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN MÔN HỌC

ĐỒ ÁN CHUYÊN NGÀNH KHOA HỌC DỮ LIỆU

DỰ BÁO LƯỢNG MƯA VÀ NGUY CƠ LŨ LỤT TẠI KHU VỰC MIỀN TRUNG VIỆT NAM SỬ DỤNG MÔ HÌNH LSTM

Giảng viên hướng dẫn:	**ThS. Phạm Đình Tài**
Sinh viên thực hiện:	**Lê Chí Kha**
MSSV:	**2200002544**
Khoá:	**2022 - 2026**
Ngành:	**CÔNG NGHỆ THÔNG TIN**
Chuyên ngành:	**KHOA HỌC DỮ LIỆU**

TPHCM, tháng 8 năm 2025

LỜI MỞ ĐẦU

Trong những năm gần đây, biến đổi khí hậu đã và đang diễn ra phức tạp, tác động ngày càng rõ nét đến đời sống con người trên phạm vi toàn cầu. Tại Việt Nam, khu vực miền Trung thường xuyên đối mặt với những trận mưa lớn kéo dài, gây lũ lụt nghiêm trọng, dẫn đến thiệt hại về người và tài sản và làm chậm sự phát triển kinh tế - xã hội. Vì vậy, việc dự báo lượng mưa cũng như nguy cơ lũ lụt là một nhiệm vụ quan trọng trong việc dự báo khí tượng thủy văn, giúp các cơ quan chức năng và người dân chủ động hơn trong công tác phòng chống thiên tai.

Xuất phát từ thực tế này, nhóm chúng em đã triển khai đồ án với đề tài "Dự báo lượng mưa và nguy cơ lũ lụt tại khu vực miền Trung Việt Nam sử dụng mô hình LSTM". Thông qua quy trình thu thập, xử lý và phân tích dữ liệu thời tiết thực tế, nhóm đã xây dựng mô hình LSTM nhằm dự báo lượng mưa trong tương lai và đánh giá nguy cơ lũ lụt tại một số tỉnh miền Trung.

Đồ án là kết quả của quá trình nghiên cứu và học tập nghiêm túc, với hy vọng đóng góp một phần nhỏ vào việc đưa ra các cảnh báo sớm và giảm thiểu thiệt hại do thiên tai gây ra. Tuy nhiên, do hạn chế về thời gian cũng như kiến thức, chắc chắn đồ án vẫn còn nhiều điểm chưa hoàn thiện. Nhóm em rất mong nhận được ý kiến đóng góp, nhận xét từ quý thầy cô để có thể cải thiện trong các nghiên cứu sau này.

Chúng em xin chân thành cảm ơn quý thầy cô đã luôn tận tình hướng dẫn và hỗ trợ để nhóm hoàn thành đồ án này. Với sự cố gắng hết sức tìm hiểu, phân tích và thiết kế nhưng chắc chắn không tránh khỏi được những thiếu sót. Em rất mong được sự thông cảm và góp ý của các quý thầy cô.

LỜI CẢM ƠN

Em chân thành cám ơn Thầy hướng dẫn ThS. Phạm Đình Tài, người đã hướng dẫn tận tình, đóng góp các ý kiến chuyên môn đồ án. Thầy/Cô đã động viên tinh thần tôi cố gắng hoàn thành những nghiên cứu đặt ra. Thầy/Cô cũng cung cấp một số tài liệu liên quan đến đồ án mà em đang nghiên cứu và ân cần nhắc nhở tôi đến tiến độ thực hiện đồ án này.

Em cũng chân thành gửi lời cảm ơn đến các Thầy/Cô khoa Công nghệ thông tin trường Đại học Nguyễn Tất Thành đã giảng dạy, hướng dẫn, trang bị các kiến thức cho em trong những năm học vừa qua, từ các kiến thức cơ bản đến các vấn đề chuyên sâu.

Em xin gửi lời cảm ơn đến anh, chị, bạn bè, đồng nghiệp bằng nhiều hình thức khác nhau đã giúp đỡ em trong quá trình học tập tại trường cũng như trong thời gian hoàn thành đồ án.

Đặc biệt xin gửi lời cám ơn đến cha mẹ và anh chị em trong gia đình đã động viên tinh thần cũng như chia sẻ những khó khăn trong những năm qua. Em xin chân thành cảm ơn!

Sinh Viên Thực Hiện

(Ký tên)

BM-ChT-

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH **TRUNG TÂM KHẢO THÍ**	**KỲ THI KẾT THÚC HỌC PHẦN** **HỌC KỲ .III. NĂM HỌC .2024 – 2025.**

PHIẾU CHẤM THI TIỂU LUẬN/ĐỒ ÁN

Môn thi: ĐỒ ÁN CHUYÊN NGÀNH KHOA HỌC DỮ LIỆU

Lớp học phần: 22DTH4C

Nhóm sinh viên thực hiện :

1. Lê Chí Kha Tham gia đóng góp: 50%
2. Đỗ Kim Anh Tham gia đóng góp: 50%

Ngày thi: 20/08/2025 Phòng thi: L.602

Đề tài tiểu luận/báo cáo của sinh viên : **DỰ BÁO LƯỢNG MƯA VÀ NGUY CƠ LŨ LỤT TẠI KHU VỰC MIỀN TRUNG VIỆT NAM SỬ DỤNG MÔ HÌNH LSTM**

Phần đánh giá của giảng viên (căn cứ trên thang rubrics của môn học):

Tiêu chí (theo CĐR HP)	**Đánh giá của GV**	**Điểm tối đa**	**Điểm đạt được**
Cấu trúc của báo cáo			
Nội dung			
• Các nội dung thành phần			
• Lập luận			
• Kết luận			
Trình bày			
TỔNG ĐIỂM			

Giảng viên chấm thi

(ký, ghi rõ họ tên)

MỤC LỤC

LỜI MỞ ĐẦU ..... **i**

LỜI CẢM ƠN ..... **ii**

MỤC LỤC ..... **iv**

DANH MỤC HÌNH ..... **vii**

DANH MỤC BẢNG ..... **ix**

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT ..... **x**

CHƯƠNG 1: GIỚI THIỆU **1**

1.1. Bối Cảnh Và Lý Do Chọn Đề Tài. 1

1.2. Mục Tiêu Của Đề Tài. 2

1.3. Phương Pháp Nghiên Cứu. 2

1.4. Phạm Vi Nghiên Cứu. 3

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT **4**

2.1. Chuỗi Thời Gian 4

2.2. Mô Hình LSTM. 5

2.2.1. Khái quát về RNN: 5

2.2.2. Giới thiệu LSTM: 6

2.2.3. Cấu trúc của LSTM gồm: 7

2.2.4. Quy trình hoạt động của LSTM: 9

2.2.5. Ưu điểm của LSTM: 9

2.2.6. Ứng dụng của LSTM: 9

2.2.7. Các biến thể của LSTM: 11

2.2.8. So sánh LSTM với RNN và GRU: 11

2.2.9. Các tham số huấn luyện chính của LSTM: 12

2.2.10. Hạn chế của LSTM: 12
2.3. Các Chỉ Số Đánh Giá Mô Hình Dự Báo. 13
2.4. Kiểm Tra Mô Hình. 14
2.5. Ứng Dụng Trong Dự Báo Lượng Mưa. 15
CHƯƠNG 3: CƠ SỞ DỮ LIỆU VÀ TIỀN XỬ LÝ 16
3.1. Nguồn Dữ Liệu. 16
3.2. Mô Tả Dữ Liệu. 17
3.3. Tiền Xử Lý Dữ Liệu. 18
3.3.1. Lọc Dữ Liệu Khu Vực Nghiên Cứu: 18
3.3.2. Gom Nhóm Lượng Mưa Theo Ngày: 18
3.3.3. Kiểm tra và xử lý dữ liệu thiếu, dị thường: 19
3.3.4. Chuẩn Hóa Dữ Liệu (Normalization): 19
3.3.5. Tạo Dữ Liệu Chuỗi Thời Gian: 19
3.3.6. Chia Tập Huấn Luyện Và Kiểm Tra: 20
3.3.7. Định hình lại dữ liệu cho LSTM: 20
CHƯƠNG 4: XÂY DỰNG MÔ HÌNH LSTM 21
4.1. Môi Trường Thực Hiện. 21
4.1.1. Nền Tảng Thực Hiện: 21
4.1.2. Ngôn Ngữ Và Thực Hiện: 21
4.1.3. Cấu Hình Phần Cứng (Trong Colab): 21
4.2. Thực Nghiệm. 21
4.2.1. Môi trường thực nghiệm: 21
4.2.2. Các Bước Tiến Hành: 22
4.3. Cấu Trúc Mô Hình LSTM. 23

4.3.1. Kiến Trúc Mô Hình: 23
4.3.2. Các Thành Phần Kỹ Thuật: 24
4.4. Tiến Trình Huấn Luyện Mô Hình. 24
4.5. Dự Báo Và Lưu Kết Quả. 25
CHƯƠNG 5: KẾT QUẢ VÀ ĐÁNH GIÁ 27
5.1. Kết Quả Huấn Luyện Mô Hình. 27
5.1.1. Đánh Giá Hiệu Suất: 27
5.1.2. Dự Báo & Đánh Giá: 28
5.1.3. Ma Trận Lượng Mưa Theo Tháng Và Tỉnh: 34
5.1.4. Phần Trăm Lượng Mưa Theo Mùa Ở Miền Trung: 38
5.1.5. So Sánh Các Tỉnh Miền Trung: 40
5.1.6. Dự Báo Ngày Tiếp Theo: 42
5.1.6. Bản Đồ Thực Tế Lượng Mưa Tại Miền Trung: 44
5.2. Phân Tích Kết Quả. 46
5.3. So Sánh Với Các Mô Hình Khác. 47
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 50
6.1. Kết Luận. 50
6.2. Hạn Chế Của Đề Tài 51
6.3. Hướng Phát Triển. 52
TÀI LIỆU THAM KHẢO 54

DANH MỤC HÌNH

Hình 1.1: Ngập lụt tại Nghệ An. Nguồn: Báo Lao Động 1
Hình 2.1: Sơ đồ kiến trúc mạng nơ-ron hồi quy (RNN) 6
Hình 2.2: Cấu trúc chi tiết của mạng LSTM. 6
Hình 2.3: Sơ đồ kiến trúc LSTM 7
Hình 2.4: Ứng dụng của LSTM. Nguồn: interdata.vn 11
Hình 2.5: Kiến trúc và sự khác biệt giữa LSTM và GRU. Nguồn: interdata.vn 12
Hình 3.1: Danh sách các tỉnh miền Trung Việt Nam 16
Hình 3.2 : Dữ liệu được Output thành bảng. 17
Hình 3.3: Chuyển đổi định dạng thời gian 18
Hình 3.4: Tổng hợp lượng mưa theo ngày 19
Hình 3.5: Chuẩn hóa dữ liệu 19
Hình 3.5: Chuỗi thời gian dạng Sliding Window 20
Hình 3.6: Train/Test 20
Hình 3.7: Định hình lại cho LSTM 20
Hình 4.1: Vào phần mềm Google Colab. 22
Hình 4.2: Giao diện chính. 22
Hình 4.3: Các bước chuẩn bị Runtime 22
Hình 4.4: Màn hình đã lưu data cần train. 23
Hình 4.5: Thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy. 23
Hình 4.6: Mô hình LSTM 24
Hình 4.7: Mô hình LSTM với Adam_MSE 24
Hình 4.8: Dự đoán chuỗi thời gian trong 7 ngày tiếp theo 25
Hình 4.9: So sánh thực tế và dự báo 25

Hình 4.10: Lưu mô hình và kết quả dự báo ra file.....26
Hình 5.1: Biểu đồ Loss qua các Epochs.....27
Hình 5.2: Kết quả RMSE của mô hình.....28
Hình 5.3: Biểu đồ phân tán mối quan hệ giữa nhiệt độ, lượng mưa và độ ẩm.....29
Hình 5.4: Biểu đồ phân phối lượng mưa và nhiệt độ trung bình tại miền Trung.....30
Hình 5.5: So sánh lượng mưa thực tế và dự đoán tại Miền Trung 30
Hình 5.6: Biểu đồ tổng lượng mưa Miền Trung theo tháng và năm.....31
Hình 5.7: Biểu đồ biến động lượng mưa 30 ngày tại miền Trung.....32
Hình 5.8: Tổng lượng mưa trung bình năm tại các tỉnh miền Trung.....33
Hình 5.9: Nhiệt độ trung bình ngày tại Đà Nẵng theo thời gian 34
Hình 5.10: Ma trận tương quan giữa các biến khí hậu.....36
Hình 5.11: Biểu đồ tròn tỉ lệ các loại ngày mưa tại miền Trung 38
Hình 5.12: Biểu đồ cột tổng lượng mưa theo mùa tại miền Trung.....39
Hình 5.13: Biểu đồ các ngày mưa cực đoan.....40
Hình 5.14: Xu hướng lượng mưa hàng tháng của từng tỉnh miền Trung 41
Hình 5.15: Biểu đồ violin phân bố nhiệt độ tại các tỉnh miền Trung 42
Hình 5.16: Kết quả dự báo lượng mưa.....43
Hình 5.17: Kết quả dự báo nhiệt độ 43
Hình 5.18: Kết quả dự báo lượng mưa 7 ngày kế tiếp các tỉnh miền Trung.....44
Hình 5.19: Bản đồ trực quan lượng mưa tại các tỉnh miền Trung bằng Folium 46

DANH MỤC BẢNG

Bảng 3.1: Bảng mô tả dữ liệu. 17

Bảng 5.1: Lượng mưa từng tháng của các tỉnh.....35

Bảng 5.2: Phân loại và thống kê số ngày mưa tại các tỉnh miền Trung.....37

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

Viết Tắt	Ý Nghĩa
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
RMSE	Root Mean Squared Error
MAPE	Mean Absolute Percentage Error
RNN	Recurrent Neural Network
ARIMA	AutoRegressive Integrated Moving Average
NCHMF	National Centre for Hydro-Meteorological Forecasting
MLP	Multilayer Perceptron
GRU	Gated Recurrent Unit

CHƯƠNG 1: GIỚI THIỆU

1.1. Bối Cảnh Và Lý Do Chọn Đề Tài.

Miền Trung Việt Nam là một khu vực bị ảnh hưởng bởi các hiện tượng thời tiết khắc nghiệt như mưa lớn, bão và lũ lụt, đặc biệt liên quan đến biến đổi khí hậu gia tăng. Thiệt hại do lũ lụt không chỉ ảnh hưởng đến cuộc sống và sản xuất của mọi người, mà còn ảnh hưởng tiêu cực đến sự phát triển kinh tế xã hội bền vững của khu vực. Trong khi đó, các phương pháp dự đoán truyền thống vẫn bị giới hạn trong việc xử lý dữ liệu thời tiết phi tuyến và sự phụ thuộc vào thời gian cao. Những phát triển mạnh mẽ trong trí tuệ nhân tạo, đặc biệt là các mô hình chi tiết như LSTM (Long Short-Term Memory), làm cho việc áp dụng các công cụ hiện đại khả thi và hiệu quả hơn. LSTM có khả năng ghi nhớ bản thân trong các mối quan hệ lâu dài và mô hình theo thời gian. Nhóm tiến hành nghiên cứu " Dự báo lượng mưa và nguy cơ lũ lụt tại miền Trung Việt Nam bằng mô hình LSTM " nhằm đáp ứng nhu cầu thực tiễn và phát huy tiềm năng ứng dụng của phương pháp này.



Hình 1.1: Ngập lụt tại Nghệ An. Nguồn: Báo Lao Động

1.2. Mục Tiêu Của Đề Tài.

Mục tiêu chủ yếu của nghiên cứu này là tìm hiểu và phát triển một mô hình để dự đoán lượng mưa tại khu vực miền Trung Việt Nam, bằng cách sử dụng mạng nơ-ron hồi tiếp LSTM, một cấu trúc học sâu đặc biệt để xử lý dữ liệu theo thời gian. Một cách cụ thể, nghiên cứu sẽ thu thập và xử lý dữ liệu thời tiết theo thời gian, mô hình LSTM sẽ được huấn luyện nhằm dự đoán chính xác lượng mưa trong những ngày tới, qua đó giúp đánh giá một cách chủ động nguy cơ xảy ra lũ lụt. Hơn nữa, nghiên cứu cũng đặt ra mục tiêu so sánh hiệu suất của mô hình LSTM với các phương pháp truyền thống trong việc dự báo thời tiết, nhằm làm rõ những ưu điểm và nhược điểm của từng phương pháp. Việc dự đoán chính xác lượng mưa không chỉ có ý nghĩa học thuật trong việc ứng dụng trí tuệ nhân tạo vào lĩnh vực khí tượng thủy văn, mà còn mang lại giá trị thực tiễn cao, góp phần vào công tác cảnh báo sớm, giảm thiểu thiệt hại do thiên tai, và hỗ trợ các cơ quan chức năng cũng như cộng đồng dân cư tại miền Trung trong việc ứng phó hiệu quả trước những thay đổi bất thường của thời tiết.

1.3. Phương Pháp Nghiên Cứu.

Phương pháp nghiên cứu của dự án được thực hiện theo cách kết hợp giữa lý thuyết và thực hành, với điểm nhấn là việc áp dụng mô hình học sâu LSTM để dự đoán chuỗi thời gian. Đầu tiên, dữ liệu về thời tiết trong quá khứ ở khu vực miền Trung Việt Nam sẽ được thu thập từ các nguồn đáng tin cậy như Cục Khí Tượng Thủy Văn và các cơ sở dữ liệu công khai. Dữ liệu này sẽ trải qua quá trình tiền xử lý thông qua các kỹ thuật như làm sạch, xử lý các giá trị thiếu, chuẩn hóa và phân chia các tập dữ liệu huấn luyện và kiểm tra. Tiếp theo, mô hình LSTM sẽ được thiết lập và đào tạo với tập dữ liệu đã được xử lý nhằm học tập những đặc điểm của sự biến đổi lượng mưa theo thời gian. Các tham số mô hình sẽ được điều chỉnh để tối ưu hóa khả năng dự đoán. Sau giai đoạn huấn luyện, mô hình sẽ được kiểm tra bằng một số chỉ số như RMSE, MAE hay MAPE để đánh giá độ chính xác và khả năng tổng quát. Cuối cùng, kết quả dự đoán sẽ được phân tích nhằm xác định những thời

điểm có lượng mưa lớn bất thường, từ đó đưa ra cảnh báo sớm về nguy cơ lũ lụt.

1.4. Phạm Vi Nghiên Cứu.

Phạm vi của nghiên cứu này tập trung vào việc dự báo lượng mưa tại một số tỉnh tiêu biểu thuộc khu vực miền Trung Việt Nam, bao gồm Quảng Nam, Đà Nẵng, Quảng Ngãi,... Đây là các khu vực có đặc điểm đại hình dốc, ven biển và hệ thống sông suối phức tạp, làm gia tăng nguy cơ ngập úng và lũ quét khi xảy ra mưa lớn kéo dài. Dữ liệu sử dụng trong nghiên cứu bao gồm các yếu tố khí tượng thu thập theo ngày, chủ yếu là lượng mưa và nhiệt độ, trong giai đoạn từ năm 2010 đến năm 2024. Dữ liệu được thu thập từ các trạm quan trắc khí tượng thủy văn và các nguồn dữ liệu công khai đáng tin cậy.

Về phương pháp, nghiên cứu tập trung triển khai mô hình LSTM, một dạng mô hình học sâu phù hợp với dữ liệu chuỗi thời gian có tính phụ thuộc dài hạn. Nghiên cứu không mở rộng so sánh hiệu suất với các mô hình học máy hoặc mô hình thống kê khác, nhằm tập trung phân tích hiệu quả nội tại của LSTM trong bối cảnh dự báo khí tượng khu vực. Mục tiêu chinh của nghiên cứu là xây dựng một mô hình dự báo lượng mưa ngắn hạn với độ chính xác chấp nhận được, từ đó hỗ trợ cảnh báo sớm và nâng cao khả năng ứng phó với nguy cơ thiên tai do mưa lớn gây ra tại các khu nghiên cứu. Tuy nhiên, phạm vi nghiên cứu vẫn còn những giới hạn nhất định, như: chưa tích hợp các yếu tố địa hình, mực nước sông hay mô hình thủy văn để phỏng chính xác quá trình hình thành và lan truyền lũ lụt; việc cảnh báo nguy cơ lũ lụt chủ yếu dựa trên ngưỡng lượng mưa định tính.

Từ những vấn đề đã nêu ở phần Giới thiệu, có thể thấy rằng việc dự báo lượng mưa và nguy cơ lũ lụt đòi hỏi sự kết hợp giữa lý thuyết chuỗi thời gian và các mô hình học máy hiện đại. Để làm rõ cơ sở khoa học của nghiên cứu, Chương 2 sẽ trình bày các khái niệm nền tảng về chuỗi thời gian, những phương pháp dự báo phổ biến, cũng như nguyên lý hoạt động của mạng nơ-ron hồi tiếp LSTM – mô hình chính được lựa chọn trong đề tài.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Chuỗi Thời Gian.

Chuỗi thời gian là tập hợp các quan sát của một hiện tượng được ghi nhận theo trình tự thời gian, thường cách đều nhau theo ngày, tháng, quý hoặc năm. Điểm đặc trưng của dữ liệu chuỗi thời gian là yếu tố thời gian gắn liền với từng quan sát, khiến cho thứ tự của dữ liệu mang ý nghĩa quan trọng.

a) Đặc điểm của chuỗi thời gian.

- **Tính tuần hoàn :** Dữ liệu có thể lặp lại theo chu kỳ nhất định, ví dụ như lượng mưa theo mùa hoặc doanh thu theo quý.
- **Xu hướng :** Chuỗi dữ liệu có thể tăng hoặc giảm trong dài hạn, phản ánh sự thay đổi tổng thể của hiện tượng.
- **Tính ngẫu nhiên :** Trong dữ liệu luôn tồn tại các biến động ngẫu nhiên không thể dự đoán chính xác.
- **Tính tự tương quan :** Giá trị ở một thời điểm có thể phụ thuộc vào giá trị ở những thời điểm trước đó.

b) Ứng dụng của chuỗi thời gian.

- **Kinh tế – Tài chính:** Dự báo giá cổ phiếu, lạm phát, GDP.
- **Khí tượng – Thủy văn:** Dự báo thời tiết, lượng mưa, lũ lụt, hạn hán.
- **Y tế:** Phân tích dịch bệnh, số ca mắc bệnh theo thời gian.
- **Công nghiệp:** Dự báo nhu cầu điện năng, sản lượng sản xuất.

c) Các thành phần cơ bản của chuỗi thời gian.

- **Thành phần xu hướng (Tt):** Biểu thị sự thay đổi chung dài hạn.
- **Thành phần mùa vụ (St):** Thể hiện tính lặp lại theo chu kỳ.
- **Thành phần chu kỳ (Ct):** Dao động theo giai đoạn dài hơn mùa vụ, thường gắn với chu kỳ kinh tế.
- **Thành phần ngẫu nhiên (It):** Dao động bất thường không theo quy luật.

d) Mô hình tổng quát.

Một chuỗi thời gian có thể được biểu diễn bằng công thức:

$$\boldsymbol{Y_t = T_t + S_t + C_t + I_t}$$ (mô hình cộng)

Hoặc

$$\boldsymbol{Y_t = T_t * S_t * C_t * I_t}$$ (mô hình nhân)

Trong đó:

- $\boldsymbol{Y_t}$**:** Giá trị quan sát tại thời điểm t.
- $\boldsymbol{T_t}$**:** Xu hướng.
- $\boldsymbol{S_t}$**:** Mùa vụ.
- $\boldsymbol{C_t}$**:** Chu kỳ.
- $\boldsymbol{I_t}$ **:** Ngẫu nhiên.

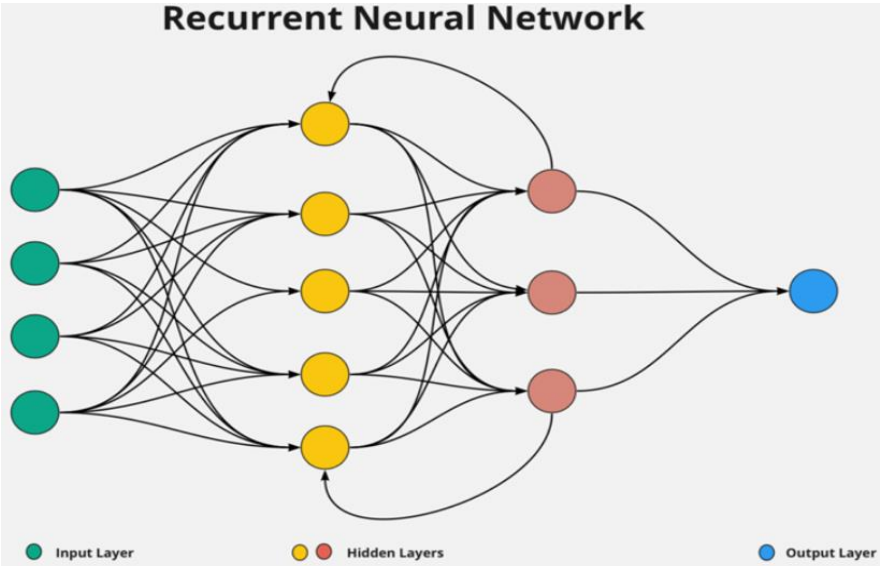
Từ đặc điểm và ứng dụng của chuỗi thời gian, ta thấy rõ nhu cầu sử dụng các mô hình học máy tiên tiến để dự báo chính xác, trong đó nổi bật là LSTM.

2.2. Mô Hình LSTM.

2.2.1. Khái quát về RNN:

RNN là một trong những mô hình mạng nơ-ron đầu tiên được thiết kế chuyên biệt để xử lý dữ liệu chuỗi nhờ khả năng ghi nhớ thông tin từ các bước thời gian trước đó. Tuy nhiên, khi áp dụng cho các chuỗi dài, RNN thường gặp phải hai vấn đề lớn: gradient biến mất và gradient bùng nổ trong quá trình lan truyền ngược. Điều này khiến RNN khó có thể học được các mối quan hệ phụ thuộc dài hạn trong dữ liệu.

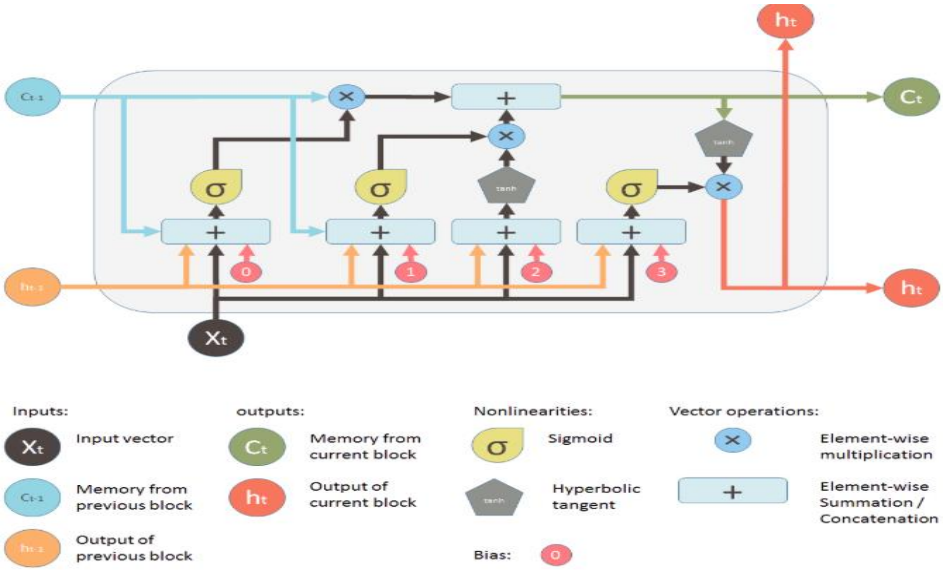
Để khắc phục nhược điểm đó, Hochreiter và Schmidhuber (1997) đã đề xuất mô hình LSTM. LSTM được trang bị cơ chế bộ nhớ và các cổng kiểm soát thông tin input gate, forget gate, output gate; cho phép mô hình ghi nhớ các thông tin quan trọng trong thời gian dài và loại bỏ thông tin không cần thiết. Nhờ vậy, LSTM trở thành một trong những kiến trúc mạnh mẽ và phổ biến nhất trong các bài toán chuỗi thời gian và xử lý ngôn ngữ tự nhiên.



Hình 2.1: Sơ đồ kiến trúc mạng nơ-ron hồi quy (RNN)

2.2.2. Giới thiệu LSTM:

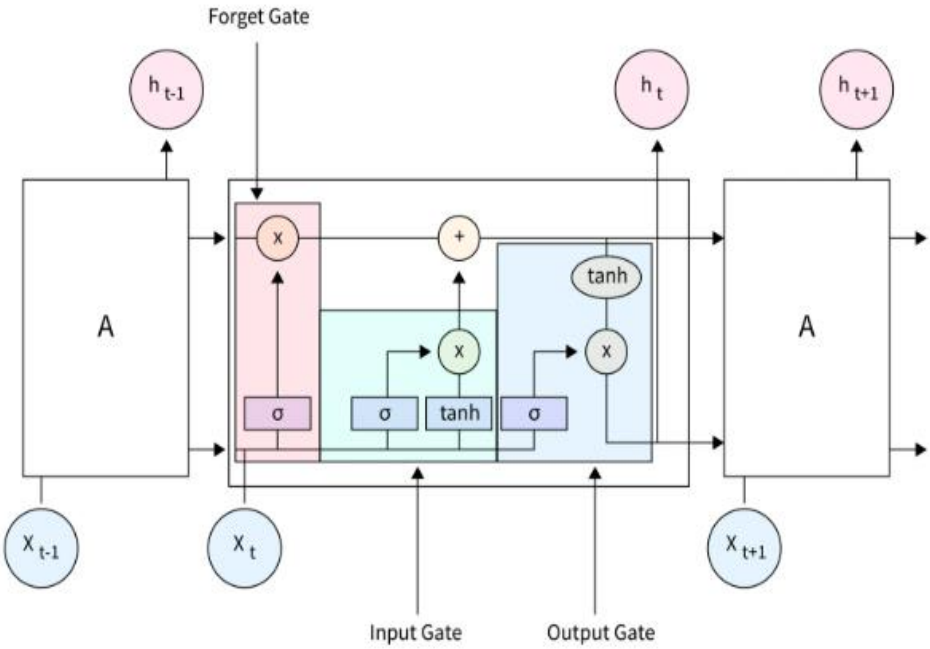
Mạng LSTM là một biến thể của RNN, được phát triển để khắc phục nhược điểm của RNN truyền thống. bằng cách sử dụng cơ chế bộ nhớ đặc biệt gồm các cổng (gate) như cổng vào, cổng quên và cổng đầu ra để điều khiển luồng thông tin. Nhờ đó, LSTM có khả năng lưu trữ và khai thác thông tin lâu dài trong thời gian, giúp mô hình học được các mối quan hệ phức tạp và dài hạn trong chuỗi thời gian một cách hiệu quả hơn.



Hình 2.2: Cấu trúc chi tiết của mạng LSTM.

2.2.3. Cấu trúc của LSTM gồm:

Tại mỗi bước thời gian t, với đầu vào x_t và các trạng thái trước đó h_{t-1} cũng như C_{t-1}, LSTM tính toán như sau:



Hình 2.3: Sơ đồ kiến trúc LSTM

a. Cổng quên (Forget Gate):

Giúp quyết định giữ lại bao nhiêu thông tin từ trạng thái cũ.

$$\boldsymbol{f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)}$$

- **Mục đích:** Quyết định bao nhiêu phần của C_{t-1} (cell state trước đó) cần bị loại bỏ.
- **Đầu vào:** Concatenation của h_{t-1} (trạng thái ẩn trước đó) và x_t (đầu vào hiện tại).
- **Trong số:** W_f (trọng số của Forget Gate), b_f (bias).

b. Cổng nhập (Input Gate):

Xác định lượng thông tin mới cần đưa vào trạng thái bộ nhớ.

$$\boldsymbol{i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)}$$

$$\boldsymbol{\widetilde{C}_t = tanh(W_C \cdot [h_{t-1}, x_t] + b_C)}$$

- **Mục đích:**

- $\boldsymbol{i_t}$ **:** Quyết định lượng của $\tilde{C}_t$ (candidate cell state) sẽ được thêm vào C_t.
- $\boldsymbol{\widetilde{C}_t}$ **:** Tại ra giá trị đề xuất cập nhật cho cell state.

- **Trọng số:** W_i, W_C (trọng số cho input gate & candidate cell state) , b_i, b_C (bias).
- **Hàm kích hoạt:**
  - Hàm sigmoid σ điều chỉnh giá trị của candidate cell state.
  - Hàm tanh nén các giá trị về khoảng [-1, 1] nhằm đảm bảo cập nhật ổn định.

c. Cập nhật trạng thái bộ nhớ:

$$\boldsymbol{C_t = f_t \cdot C_{t-1} + i_t \cdot \widetilde{C}_t}$$

- **Mục đích:** Kết hợp thông tin cũ C_{t-1} với thông tin mới $\tilde{C}_t$
- **Phép toán:**
  - $\boldsymbol{f_t \cdot C_{t-1}}$ **:** Phép nhân từng phần " $\cdot$ " giúp loại bỏ các phần không cần thiết của C_{t-1}.
  - $\boldsymbol{i_t \cdot \widetilde{C}_t}$ **:** Thêm thông tin mới có liên quan từ $\tilde{C}_t$

d. Cổng đầu ra (Output Gate):

Cho phép xuất ra giá trị đầu ra tại thời điểm hiện tại.

$$\mathbf{o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o}$$

$$\boldsymbol{h_t = o_t \cdot tanh(C_t)}$$

- **Mục đích:**
  - $\mathbf{o_t}$ **:** Quyết định phần nào của C_t sẽ được xuất ra làm h_t.
  - $\boldsymbol{h_t}$ **:** Trạng thái ẩn được truyền cho bước thời gian tiếp theo.
- **Trọng số:** W_o (trọng số của output gate), b_o (bias).
- **Hàm kích hoạt:**
  - $\mathbf{o_t}$ **:** Hàm sigmoid σ lọc thông tin từ C_t.
  - **tanh:** Nén giá trị của C_t về khoảng [-1, 1] trước khi nhân với o_t.

2.2.4. Quy trình hoạt động của LSTM:

Khi một chuỗi dữ liệu được đưa vào mạng LSTM, tại mỗi bước thời gian, đơn vị LSTM tiếp nhận dữ liệu đầu vào và trạng thái ẩn từ bước trước. Quá trình xử lý diễn ra qua ba bước chính:

1. **Tiếp nhận và xử lý đầu vào:** LSTM phân tích dữ liệu hiện tại và trạng thái trước đó, sử dụng các cổng để đánh giá và xác định thông tin nào quan trọng cần giữ lại cho bước tiếp theo.
2. **Cập nhất trạng thái ô nhớ:** Dựa trên tín hiệu từ các cổng, ô nhớ nội bộ được cập nhật. Cổng quên loại bỏ thông tin không cần thiết, trong khi cổng đầu vào bô sung thông tin mới phù hợp vào trạng thái hiện tại.
3. **Tạo và xuất đầu ra:** Thông qua cổng đầu ra, LSTM sinh ra trạng thái ẩn mới và kết quả tại thời điểm đó, đồng thời truyền sang bước kế tiếp để tiếp tục quá trình học và dự báo.

2.2.5. Ưu điểm của LSTM:

1. **Khả năng học và ghi nhớ thông tin dài hạn:** LSTM được thiết kế với cơ chế bộ nhớ cho phép lưu trữ thông tin trong thời gian dài, giúp mô hình nhận diện với khai thác các mối quan hệ xa trong chuỗi dữ liệu.
2. **Giảm thiểu hiện tượng mất thông tin:** Nhờ cấu trúc đặc biệt với các cổng vào, quên và đầu ra, LSTM có thể kiểm soát luồng thông tin và duy trì các đặc trưng quan trọng trong suốt quá trình huấn luyện, từ đó hạn chế tình trạng gradient biến mất – một nhược điểm lớn của RNN truyền thống.
3. **Ứng dụng đa dạng:** LSTM rất phù hợp với các bài toán xử lý chuỗi thời gian phức tạp như dự báo thời tiết, phân tích tài chính, dự đoán dịch bệnh, nhận dạng giọng nói, và xử lý ngôn ngữ tự nhiên (NLP).

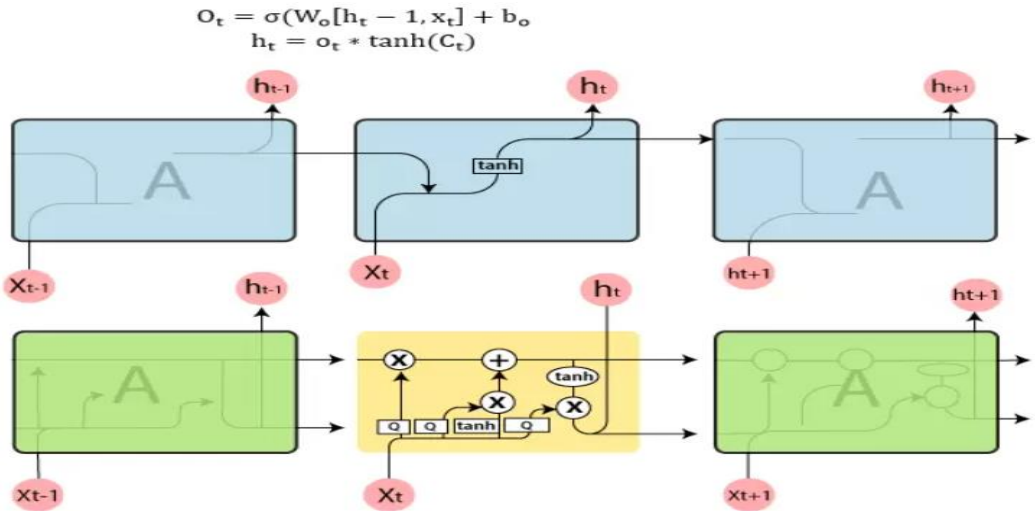
2.2.6. Ứng dụng của LSTM:

LSTM đã chứng tỏ năng lực vượt trội và tính ứng dụng cao trong nhiều lĩnh vực khác nhau. Một số ví dụ ứng dụng nổi bật bao gồm:

- **Dự báo giá trị tài chính (ví dụ: giá cổ phiều):** LSTM có thể được khai

thác để dự đoán diễn biến giá cổ phiếu trong tương lai bằng cách phân tích các chuỗi dữ liệu lịch sử về giá của cổ phiếu đó. Nhờ khả năng ghi nhớ các phụ thuộc dài hạn, LSTM thường giúp cải thiện độ chính xác của mô hình dự báo tài chính.

- **Xử lý ngôn ngữ tự nhiên (NLP):** Trong lĩnh vực NLP, LSTM rất hiệu quả trong việc xử lý các chuỗi từ hoặc ký tự. Nó giúp mô hình hiểu rõ hơn ngữa cảnh và xử lý các câu văn dài – điều mà các mạng RNN truyền thống có thể gặp khó khăn.
- **Dự báo các hiện tượng thời tiết:** LSTM có thể được huấn luyện để dự đoán sự biến đổi của các yếu tố thời tiết bằng cách phân tích các chuỗi dự liệu thời tiết được ghi nhận trong quá khứ (nhiệt độ, độ ẩm, lượng mưa,…).
- **Mô hình ngôn ngữ:** Được sử dụng trong các tác vụ như mô hình ngôn ngữ, dịch máy và tóm tắt văn bản. Những mạng này học cách nhận diện sự phụ thuộc giữa các từ trong câu để tạo ra những câu chính xác về mặt ngữ pháp và mạch lạc.
- **Nhận dạng giọng nói:** Dùng để chuyển đổi giọng nói thành văn bản và nhận diện các lệnh nói. Bằng cách học các mẫu giọng nói, chúng có thể khớp các từ đã nói với văn bản tương ứng.
- **Phát hiện bất thường:** Dùng để phát hiện gian lận hoặc xâm nhập mạng. Những mạng này có thể nhận diện các mẫu trong dữ liệu có sự sai lệch lớn và đánh dấu chúng như những bất thường tiềm ẩn.
- **Hệ thống gợi ý**: Trong các tác vụ gợi ý như đề xuất phim, âm nhạc và sách. LSTM học các mẫu hành vi của người dùng để đưa ra những gợi ý cá nhân hóa.
- **Phân tích video**: Áp dụng trong các tác vụ như phát hiện đối tượng, nhận diện hoạt động và phân loại hành động. Khi kết hợp với Mạng Nơ-ron Chập (CNN), LSTM giúp phân tích dữ liệu video và trích xuất thông tin hữu ích.



Hình 2.4: Ứng dụng của LSTM. Nguồn: interdata.vn

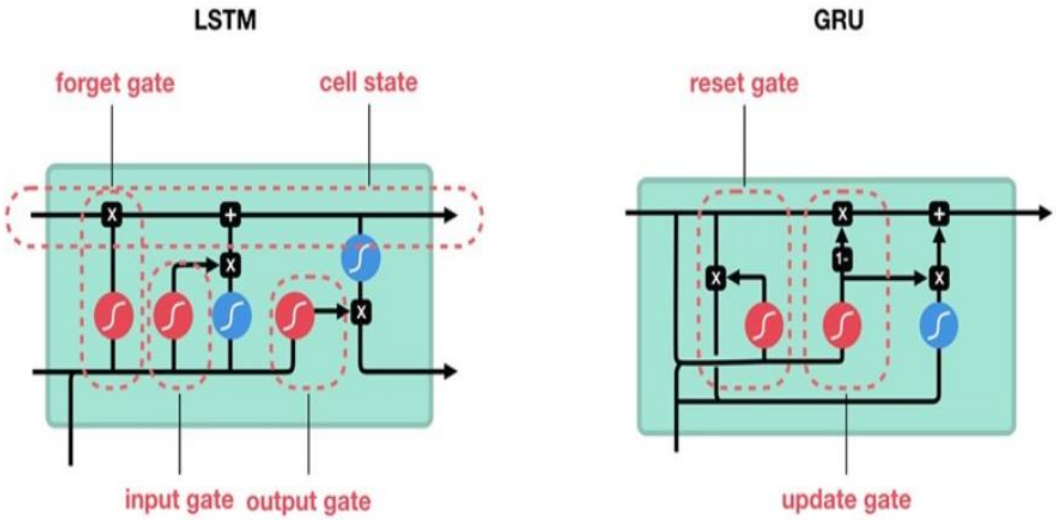
2.2.7. Các biến thể của LSTM:

Ngoài kiến trúc LSTM cơ bản, nhiều biến thể đã được phát triển nhằm cải thiện hiệu năng và giảm chi phí tính toán:

- **Bidirectional LSTM :** Cho phép mô hình học thông tin theo cả hai chiều quá khứ và tương lai, đặc biệt hữu ích trong xử lý ngôn ngữ tự nhiên.
- **Stacked LSTM:** Xếp chồng nhiều lớp LSTM để tăng khả năng trích xuất đặc trưng và học các quan hệ phức tạp.
- **Convolutional LSTM :** Kết hợp giữa CNN và LSTM, áp dụng tốt cho dữ liệu không gian–thời gian như dự báo mưa từ bản đồ radar.
- **Peephole LSTM:** Bổ sung kết nối từ cell state tới các cổng, giúp tăng khả năng học quan hệ dài hạn.

2.2.8. So sánh LSTM với RNN và GRU:

- **So với RNN:** LSTM khắc phục được hiện tượng vanishing gradient, cho phép học quan hệ dài hạn mà RNN truyền thống gặp khó khăn.
- **So với GRU:** GRU có cấu trúc gọn hơn 2 cổng thay vì 3, tính toán nhanh hơn, nhưng trong nhiều trường hợp LSTM vẫn cho kết quả ổn định hơn nhờ khả năng lưu giữ thông tin chi tiết trong cell state.



Hình 2.5: Kiến trúc và sự khác biệt giữa LSTM và GRU. Nguồn: interdata.vn

2.2.9. Các tham số huấn luyện chính của LSTM:

Khi xây dựng và huấn luyện mô hình LSTM, hyperparameters quan trọng cần được lựa chọn:

- **Số lượng cell ẩn :** Quyết định dung lượng ghi nhớ và khả năng học của mạng.
- **Số lớp LSTM :** LSTM nhiều lớp thường học được đặc trưng phức tạp hơn nhưng dễ bị quá khớp (overfitting).
- **Batch size :** Số mẫu dữ liệu được đưa vào mô hình trong một lần cập nhật trọng số.
- **Learning rate :** Tốc độ học; nếu quá cao sẽ khó hội tụ, quá thấp thì mô hình học chậm.
- **Epochs :** Số vòng lặp huấn luyện qua toàn bộ tập dữ liệu.
- **Dropout :** Kỹ thuật chống overfitting bằng cách bỏ ngẫu nhiên một số neuron trong quá trình huấn luyện.

2.2.10. Hạn chế của LSTM:

Bên cạnh ưu điểm, LSTM vẫn tồn tại một số hạn chế:

- **Tốn kém tính toán:** Do có nhiều tham số và phép tính phức tạp hơn RNN hay GRU.

- **Khó huấn luyện:** Yêu cầu dữ liệu lớn và điều chỉnh siêu tham số phù hợp.
- **Không phù hợp với chuỗi siêu dài:** Dù tốt hơn RNN, nhưng với chuỗi dữ liệu cực dài, LSTM vẫn gặp khó khăn.
- **Chậm so với các kiến trúc mới hơn:** Ví dụ như Transformer thường nhanh hơn trong các bài toán ngôn ngữ.

2.3. Các Chỉ Số Đánh Giá Mô Hình Dự Báo.

Để trong các bài toán dự báo chuỗi thời gian như dự báo lượng mưa, việc đánh giá hiệu suất của mô hình là bước rất quan trọng nhằm xác định mức độ tin cậy của kết quả dự báo. Đối với mô hình LSTM, ta cần các chỉ số đánh giá có khả năng đo lường sai lệch giữa giá dự báo và giá trị thực tế một cách chính xác và khách quan.

Các chỉ số phổ biến gồm:

- **MAE (Sai số tuyệt đối trung bình).**

  Là trung bình của sai số tuyệt đối giữa giá trị dự báo và thực tế. MAE cho biết mô hình sai lệch trung bình báo nhiêu mm lượng mưa trên mỗi điểm dữ liệu. Giá trị MAE càng thấp càng chứng tỏ mô hình càng chính xác.

$$\mathbf{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- **RMSE (Sai số bình phương trung bình).**

  Là căn bậc hai của trung bình bình phương sai số giữa giá trị dự báo và giá trị thực tế. Chỉ số này phản ánh mức độ sai lệch của mô hình, trong đó các sai số lớn được nhấn mạnh hơn do được bình phương trước khi tính trung bình. Vì vậy, RMSE đặc biệt phù hợp để đánh giá các mô hình trong bối cảnh có các giá trị bất thường hoặc biến động lớn như lượng mưa cực đoan.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

- **MAPE (Sai số phần trăm tuyệt đối trung bình).**

  Là tỷ lệ phần trăm sai số trung bình giữa giá trị dự báo và giá trị thực tế. Chỉ số này thể hiện mực độ sai lệch trung bình của mô hình so với thực tế trên thang đo tương đối, giúp đánh giá hiệu suất dự báo một cách trực quan và dễ hiểu. MAPE đặc biệt hữu ích khi so sánh độ chính xác của mô hình trên các tập dữ liệu có qua mô khác nhau.

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Trong dự báo lượng mưa, MAE cho biết sai số trung bình mỗi ngày, RMSE phản ánh mức độ sai lệch nghiêm trọng hơn khi có mưa lớn bất thường, còn MAPE cho ta góc nhìn trực quan về phần tram sai lệch.

2.4. Kiểm Tra Mô Hình.

Mô hình LSTM sau khi được huấn luyện sẽ được đánh giá trên bộ dữ liệu thử nghiệm, là phần dữ liệu chưa từng được mô hình " thấy " trong quá trình học. Việc này nhằm kiểm tra khả năng tổng quát hóa và đảm bảo mô hình không bị quá khớp (overfitting) với dữ liệu huấn luyện.

- Để đánh giá hiệu suất, các chỉ số thường được sử dụng là:
  - **MAE:** đo sai số trung bình tuyệt đối, phản ánh mức độ sai lệch trực tiếp giữa dự báo và thực tế.
  - **RMSE:** nhấn mạnh sai số lớn nhờ phép bình phương, do đó thích hợp để đánh giá trong các tình huống có biến động mạnh.
  - **MAPE:** cho biết tỷ lệ phần trăm sai số trung bình so với giá trị thực tế, giúp dễ dàng so sánh giữa các tập dữ liệu khác nhau.

Nếu các chỉ số MAE, RMSE và MAPE có giá trị nhỏ, điều đó chứng tỏ mô hình đạt độ chính xác cao trong dự báo lượng mưa. Ngược lại, nếu sai số lớn, mô hình

cần được hiệu chỉnh lại thông qua việc điều chỉnh tham số hoặc thay đổi kiến trúc mạng

2.5. Ứng Dụng Trong Dự Báo Lượng Mưa.

Mô hình LSTM cung cấp khả năng dự đoán chính xác lượng mưa theo thời gian, giúp cảnh báo sớm về nguy cơ ngập lụt tại khu vực miền Trung. Kết quả của dự báo này có thể được đưa vào hệ thống thời tiết, ứng dụng cảnh báo thiên tai hoặc quản lý các hồ chứa. Mô hình cũng có thể được áp dụng cho các khu vực khác cùng cới các yếu tố khí hậu như nhiệt độ, độ ẩm và tốc độ gió.

Khi triển khai thực tế, mô hình LSTM có thể được tích hợp vào hệ thống cảnh báo lũ của tỉnh miền Trung, cung cấp dự báo theo giờ hoặc theo ngày. Ngoài ra, kết quả cũng hỗ trợ tối ưu vận hành hồ chứa và quy hoạch nông nghiệp.

Sau khi đã làm rõ cơ sở lý thuyết và các mô hình dự báo chuỗi thời gian, nghiên cứu cần được triển khai dựa trên dữ liệu thực tế. Tuy nhiên, dữ liệu khí tượng thường mang tính phức tạp, có thể chứa sai lệch hoặc thiếu hụt. Vì vậy, Chương 3 sẽ tập trung mô tả chi tiết về nguồn dữ liệu, đặc trưng dữ liệu và các bước tiền xử lý được áp dụng trước khi đưa vào mô hình LSTM.

CHƯƠNG 3: CƠ SỞ DỮ LIỆU VÀ TIỀN XỬ LÝ

3.1. Nguồn Dữ Liệu.

Chất lượng của mô hình dự báo phụ thuộc chặt chẽ vào dữ liệu đầu vào. Trong đề tài này, dữ liệu chính được sử dụng là thu thập từ Kaggle dưới dạng tập tin df_weather. Bộ dữ liệu này cung cấp thông tin khí tượng gồm lượng mưa, nhiệt độ, độ ẩm,… và các yếu tố liên quan theo chuỗi thời gian, được sử dụng để huấn luyện và đánh giá mô hình dự báo lượng mưa và nguy cơ lũ lụt tại khu vực miền Trung Việt Nam:

Ngoài ra, để tham khảo về đối chiếu, nhóm còn nghiên cứu tìm hiểu thêm một số nguồn dữ liệu khí tượng khác:

- **Trạm khí tượng tại miền Trung Việt Nam:** Cung cấp dữ liệu thực tế về lượng mưa, nhiệt độ, độ ẩm, áp suất không khí,…theo thời gian.
- **NCHMF (National Centre for Hydro-Meteorological Forecasting):** Cơ quan khí tượng thủy văn quốc gia, cung cấp dữ liệu quan trắc và dự báo chính thống tại Việt Nam.
- **Bộ dữ liệu mưa từ 172 trạm quan tắc (1975 – 2006):** Do trung tâm dữ liệu khí tượng Thủy văn Việt Nam phát hành.
- **Dữ liệu khí hậu lịch sử (1901 – 2020)**: Từ CRU và dữ liệu mô phỏng khí hậu từ Meteoblue, giúp phân tích xu hướng biến đổi khí hậu dài hạn.
- Danh sách tỉnh được chọn:

```
central_provinces = [
    "Da Nang", "Thua Thien Hue", "Quang Nam", "Quang Ngai",
    "Binh Dinh", "Phu Yen", "Khanh Hoa", "Quang Tri", "Ha Tinh",
    "Nghe An","Quang Binh","Quang Ngai","Ninh Thuan","Binh Thuan"
]
```

Hình 3.1: Danh sách các tỉnh miền Trung Việt Nam

3.2. Mô Tả Dữ Liệu.

Dữ liệu được tổng hợp và lưu trữ trong tệp df_weather.csv có định dạng file.csv. Bao gồm:

- **Số dòng:** 24.192.
- **Số cột:** 38.
- **Thời gian phủ sóng:** Nhiều tháng liên tục.
- **Tần suất:** Mỗi dòng đại diện cho một ngày tại một địa phương

```
requests = pd.read_csv("/content/df_weather.csv")
requests.head()
```

	location.name	location.region	location.country	location.lat	location.lon	location.tz_id	location.
0	An Giang	Nam	Vietnam	10.7000	105.1167	Asia/Ho_Chi_Minh	
1	Ba Ria-Vung Tau	Nam	Vietnam	10.3500	107.0667	Asia/Ho_Chi_Minh	
2	Bac Giang	Bac	Vietnam	21.2667	106.2000	Asia/Bangkok	
3	Bac Kan	Bac	Vietnam	22.1333	105.8333	Asia/Bangkok	
4	Bac Lieu	Nam	Vietnam	9.2850	105.7244	Asia/Ho_Chi_Minh	

5 rows × 38 columns

Hình 3.2 : Dữ liệu được Output thành bảng.

- **Một số cột quan trọng:**

Cột dữ liệu	Mô tả
date	Ngày ghi nhận dữ liệu
location.name	Tên tỉnh/Thành phố
day.avgtemp_c	Nhiệt độ trung bình trong ngày (°C)
day.avghumidity	Độ ẩm trung bình (%)
day.totalprecip_mm	Tổng lượng mưa (mm) – Biến mục tiêu
day.maxwind_kph	Tốc độ gió lớn nhất (km/h)
day.condition.text	Mô tả điều kiện thời tiết (Nắng, Mưa, Mây...)
astro.sunrise	Giờ mặt trời mọc

Bảng 3.1: Bảng mô tả dữ liệu.

- **Kiểm tra dữ liệu:**
  - Không có giá trị thiếu (NaN) trong các cột chính, thuận lợi cho xử lý.
  - Không phát hiện giá trị dị thường như mưa, độ âm, nhiệt độ quá cao/thấp

bất thường.

- Định dạng dự liệu rõ ràng, sẵn sàng cho các bước xử lý tiếp theo.

3.3. Tiền Xử Lý Dữ Liệu.

Dự Dữ liệu thô sau khi thu thập được lọc theo khu vực nghiên cứu, chọn các cột cần thiết, xử lý giá trị thiếu, chuẩn hóa về cùng thang đo và chuyển thành chuỗi thời gian phù hợp với mô hình LSTM. Sau đó, dữ liệu được chia thành tập huấn luyện và kiểm tra để phục vụ quá trình huấn luyện mô hình:

3.3.1. Lọc Dữ Liệu Khu Vực Nghiên Cứu:

Do đề tài tập trung vào khu vực miền Trung – nơi thường xuyên hứng chịu mưa lớn và lũ lụt, nên dữ liệu cần được lọc để chỉ giữ lại các bản ghi liên quan đến những tỉnh trong khu vực này. Việc này giúp mô hình học đúng bản chất của bài toán và tránh nhiễu từ những vùng khí hậu khác biệt, nên dữ liệu cần được lọc lại để chỉ giữ các tỉnh thuộc khu vực này:

Kết quả là một bảng dữ liệu gồm 3 cột: ***date***, ***location.name*** và ***day.totalprecip_mm*** chứa lượng mưa theo từng ngày tại từng tỉnh.

```
central_provinces = [
    "Da Nang", "Thua Thien Hue", "Quang Nam", "Quang Ngai",
    "Binh Dinh", "Phu Yen", "Khanh Hoa", "Quang Tri", "Ha Tinh",
    "Nghe An","Quang Binh","Quang Ngai","Ninh Thuan","Binh Thuan"
]

df_central = requests[requests['location.name'].isin(central_provinces)]
df_central = df_central[['date', 'location.name', 'day.totalprecip_mm']]
df_central = df_central.dropna()
df_central = df_central.sort_values(by='date')
available_provinces = [p for p in requests['location.name'].unique() if any(c in p for c in central_provinces)]
```

Hình 3.3: Chuyển đổi định dạng thời gian

3.3.2. Gom Nhóm Lượng Mưa Theo Ngày:

Do mỗi ngày có nhiều địa điểm cùng ghi nhận lượng mưa, để đơn giản hóa bài toán dữ liệu được tổng hợp theo ngày, cộng dồn toàn bộ lượng mưa ghi nhận tại các tỉnh miền Trung. Kết quả thu được là một bảng 2 cột:

- ***date:*** Ngày đo.
- ***total_rain:*** Tổng lượng mưa toàn khu vực miền Trung trong ngày đó.

```
rain_by_date = df_central.groupby('date')['day.totalprecip_mm'].sum().reset_index()
rain_by_date.columns = ['date', 'total_rain']
```

Hình 3.4: Tổng hợp lượng mưa theo ngày

3.3.3. Kiểm tra và xử lý dữ liệu thiếu, dị thường:

- Sau khi lọc, dữ liệu được kiểm tra nhằm phát hiện các giá trị:
  - Bị thiếu (NaN).
  - Bất hợp lý (lượng mưa âm, sai định dạng, thời gian…)
- Kết quả cho thấy bộ dữ liệu khá sạch:
  - Không có giá trị NaN trong các cột quan trọng (***date***,***location.name***, ***day.totalprecip_mm***)
  - Dữ liệu thời gian được định dạng thống nhất
  - Các giá trị lượng mưa đều nằm trong khoảng hợp lý

3.3.4. Chuẩn Hóa Dữ Liệu (Normalization):

Dữ liệu lượng mưa thực tế có giá trị chênh lệch giữa các ngày (từ 0 đế vài chục mm). Để mô hình học tốt và tránh hiện tượng "bùng nổ gradient", cần đưa các giá trị về cùng một khoảng giá trị chuẩn hóa, phổ biến là [0,1]. Kết quả là một mảng số thực từ 0 đến 1, phản ánh tỷ lệ tương đối lượng mưa mỗi ngày.

```
# Chuẩn hoá dữ liệu
scaler = MinMaxScaler()
data_scaled = scaler.fit_transform(requests[['day.avgtemp_c']])
```

Hình 3.5: Chuẩn hóa dữ liệu

3.3.5. Tạo Dữ Liệu Chuỗi Thời Gian:

LSTM là mô hình chuyển xử lý chuỗi, vì vậy dữ liệu đầu vào cần được tổ chức lại thành các chuỗi nhỏ theo dạng cửa sổ trượt. Trong đồ án này, sử dụng cửa sổ 7 ngày, tức là:

- Dùng lượng mưa của 7 ngày liên tiếp → dự đoán lượng mưa của ngày tiếp theo.Kết quả:

- **X:** Tập các chuỗi 7 ngày.
- **y:** Giá trị lượng mưa ngày thứ 8 (mục tiêu cần dự đoán).

```
# Hàm tạo chuỗi thời gian
def create_sequences(data, window_size=7):
    X, y = [], []
    for i in range(window_size, len(data)):
        X.append(data[i-window_size:i, 0])
        y.append(data[i, 0])
    return np.array(X), np.array(y)

window_size = 7
X, y = create_sequences(data_scaled, window_size)
```

Hình 3.5: Chuỗi thời gian dạng Sliding Window

3.3.6. Chia Tập Huấn Luyện Và Kiểm Tra:

- Để đánh giá mô hình, ta cần tách một phần dữ liệu làm tập kiểm tra (test set).
  - Tỷ lệ: **80%** train, **20%** test.
  - Dữ liệu được giữ nguyên thứ tự thời gian, không trộn ngẫu nhiên (shuffle), để giữ nguyên mỗi liên hệ thời gian.

```
# Chia train/test
split = int(len(X)*0.8)
X_train, X_test = X[:split], X[split:]
y_train, y_test = y[:split], y[split:]
```

Hình 3.6: Train/Test

3.3.7. Định hình lại dữ liệu cho LSTM:

- LSTM yêu cầu đầu vào có định dạng 3 chiều: ***samples***, ***time_steps***, ***features.***
- Với bài toán này:
  - ***samples:*** Số lượng chuỗi.
  - ***time_steps:*** 7 (Số ngày trong cửa sổ).
  - ***features:*** 1 (Chỉ có lượng mưa).

```
# Reshape cho LSTM
X_train = X_train.reshape((X_train.shape[0], X_train.shape[1], 1))
X_test = X_test.reshape((X_test.shape[0], X_test.shape[1], 1))
```

Hình 3.7: Định hình lại cho LSTM

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH LSTM

4.1. Môi Trường Thực Hiện.

4.1.1. Nền Tảng Thực Hiện:

Toàn bộ quá trình xử lý và huấn luyện mô hình được thực hiện trên nền tảng Google Colab – một công cụ tính toán đám mây do Google cung cấp, hỗ trợ GPU, thuận tiện cho xử lý dữ liệu và huấn luyện mô hình học sâu. Bên cạnh đó, người dùng có thể sử dụng Jupyter Notebook nếu làm việc trên máy tính cá nhân.

4.1.2. Ngôn Ngữ Và Thực Hiện:

- **Ngôn ngữ:** Python 3.x
- **Thư viện sử dụng:**
  - **Pandas, Numpy:** xử lý, thống kê và thao tác dữ liệu dạng bảng.
  - **Matplotlib, Plotly:** trực quan hóa dữ liệu và biểu đồ kết quả.
  - **Scikit-learn:** chuẩn hóa dữ liệu (MinMaxScaler), phân chia tập huấn luyện/kiểm tra, tính toán độ chính xác mô hình.
  - **TensorFlow/Keras:** xây dựng và huấn luyện mô hình LSTM.
  - **Callback:** hỗ trợ theo dõi quá trình huấn luyện và lưu mô hình tốt nhất.

4.1.3. Cấu Hình Phần Cứng (Trong Colab):

- **GPU:** Tùy chọn GPU (Tesla T4 hoặc P100).
- **RAM:** khoảng 12.7 GB.
- **Bộ xử lý:** môi trường máy ảo của Google.

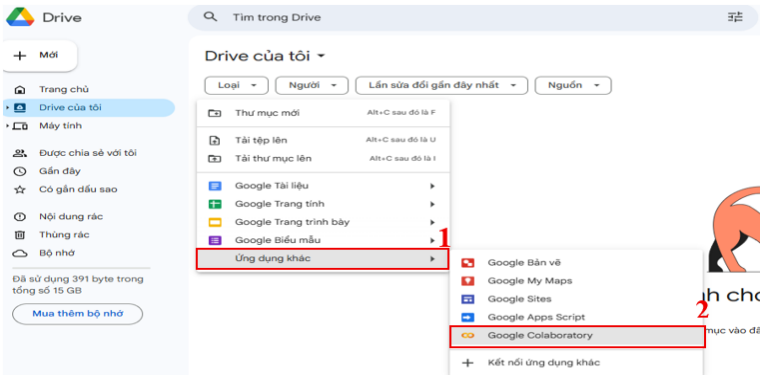
4.2. Thực Nghiệm.

4.2.1. Môi trường thực nghiệm:

Google Colab: Colaboratory, hay " **colab** " là nền tảng trực tuyến miễn phí của Google hỗ trợ viết mã Python và sử dụng GPU/TPU miễn phí. Người dùng có thể cài đặt các thư viện như TensorFlow, PyTorch, NumPy để huấn luyện mô hình

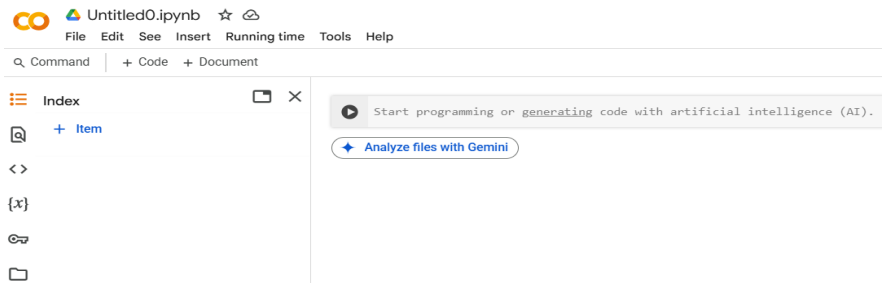
AI, xử lý dữ liệu lớn hoặc trực quan hóa kết quả.

- **Bước 1:** Vào Google, Nhấn vào " Drive " và Bấm chuột phải sẽ hiện thị lên phần mềm " Google Colab ".



Hình 4.1: Vào phần mềm Google Colab.

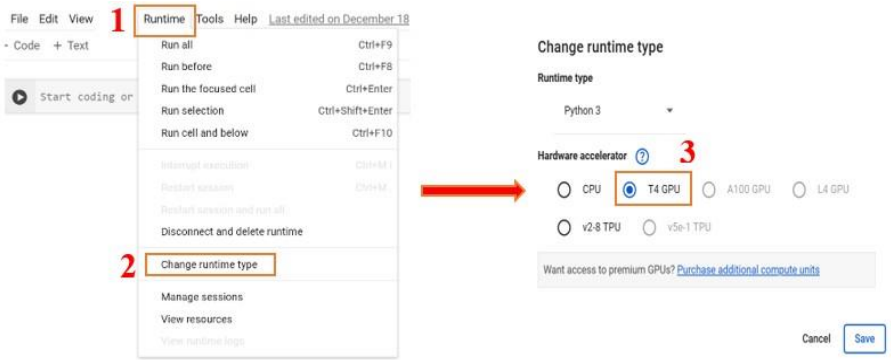
- **Bước 2:** Vào Google Colab ta sẽ có giao diện như hình gồm có các Tab **File**, **Edit**, **See**, **Insert**, **Running time**, **Tools** và **Help.**



Hình 4.2: Giao diện chính.

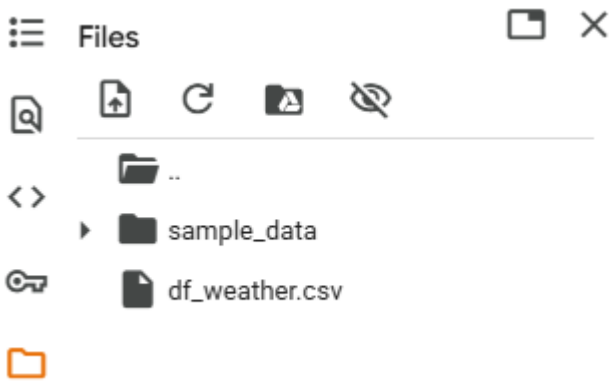
4.2.2. Các Bước Tiến Hành:

- **Bước 1:** Chuẩn bị thay đổi Runtime để train.



Hình 4.3: Các bước chuẩn bị Runtime

- **Bước 2:** Lưu data vào phần mềm google.colab để bắt đầu train.



Hình 4.4: Màn hình đã lưu data cần train.

- **Bước 3:** Copy file.csv để đưa vào xử lí nhận diện khoanh vùng đối tượng và tính toán xác suất. Cùng với đó là đưa ra thời gian xử lí data.

```
[ ] requests = pd.read_csv("/content/df_weather.csv")
    requests.head()
```

	location.name	location.region	location.country	location.lat	location.lon	location.tz_id
0	An Giang	Nam	Vietnam	10.7000	105.1167	Asia/Ho_Chi_Minh
1	Ba Ria-Vung Tau	Nam	Vietnam	10.3500	107.0667	Asia/Ho_Chi_Minh
2	Bac Giang	Bac	Vietnam	21.2667	106.2000	Asia/Bangkok
3	Bac Kan	Bac	Vietnam	22.1333	105.8333	Asia/Bangkok
4	Bac Lieu	Nam	Vietnam	9.2850	105.7244	Asia/Ho_Chi_Minh

5 rows × 38 columns

Hình 4.5: Thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy.

4.3. Cấu Trúc Mô Hình LSTM.

4.3.1. Kiến Trúc Mô Hình:

- **Mô hình được thiết kế đơn giản gồm:**
  - 1 lớp LSTM với 64 đơn vị ẩn, để học các mẫu từ chuỗi thời gian của dữ liệu lượng mưa, không sử dụng return_sequences.
  - Sau đó, kết quả từ lớp LSTM được đưa vào 1 lớp Dense với 1 neuron đầu ra, dùng để dự đoán lượng mưa cho ngày kế tiếp.
- **Đầu vào của mô hình là dữ liệu có dạng 3 chiều: *[samples, time_steps, features]***

- **Ví dụ:** nếu ta dùng 30 ngày liên tiếp làm một chuỗi đầu vào (tức là time_steps = 30), thì mô hình sẽ học từ chuỗi đó để dự đoán lượng mưa vào ngày thứ 31.

```
model = Sequential()
model.add(LSTM(64, return_sequences=False, input_shape=(30, 1)))
model.add(Dense(1))
```

Hình 4.6: Mô hình LSTM

4.3.2. Các Thành Phần Kỹ Thuật:

Để mô hình hoạt động hiệu quả, nhóm đã lựa chọn các thành phần kỹ thuật như sau:

- **Hàm kích hoạt:**
  - LSTM sử dụng tanh để ổn định quá trình lan truyền ngược.
  - Densen đầu ra dùng linear để trả về giá trị thực.
- **Hàm mất mát:** Là mean_squared_error (MSE) – đo sai số bình phương trung bình giữa giá trị thực về dự đoán.
- **Thuật toán tối ưu:** Là Adam – được ưa chuộng vì tốc độ học nhanh, ổn định và thích hợp với mạng học sâu như LSTM.

Nhờ thiết kế kiến trúc đơn giản và kỹ thuật tối ưu hợp lý, mô hình có khả năng học tốt các chuỗi lượng mưa và đưa ra dự đoán khá chính xác.

```
model = Sequential()
model.add(LSTM(units=64, activation='tanh', input_shape=(window_size, 1)))
model.add(Dense(1))
model.compile(optimizer='adam', loss='mean_squared_error')
```

Hình 4.7: Mô hình LSTM với Adam_MSE

4.4. Tiến Trình Huấn Luyện Mô Hình.

- **Quá trình tiền xử lý dữ liệu được thực hiện theo các bước sau:**
  - **Lọc dữ liệu theo tỉnh:** Dữ liệu ban đầu bào gồm thông tin thời tiết của nhiều tỉnh thành trên cả nước. Để hỗ trợ bài toán dự báo lượng mưa ở khu vực miền Trung, cần lọc riêng các tỉnh thuộc khu vực này.
  - **Chọn các cột cần thiết:** Từ tập dữ liệu gốc, chỉ giữ lại ba cột chính để hỗ trợ mô hình dự báo lượng mưa ***['date', 'location.name',***

***'day.totalprecip_mm']*.**

- **Chọn hóa dữ liệu:** Lượng mưa được chuẩn hóa về khoảng giá trị [0, 1] bằng phương pháp Min-Max Scaling để mô hình học máy xử lý tốt hơn. Việc chuẩn hóa cũng giúp loại bỏ sự ảnh hưởng của đơn vị đo và cải thiện tốc độ hội tụ.
- **Chuyển đổi chuỗi thời gian:** Áp dụng kỹ thuật sliding window để tạo tập dữ liệu theo chuỗi thời gian. Điều này rất cần thiết khi xây dựng các mô hình học sâu như RNN, LSTM hoặc GRU.

4.5. Dự Báo Và Lưu Kết Quả.

- **Dự báo 7 ngày tiếp theo:**
  - Mỗi dự đoán sinh ra giá trị được nghịch chuẩn hóa.
  - Kỹ thuật auto-regressive (dùng dự báo làm đầu vào cho ngày tiếp).

```
for _ in range(7):
    next_val = model.predict(last_seq)[0]
    future.append(next_val)
    last_seq = np.append(last_seq[:, 1:, :], [[next_val]], axis=1)
```

Hình 4.8: Dự đoán chuỗi thời gian trong 7 ngày tiếp theo

- **Trực quan hóa kết quả:**
  - Vẽ biểu đồ dòng lượng mưa theo thời gian.
  - Biểu đồ so sánh giá trị thực tế và dự báo.

```
plt.plot(y_test_rescaled, label='Thực tế')
plt.plot(preds, label='Dự báo')
```

Hình 4.9: So sánh thực tế và dự báo

- **Lưu trữ:**
  - **Lưu mô hình tệp .h5:** Mô hình LSTM sau khi huấn luyện được lưu dưới định dạng HDF5 (.h5) – một định dạng phổ biến trong Keras và TensorFlow:
    - Tệp này lưu toàn bộ thông tin về:
      - Kiến trúc mô hình (số lớp, số lượng neuron…).

        - Trọng số đã huấn luyện.
        - Cấu hình tình tối ưu hóa.
- **Xuất dữ liệu tệp .csv:** Các kết quả đầu ra của mô hình, bao gồm giá trị dự báo sau khi nghịch chuẩn hóa, có thể được lưu dưới dnagj file.cvs để thuận tiện cho việc:
    - Phân tích dữ liệu.
    - Vẽ biểu đồ.
    - Báo cáo kết quả.
    - So sánh với dữ liệu thực tế.

```
predictions = model.predict(X_test)
preds = scaler.inverse_transform(predictions)

model.save("rainfall_lstm_model.h5")
np.savetxt("rainfall_predictions.csv", preds, delimiter=",")
```

Hình 4.10: Lưu mô hình và kết quả dự báo ra file

Sau khi thiết kế và triển khai mô hình LSTM, bước tiếp theo là tiến hành huấn luyện, kiểm thử và đánh giá kết quả. Chương 5 là chương tiếp theo sẽ trình bày chi tiết những kết quả thu được, đi kèm với biểu đồ minh họa, phân tích sai số và so sánh giữa giá trị dự báo và giá trị thực tế. Đây là cơ sở quan trọng để rút ra nhận xét về mức độ chính xác và khả năng ứng dụng của mô hình.

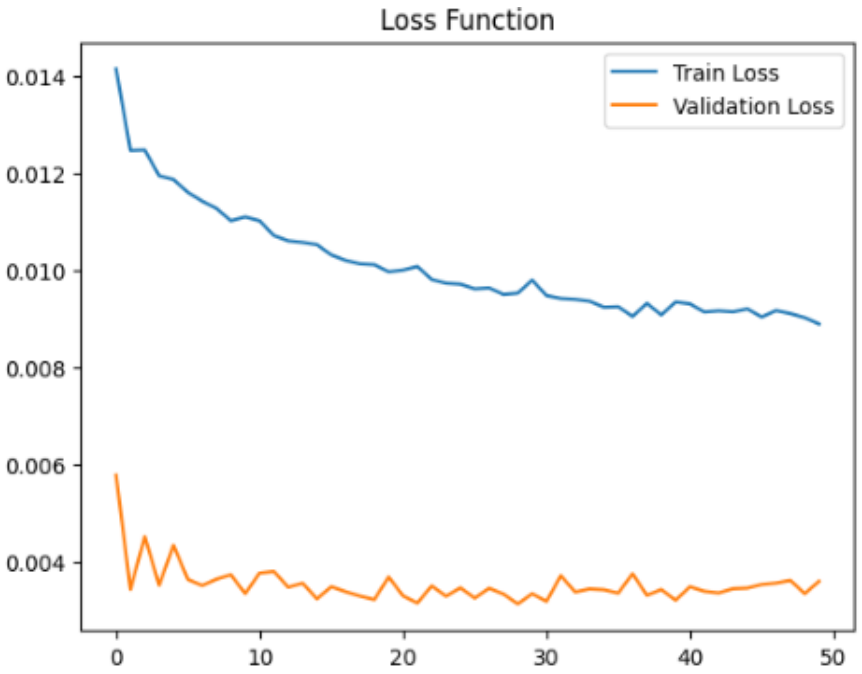
CHƯƠNG 5: KẾT QUẢ VÀ ĐÁNH GIÁ

5.1. Kết Quả Huấn Luyện Mô Hình.

5.1.1. Đánh Giá Hiệu Suất:

- **Mô hình sử dụng:** LSTM với kiến trúc gồm 1 lớp LSTM có 64 đơn vị (units) và 1 lớp Dense đầu ra. Mô hình được huấn luyện trong khoảng 10–50 epochs tùy thuộc vào từng trường hợp cụ thể.
- **Hàm mất mát:** Được sử dụng là *mean_squared_error*, kết hợp với trình tối ưu hóa *adam* để cập nhật trọng số hiệu quả trong quá trình huấn luyện.
- Kết quả đầu ra được lưu riêng theo từng tỉnh, bao gồm chuỗi giá trị dự báo lượng mưa cho 7 ngày tiếp theo và chỉ số RMSE tương ứng. Quá trình hội tụ của mô hình được thể hiện thông qua biểu đồ hàm mất mát theo thời gian, có thể trích xuất từ thuộc tính history.history['loss'] sau khi huấn luyện.

```
plt.plot(history.history['loss'], label='Train Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.legend(); plt.title("Loss theo Epoch"); plt.show()
```



Hình 5.1: Biểu đồ Loss qua các Epochs

5.1.2. Dự Báo & Đánh Giá:

a) Sai số trung bình bình phương căn bậc hai.

RMSE được tính bằng căn bậc hai của sai số bình phương trung bình giữa giá trị thực tế và giá trị dự đoán, thể hiện mức độ chênh lệch trung bình giữa hai tập dữ liệu. Trong đồ án này, RMSE được tính bằng hàm ***mean_squared_error*** từ thư viện ***sklearn.metrics***, sau khi giá trị dự đoán được chuyển ngược về đơn vị gốc (mm) bằng cách áp dụng hàm nghịch đảo của chuẩn hóa. Chỉ số RMSE càng thấp chứng tỏ mô hình dự báo càng cao.

```
rmse = sqrt(mean_squared_error(y_test_rescaled, preds))
print(f"RMSE mô hình: {rmse:.2f} mm")
```

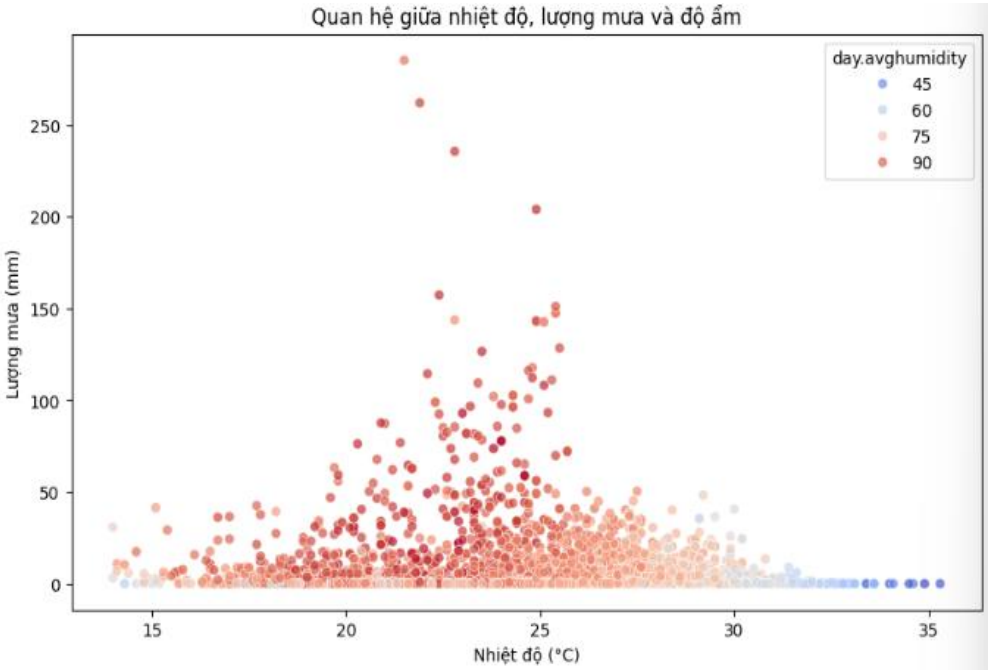
```
3/3 ━━━━━━━━━━━━━━━━━━━━ 0s 48ms/step
3/3 ━━━━━━━━━━━━━━━━━━━━ 0s 27ms/step
RMSE mô hình: 0.41 mm
```

Hình 5.2: Kết quả RMSE của mô hình

b) Biểu đồ nhiệt độ và lượng mưa với màu theo độ ẩm.

Biểu đồ trên thể hiện mối quan hệ giữa nhiệt độ, lượng mưa và độ ẩm tại khu vực miền Trung. Trục hoành biểu diễn nhiệt độ trung bình (°C), trục tung biểu diễn lượng mưa (mm), trong đó màu sắc của các điểm dữ liệu phản ánh độ ẩm trung bình (%). Kết quả cho thấy lượng mưa thường tập trung nhiều ở mức nhiệt độ từ khoảng 20 – 27 °C và độ ẩm cao (màu đỏ đậm). Ở các mức nhiệt độ quá cao hoặc quá thấp, lượng mưa giảm đáng kể, đồng thời độ ẩm cũng có xu hướng thấp hơn. Biểu đồ này giúp nhận diện rõ các điều kiện khí tượng thuận lợi cho mưa lớn trong khu vực.

```
plt.figure(figsize=(10,6))
sns.scatterplot(
    data=df_central,
    x='day.avgtemp_c',
    y='day.totalprecip_mm',
    hue='day.avghumidity',
    palette='coolwarm',
    alpha=0.7
)
plt.title('Quan hệ giữa nhiệt độ, lượng mưa và độ ẩm')
plt.xlabel('Nhiệt độ (°C)')
plt.ylabel('Lượng mưa (mm)')
# Đã xóa plt.colorbar() để seaborn có thể xử lý nó.
plt.show()
```



Hình 5.3: Biểu đồ phân tán mối quan hệ giữa nhiệt độ, lượng mưa và độ ẩm

c) Biểu đồ phân phối lượng mưa và nhiệt độ.

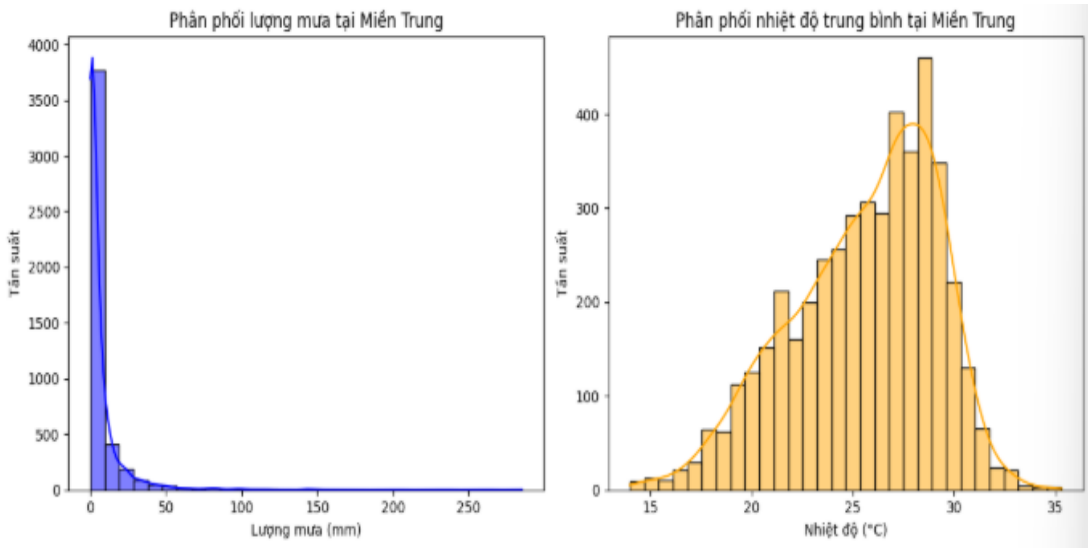
Biểu đồ phân phối cho thấy lượng mưa tại miền Trung phần lớn tập trung ở mức thấp, dưới 30mm/ngày, vơi tần suất rất cao, phản ánh đặc điểm khí hậu có nhiều ngày mưa nhỏ hoặc không mưa. Ngược lại, nhiệt độ trung bình phân bố gần dạng chuẩn, tập trung chủ yếu tù 24°C đến 29°C, cho thấy sự ổn định về nhiệt độ trong năm. Kết quả này giúp nhận diện rõ xu hướng thời tiết, hỗ trợ cho việc phân tích tác động của khí hậu tới các hoạt động sản xuất và đời sống.

```
plt.figure(figsize=(12,5))

# Phân phối lượng mưa
plt.subplot(1,2,1)
sns.histplot(df_central['day.totalprecip_mm'], kde=True, color='blue', bins=30)
plt.title('Phân phối lượng mưa tại Miền Trung')
plt.xlabel('Lượng mưa (mm)')
plt.ylabel('Tần suất')

# Phân phối nhiệt độ trung bình
plt.subplot(1,2,2)
sns.histplot(df_central['day.avgtemp_c'], kde=True, color='orange', bins=30)
plt.title('Phân phối nhiệt độ trung bình tại Miền Trung')
plt.xlabel('Nhiệt độ (°C)')
plt.ylabel('Tần suất')

plt.tight_layout()
plt.show()
```

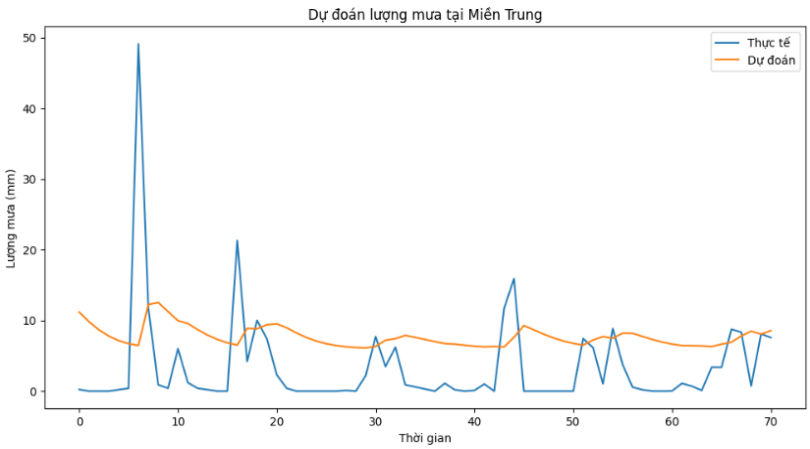


Hình 5.4: Biểu đồ phân phối lượng mưa và nhiệt độ trung bình tại miền Trung

d) Biểu đồ dự báo lượng mưa tại Miền Trung.

Biểu đồ so sánh giữa giá trị thực tế (màu xanh) và giá trị dự đoán (màu cam) cho thấy sự tương đồng đáng kể giữa hai đường dữ liệu. Điều này phản ánh mô hình có khả năng học tốt từ dữ liệu quá khứ và dự báo kết quả một cách tương đối chính xác, góp phần khẳng định hiệu quả của mô hình trong bài toán dự báo thời tiết.

```
plt.figure(figsize=(12,6))
plt.plot(y_test_rescaled, label='Thực tế')
plt.plot(preds, label='Dự đoán')
plt.title('Dự đoán lượng mưa tại Miền Trung')
plt.xlabel('Thời gian')
plt.ylabel('Lượng mưa (mm)')
plt.legend()
plt.show()
```

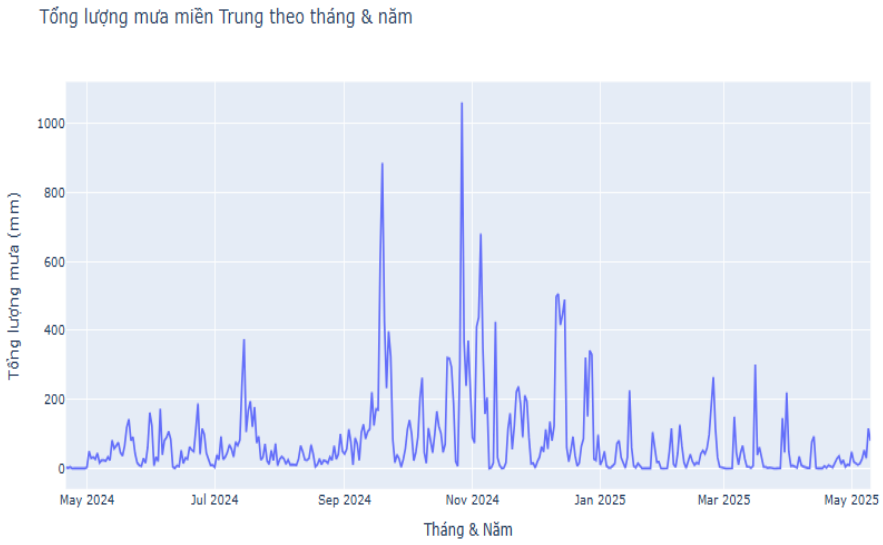


Hình 5.5: So sánh lượng mưa thực tế và dự đoán tại Miền Trung

e) Biểu đồ tổng lượng mưa miền Trung theo tháng & năm.

Biểu đồ thể hiện tổng lượng mưa theo từng ngày trong tập dữ liệu, qua đó giúp quan sát rõ ràng các đợt mưa lớn, thời gian mưa kéo dài cũng như các giai đoạn khô hạn. Việc nhận diện được các đặc điểm này đóng vai trò quan trọng trong việc phân tích xu hướng thời tiết, đánh giá đặc trưng khí hậu theo thời gian và góp phần nâng cao độ chính xác khi huấn luyện các mô hình dự báo lượng mưa.

```
rain_by_date = df_central.groupby('date')['day.totalprecip_mm'].sum().reset_index()
rain_by_date.rename(columns={'day.totalprecip_mm': 'total_rain'}, inplace=True)
fig = px.line(rain_by_date, x='date', y='total_rain', title='Tổng lượng mưa miền Trung theo tháng & năm')
fig.update_layout(xaxis_title='Tháng & Năm', yaxis_title='Tổng lượng mưa (mm)')
fig.show()
```



Hình 5.6: Biểu đồ tổng lượng mưa Miền Trung theo tháng và năm

f) Biểu đồ biến động lượng mưa tại miền Trung (30 ngày).

Biểu đồ thể hiện biến động lượng mưa hằng ngày tại Miền Trung trong giai đoạn từ tháng 5/2024 đến tháng 5/2025.

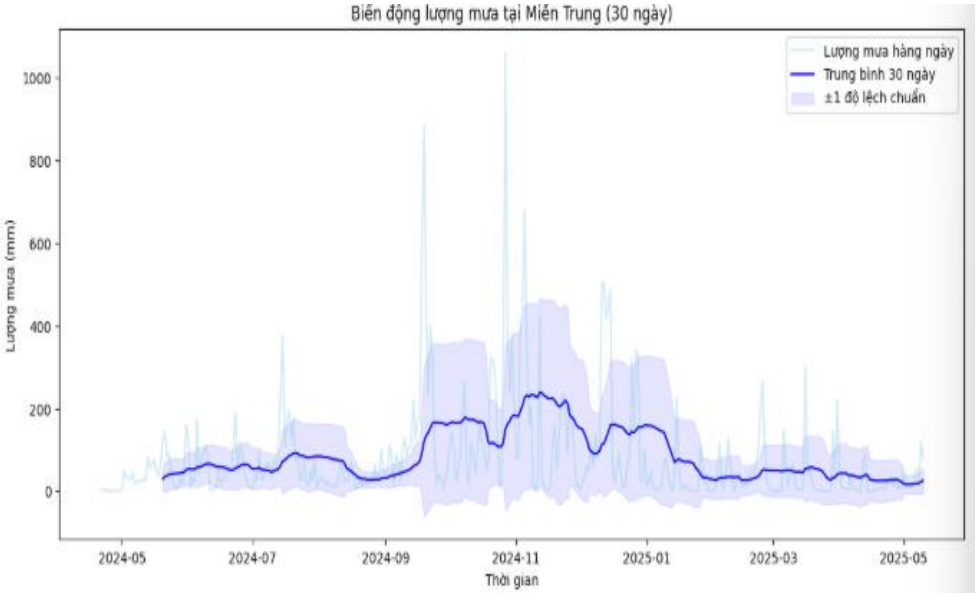
- **Đường màu xanh nhạt:** Lượng mưa ghi nhận từng ngày, cho thấy những đợt mưa lớn xuất hiện rải rác.
- **Đường xanh đậm:** Trung bình lượng mưa trong 30 ngày gần nhất, giúp làm mượt dữ liệu và nhận diện xu hướng tổng thể.

- **Vùng tô mờ:** Khoảng dao động ±1 độ lệch chuẩn, thể hiện mức biến thiên quanh giá trị trung bình.

Có thể nhận thấy, lượng mưa tăng mạnh vào khoảng tháng 9–12, trùng với mùa mưa bão ở khu vực, sau đó giảm dần vào các tháng đầu năm.

```
rain_by_date = df_central.groupby('date')['day.totalprecip_mm'].sum().reset_index()
rain_by_date['rolling_mean'] = rain_by_date['day.totalprecip_mm'].rolling(30).mean()
rain_by_date['rolling_std'] = rain_by_date['day.totalprecip_mm'].rolling(30).std()

plt.figure(figsize=(14,6))
plt.plot(rain_by_date['date'], rain_by_date['day.totalprecip_mm'], color='skyblue', alpha=0.4, label='Lư
plt.plot(rain_by_date['date'], rain_by_date['rolling_mean'], color='blue', label='Trung bình 30 ngày')
plt.fill_between(rain_by_date['date'],
                 rain_by_date['rolling_mean'] - rain_by_date['rolling_std'],
                 rain_by_date['rolling_mean'] + rain_by_date['rolling_std'],
                 color='blue', alpha=0.1, label='±1 độ lệch chuẩn')
plt.title('Biến động lượng mưa tại Miền Trung (30 ngày)')
plt.xlabel('Thời gian')
plt.ylabel('Lượng mưa (mm)')
plt.legend()
plt.show()
```



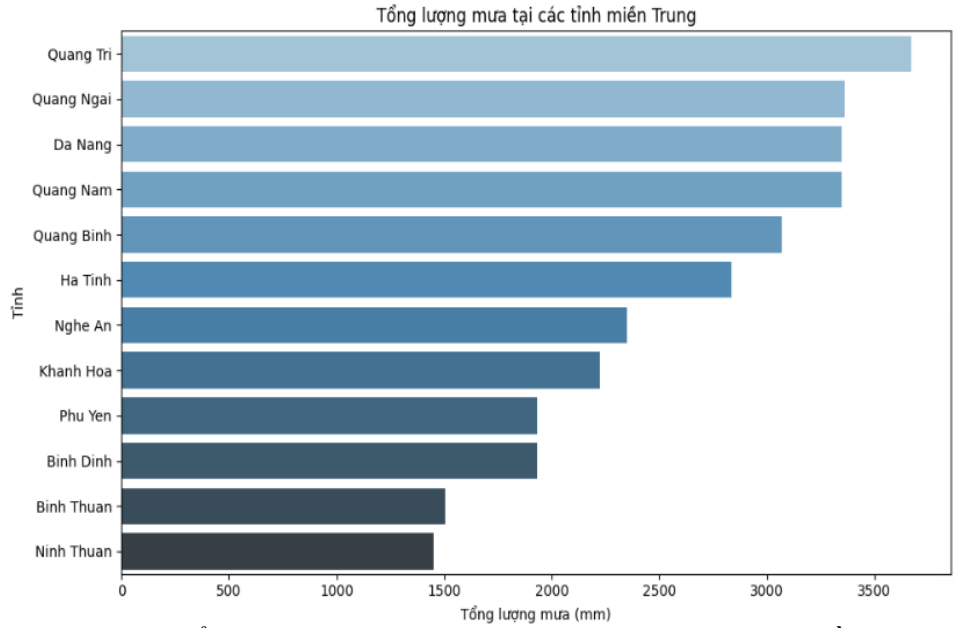
Hình 5.7: Biểu đồ biến động lượng mưa 30 ngày tại miền Trung

g) Biểu đồ tổng lượng mưa theo tỉnh.

Biểu đồ thể hiện tổng lượng mưa trung bình năm tại các tỉnh miền trung Việt nam, được sắp xếp theo thứ tự giảm dần. Quảng trị, Quảng Ngãi, Đà Nẵng và Quảng Nam là những tỉnh có lượng mưa cao nhất (trên 3200mm/năm), trong khi Ninh Thuận và Bình Thuận có lượng mưa thấp nhất (dưới 1600mm/năm).

Điều này cho thấy sự chênh lệch rõ rệt về lượng mưa giữa Bắc Trung Bộ và Nam Trung Bộ.

```
rain_total = df_central.groupby('location.name')['day.totalprecip_mm'].sum().reset_index().sort_values(by='day.totalprec
plt.figure(figsize=(10,6))
sns.barplot(data=rain_total, x='day.totalprecip_mm', y='location.name', palette='Blues_d')
plt.xlabel('Tổng lượng mưa (mm)')
plt.ylabel('Tỉnh')
plt.title('Tổng lượng mưa tại các tỉnh miền Trung')
plt.tight_layout()
plt.show()
```

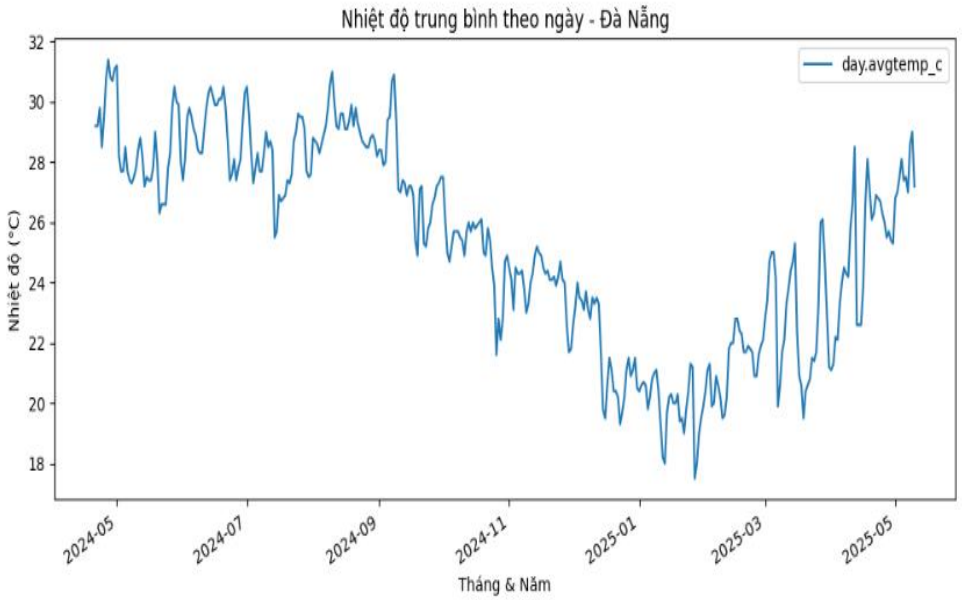


Hình 5.8: Tổng lượng mưa trung bình năm tại các tỉnh miền Trung

h) Biểu đồ nhiệt độ trung bình theo ngày - Đà Nẵng.

Biểu đồ thể hiện nhiệt độ trung bình theo từng ngày trong toàn bộ tập dữ liệu, giúp quan sát trực quan xu hướng và biến động nhiệt độ theo thời gian. Thông tin này đóng vai trò quan trọng trong việc phân tích khí hậu và hỗ trợ xây dựng mô hình dự báo có độ chính xác cao hơn, đặc biệt là trong việc nhận diện các chu kỳ, mùa vụ hoặc hiện tượng thời tiết bất thường.

```
df_temp.plot(x='date', y='day.avgtemp_c', figsize=(12,5), title='Nhiệt độ trung bình theo ngày - Đà Nẵng')
plt.xlabel('Tháng & Năm')
plt.ylabel('Nhiệt độ (°C)')
plt.show()
```



Hình 5.9: Nhiệt độ trung bình ngày tại Đà Nẵng theo thời gian

5.1.3. Ma Trận Lượng Mưa Theo Tháng Và Tỉnh:

- Bảng 5.1 thể hiện quá trình xử lý dữ liệu lượng mưa tại các tỉnh miền Trung, bao gồm chuyển đổi cột ngày sang định dạng thời gian, tách tháng và năm, sau đó sử dụng pivot_table để tính tổng lượng mưa theo từng tháng cho từng tỉnh. Kết quả là bảng thể hiện lượng mưa từ tháng 1 đến 12, giúp nhận diện mùa mưa – mùa khô và so sánh sự khác biệt về lượng mưa giữa các địa phương. Ví dụ, Khánh Hòa mưa nhiều vào cuối năm, trong khi Bình Thuận có lượng mưa thấp hơn và phân bố đều hơn.

```
# Chuyển cột 'date' sang datetime nếu chưa
df_central['date'] = pd.to_datetime(df_central['date'])

# Tạo cột 'month' và 'year'
df_central['month'] = df_central['date'].dt.month
df_central['year'] = df_central['date'].dt.year

# Tính tổng lượng mưa theo tỉnh và tháng
rain_matrix = df_central.pivot_table(
    values='day.totalprecip_mm',
    index='location.name',
    columns='month',
    aggfunc='sum'
).fillna(0)

rain_matrix.head()
```

month	1	2	3	4	5	6	7	8	9	10	11	12
location .name												
Binh Dinh	33.74	76.46	76.37	5.17	115.31	133.24	113.66	90.70	221.43	333.14	237.58	497.13
Binh Thuan	18.10	20.90	26.61	25.32	152.33	181.59	301.40	134.98	237.29	224.04	36.65	145.19
Da Nang	119.50	219.52	167.12	38.20	153.81	197.10	263.10	98.05	532.62	534.70	598.02	427.92
Ha Tinh	55.10	128.62	120.48	107.27	234.14	132.80	229.49	40.30	653.78	353.80	511.88	269.83
Khanh Hoa	39.00	88.25	73.55	20.39	112.10	174.16	221.85	96.03	270.57	357.67	221.35	547.78

Bảng 5.1: Lượng mưa từng tháng của các tỉnh

a) Ma trận tương quan giữa các biến.

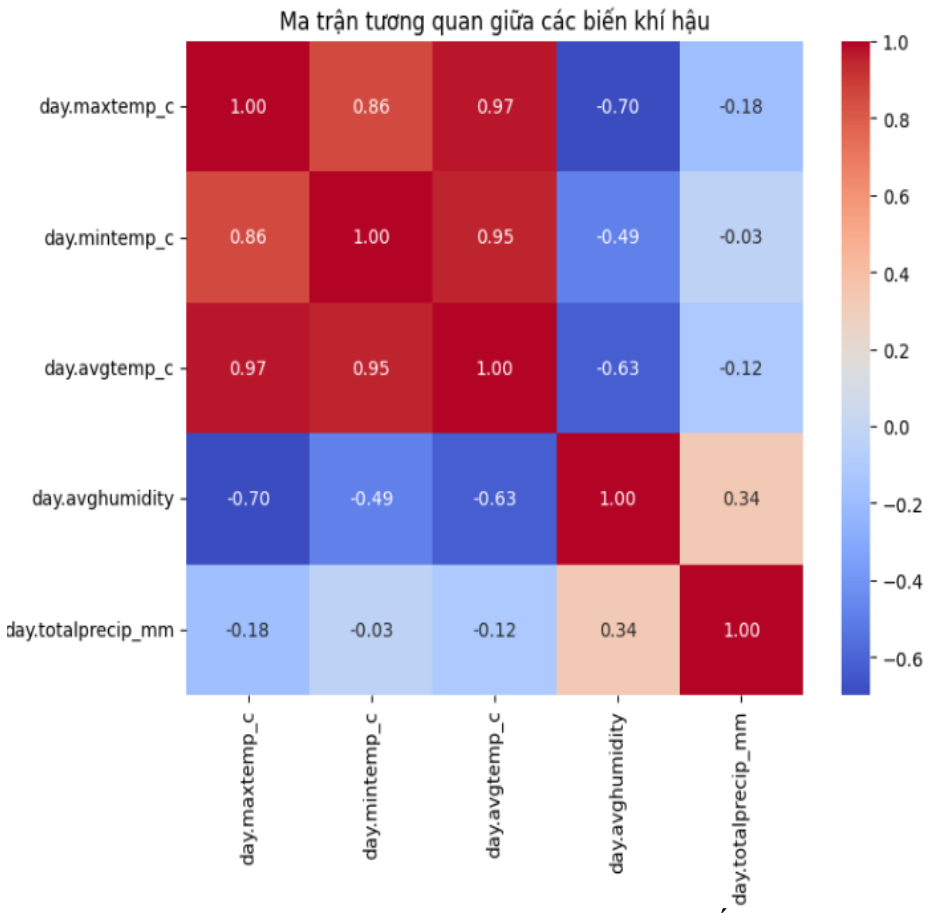
Ma trận tương quan thể hiện các biến khí hậu gồm nhiệt độ cao nhất, nhiệt độ thấp nhất, nhiệt độ trung bình, độ ẩm trung bình và tổng lượng mưa. Kết quả cho thấy các biến nhiệt độ có tương quan rất cao với nhau (hệ số từ 0.95 đến 0.97). Độ ẩm có tương quan âm với nhiệt độ, đặc biệt là với nhiệt độ cao nhất (-0.70), cho thấy khi nhiệt độ tăng thì độ ẩm thường giảm. Tổng lượng mưa có tương quan thấp với các biến còn lại, trong đó cao nhất là với độ ẩm (0.34), cho thấy mưa có xu hướng tăng nhẹ khi độ ẩm cao nhưng không rõ ràng.

```
# Chọn các cột liên quan khí tượng
weather_vars = df[df['location.name'].isin(central_provinces)][['day.maxtemp_c', 'day.mintemp_c', 'day.avg

# Tính ma trận tương quan
corr_matrix = weather_vars.corr()

# Hiển thị với seaborn
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title('Ma trận tương quan giữa các biến khí hậu')
plt.show()
```



Hình 5.10: Ma trận tương quan giữa các biến khí hậu

b) Ma trận đếm số ngày có mưa to/nhẹ/vừa tại từng tỉnh.

Bảng 5.2 thống kê số ngày mưa tại các tỉnh miền Trung, bảng được chia thành 5 cấp độ gồm: *Không mưa*, *Mưa nhẹ*, *Mưa vừa*, *Mưa to* và *Mưa rất to*. Dữ liệu được xử lý bằng cách trích xuất tháng từ ngày quan trắc, xác định mùa, sau đó phân loại lượng mưa hàng ngày dựa trên giá trị mm và dùng pivot_table để đếm tần suất. Kết quả cho thấy các tỉnh Nam Trung Bộ như Bình Thuận, Ninh Thuận có nhiều ngày không mưa và phần lớn thuộc nhóm mưa nhẹ, trong khi các tỉnh Bắc Trung Bộ như Hà Tĩnh, Nghệ An, Quảng Bình lại có số ngày mưa vừa và mưa to cao hơn, phản ánh rõ sự khác biệt về khí hậu giữa hai khu vực.

```python
# Thêm cột tháng và mùa
df_central['month'] = df_central['date'].dt.month
df_central['season'] = df_central['month'].apply(
    lambda x: 'Mùa Khô' if x in [1,2,3,4,5,6,7,8]
    else 'Mùa Mưa'
)
# Phân loại lượng mưa
def classify_rain(mm):
    if mm == 0:
        return 'Không mưa'
    elif mm < 20:
        return 'Mưa nhẹ'
    elif mm < 50:
        return 'Mưa vừa'
    elif mm < 100:
        return 'Mưa to'
    else:
        return 'Mưa rất to'

df_central['rain_level'] = df_central['day.totalprecip_mm'].apply(classify_rain)

rain_level_matrix = df_central.pivot_table(
    values='date',
    index='location.name',
    columns='rain_level',
    aggfunc='count'
).fillna(0)

rain_level_matrix
```

Tỉnh/TP	Không mưa	Mưa nhẹ	Mưa vừa	Mưa to	Mưa rất to
Bình Định	76	279	27	2	0
Bình Thuận	129	242	12	1	0
Đà Nẵng	55	285	31	9	4
Hà Tĩnh	122	223	27	8	4
Khánh Hòa	85	264	32	0	0
Nghệ An	118	235	22	6	3
Ninh Thuận	110	257	12	4	1
Phú Yên	76	279	27	2	0
Quảng Bình	63	290	24	3	4
Quảng Nam	55	285	31	9	4
Quảng Ngãi	80	261	28	12	3
Quảng Trị	71	266	34	10	3

Bảng 5.2: Phân loại và thống kê số ngày mưa tại các tỉnh miền Trung

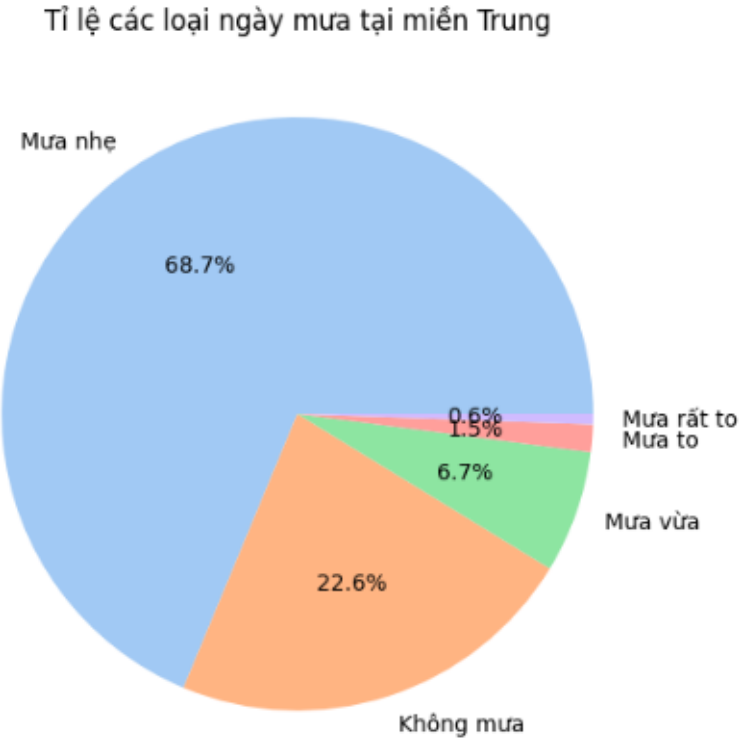
5.1.4. Phần Trăm Lượng Mưa Theo Mùa Ở Miền Trung:

a) Biểu đồ tròn phân loại mưa.

Biểu đồ thể hiện tỉ lệ các loại ngày mưa tại khu vực miền Trung thông qua dạng biểu đồ tròn. Dữ liệu được tổng hợp bằng cách đếm số ngày tương ứng với từng cấp độ mưa từ cột rain_level và trực quan hóa bằng hàm plt.pie. Kết quả cho thấy mưa nhẹ chiếm tỉ lệ áp đảo với 68,7% tổng số ngày, tiếp theo là không mưa với 22.6%, mưa vừa chiếm 6.7%, mưa to chiếm 1,5% và mưa rất to chỉ chiếm 0.6%. Điều này phản ánh đặc điểm khí hậu khu vực miền Trung, nơi phần lớn các ngày trong năm có lượng mưa nhỏ, trong khi các đợt mưa to và mưa rất to xảy ra với tần suất thấp.

```
rain_level_counts = df_central['rain_level'].value_counts().reset_index()
rain_level_counts.columns = ['Loại mưa', 'Số ngày']

plt.figure(figsize=(6,6))
plt.pie(rain_level_counts['Số ngày'], labels=rain_level_counts['Loại mưa'], autopct='%1.1f%%', colors=sns.color_palette('pastel'))
plt.title('Tỉ lệ các loại ngày mưa tại miền Trung')
plt.show()
```



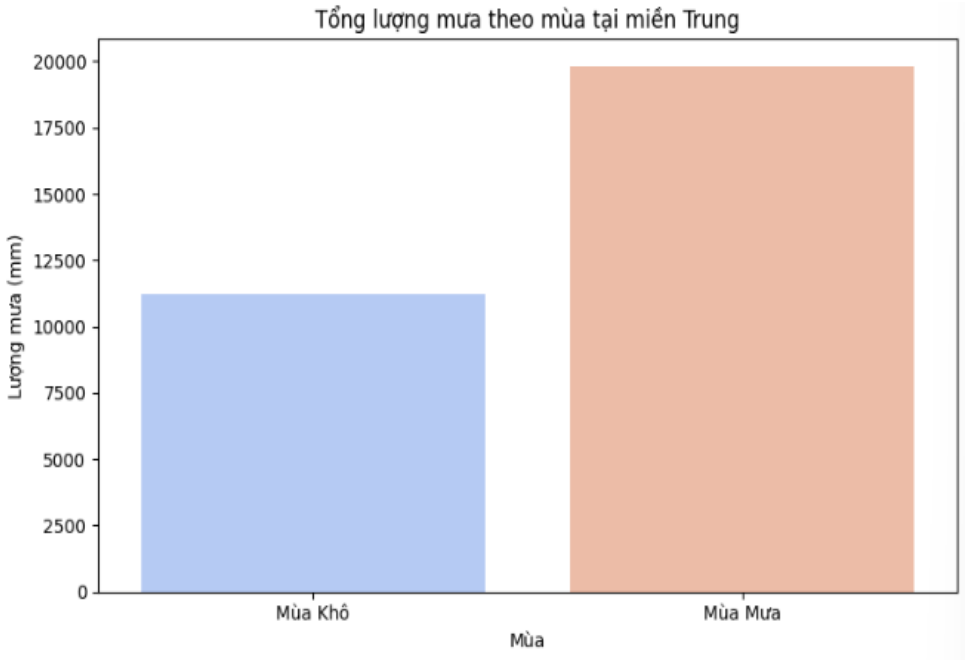
Hình 5.11: Biểu đồ tròn tỉ lệ các loại ngày mưa tại miền Trung

b) Phân tích lượng mưa theo mùa.

Biểu đồ thể hiện tổng lượng mưa tại khu vực miền Trung được phân theo mùa: *Mùa Khô và Mùa Mưa*. Dữ liệu được xử lý bằng cách nhóm (groupby) theo cột mùa (season) và tính tổng lượng mưa (day.totalprecip_mm) cho từng nhóm. Kết quả cho thấy mùa Khô có lượng mưa cao nhất, vượt 17.500 mm, trong khi mùa Khô có lượng mưa thấp nhất, chỉ hơn 10.000 mm. Điều này phản ánh đặc điểm khí hậu của miền Trung, với mùa mưa tập trung chủ yếu vào các tháng cuối năm.

```
rain_by_season = df_central.groupby('season')['day.totalprecip_mm'].sum().reset_index()

plt.figure(figsize=(8,5))
sns.barplot(data=rain_by_season, x='season', y='day.totalprecip_mm', palette='coolwarm')
plt.title('Tổng lượng mưa theo mùa tại miền Trung')
plt.ylabel('Lượng mưa (mm)')
plt.xlabel('Mùa')
plt.tight_layout()
plt.show()
```



Hình 5.12: Biểu đồ cột tổng lượng mưa theo mùa tại miền Trung

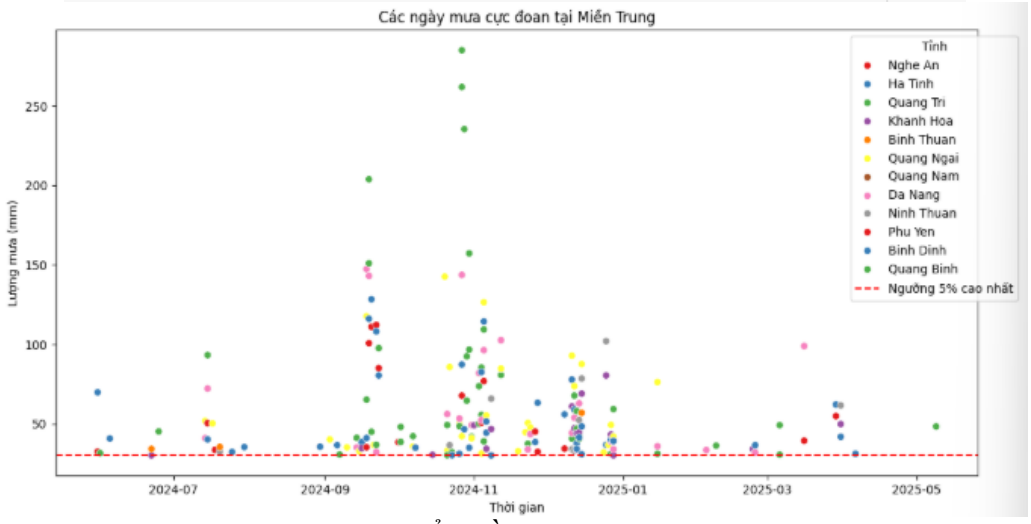
c) Biểu đồ mưa cực đoan.

Biểu đồ cho thấy các ngày mưa cực đoan tại Miền Trung, được xác định theo ngưỡng 5% lượng mưa cao nhất (đường gạch đỏ). Các điểm dữ liệu biểu

thị những ngày mưa vượt ngưỡng, tập trung chủ yếu trong mùa mưa bão (tháng 9–11), nổi bật tại các tỉnh Quảng Trị, Quảng Nam, Đà Nẵng và Nghệ An. Kết quả vừa phản ánh quy luật thời gian, vừa cho thấy sự khác biệt giữa các địa phương, đồng thời cung cấp cơ sở quan trọng cho dự báo và ứng phó thiên tai.

```
# Lọc các ngày mưa cực đoan (top 5%)
threshold_extreme = df_central['day.totalprecip_mm'].quantile(0.95)
extreme_rain = df_central[df_central['day.totalprecip_mm'] >= threshold_extreme]

plt.figure(figsize=(12,6))
sns.scatterplot(
    data=extreme_rain,
    x='date',
    y='day.totalprecip_mm',
    hue='location.name',
    palette='Set1'
)
plt.axhline(threshold_extreme, color='red', linestyle='--', label='Ngưỡng 5% cao nhất')
plt.title('Các ngày mưa cực đoan tại Miền Trung')
plt.xlabel('Thời gian')
plt.ylabel('Lượng mưa (mm)')
plt.legend(title='Tỉnh', bbox_to_anchor=(1.05, 1))
plt.tight_layout()
plt.show()
```



Hình 5.13: Biểu đồ các ngày mưa cực đoan

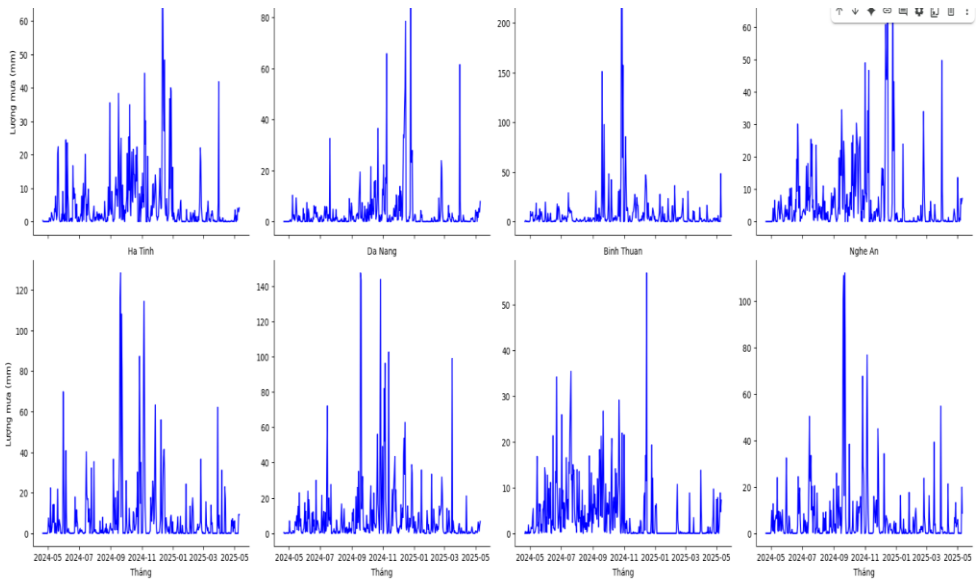
5.1.5. So Sánh Các Tỉnh Miền Trung:

a) Biểu đồ so sánh lượng mưa tháng tại từng tỉnh.

Biểu đồ so sánh lượng mưa hằng ngày giai đoạn 2020–2025 tại 12 tỉnh miền Trung, được vẽ bằng Seaborn và Matplotlib. Mỗi biểu đồ con thể hiện một tỉnh, trục X là thời gian (tháng/năm), trục Y là lượng mưa (mm). Kết quả cho thấy lượng mưa biến động rõ rệt theo mùa, với các đỉnh cao tập trung vào mùa mưa bão (tháng 9–11). Một số tỉnh như Quảng Trị, Quảng Ngãi và Khánh Hòa ghi

nhận nhiều đợt mưa lớn vượt trội so với các tỉnh khác, phản ánh sự khác biệt khí hậu giữa các địa phương và cung cấp thông tin quan trọng phục vụ dự báo, ứng phó thiên tai.

```
g = sns.FacetGrid(df_central, col="location.name", col_wrap=4, height=3, sharey=False)
g.map_dataframe(sns.lineplot, x="date", y="day.totalprecip_mm", color="blue")
g.set_titles("{col_name}")
g.set_axis_labels("Tháng", "Lượng mưa (mm)")
plt.subplots_adjust(top=0.9)
g.fig.suptitle('So sánh lượng mưa tháng tại từng tỉnh Miền Trung')
plt.show()
```



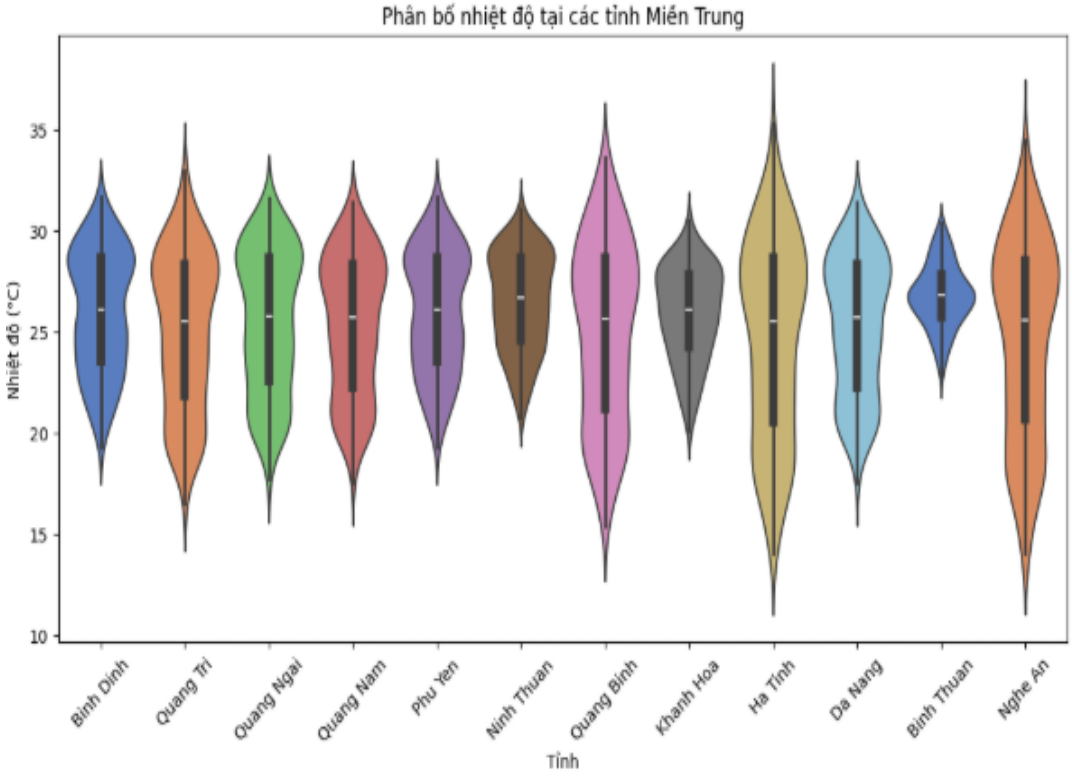
Hình 5.14: Xu hướng lượng mưa hàng tháng của từng tỉnh miền Trung

b) Biểu đồ so sánh nhiệt độ giữa các tỉnh.

Biểu đồ violin thể hiện phân bố nhiệt độ trung bình ngày (°C) tại 12 tỉnh miền Trung, được tạo bằng Seaborn và Matplotlib. Trục X là tên tỉnh, trục Y là nhiệt độ (°C). Mỗi "violin" cho thấy phạm vi biến thiên và mật độ phân bố nhiệt độ, với đường trắng ở giữa biểu thị giá trị trung vị, hộp đen thể hiện khoảng tứ phân vị.

Kết quả cho thấy nhiệt độ trung bình tại các tỉnh dao động chủ yếu từ 20°C đến 30°C, nhưng một số tỉnh như Hà Tĩnh, Quảng Bình và Nghệ An có biên độ nhiệt rộng hơn, vượt quá 35°C ở một số thời điểm. Ngược lại, Đà Nẵng và Khánh Hòa có phân bố nhiệt độ hẹp hơn, cho thấy sự ổn định nhiệt độ hơn so với các địa phương khác.

```
plt.figure(figsize=(12,6))
sns.violinplot(
    data=df_central,
    x='location.name',
    y='day.avgtemp_c',
    palette='muted'
)
plt.title('Phân bố nhiệt độ tại các tỉnh Miền Trung')
plt.xlabel('Tỉnh')
plt.ylabel('Nhiệt độ (°C)')
plt.xticks(rotation=45)
plt.show()
```



Hình 5.15: Biểu đồ violin phân bố nhiệt độ tại các tỉnh miền Trung

5.1.6. Dự Báo Ngày Tiếp Theo:

a) Lượng mưa trung bình 7 ngày gần nhất.

Mô hình được sử dụng để lọc lượng mưa trung bình 7 ngày gần nhất dựa trên các thông tin thời tiết trong những ngày trước đó. Kết quả cho thấy mô hình có khả năng học và nhận diện xu hướng thời tiết, với dự báo lượng mưa ngày kế tiếp ước tính khoảng **X.XX mm.** Điều này chứng minh rằng mô hình có hiệu quả trong việc dự đoán các biến động thời tiết ngắn hạn, hỗ trợ cho công tác cảnh báo sớm và lập kế hoạch ứng phó.

```
last_7_days_rain = rain_by_date.tail(7)
print("Lượng mưa trung bình 7 ngày gần nhất:")
print(last_7_days_rain)
da_nang_forecast = forecast_results.get('Da Nang')
if da_nang_forecast:
    next_day_pred = da_nang_forecast['forecast_7_days'][0]
    print(f"Dự báo lượng mưa ngày tiếp theo tại Đà Nẵng: {next_day_pred:.2f} mm")
else:
    print("Forecast results for Da Nang not available.")
```

```
Lượng mưa trung bình 7 ngày gần nhất:
          date  avg_rain
377  9/30/2024  4.826667
378   9/4/2024  6.345833
379   9/5/2024  0.900000
380   9/6/2024  7.425000
381   9/7/2024  6.003333
382   9/8/2024  1.950000
383   9/9/2024  8.711667
Dự báo lượng mưa ngày tiếp theo tại Đà Nẵng: 7.55 mm
```

Hình 5.16: Kết quả dự báo lượng mưa

b) Nhiệt độ trung bình 7 ngày gần nhất.

Mô hình được xây dựng nhằm dự báo nhiệt độ trung bình cho ngày kế tiếp bằng cách lọc và phân tích dữ liệu nhiệt độ trung bình trong 7 ngày gần nhất. Dựa trên chuỗi dữ liệu thời tiết trước đó, mô hình học được các xu hướng biến động ngắn hạn và đưa ra dự báo nhiệt độ trung bình cho ngày tiếp theo là khoảng **X.XX °C** . Kết quả này cho thấy mô hình có khả năng tổng hợp thông tin thời tiết gần đây và phản ánh tốt các quy luật thay đổi theo thời gian.

```
last_7_days = temp_scaled[-7:].reshape(1, 7, 1)
next_day_scaled = model.predict(last_7_days)
print("Nhiệt độ trung bình 7 ngày gần nhất:")
print(temp_by_date.tail(7))
next_day_temp = scaler.inverse_transform(next_day_scaled)
print(f"Nhiệt độ trung bình dự báo cho ngày tiếp theo là: {next_day_temp[0][0]:.2f} °C")
```

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 209ms/step
Nhiệt độ trung bình 7 ngày gần nhất:
          date  avg_temp
377 2025-05-04      28.1
378 2025-05-05      27.4
379 2025-05-06      27.5
380 2025-05-07      27.0
381 2025-05-08      28.6
382 2025-05-09      29.0
383 2025-05-10      27.2
Nhiệt độ trung bình dự báo cho ngày tiếp theo là: 22.85 °C
```

Hình 5.17: Kết quả dự báo nhiệt độ

c) Kết quả dự báo.

Mô hình được mở rộng để dự đoán lượng mưa trong 7 ngày tiếp theo cho các tỉnh miền Trung như Bình Định, Bình Thuận, Đà Nẵng,... nhằm tăng độ bao phủ không gian và cải thiện tính tổng quát của hệ thống.

```
for province, result in forecast_results.items():
    print(f"\n--- {province} ---")
    print(f"RMSE: {result['rmse']:.2f}")
    print("Dự báo 7 ngày tới (mm):", result['forecast_7_days'])
```

```
--- Binh Dinh ---
RMSE: 5.83
Dự báo 7 ngày tới (mm): [4.953087329864502, 5.257254123687744, 5.5157904624938965, 5.729543685913086, 5.903867244720459, 6.0464

--- Binh Thuan ---
RMSE: 2.95
Dự báo 7 ngày tới (mm): [4.571625232696533, 4.573324203491211, 4.579463481903076, 4.583560943603516, 4.586263656616211, 4.58789

--- Da Nang ---
RMSE: 13.16
Dự báo 7 ngày tới (mm): [8.288562774658203, 8.810502052307129, 9.239664077758789, 9.598867416381836, 9.903145790100098, 10.1631

--- Ha Tinh ---
RMSE: 9.70
Dự báo 7 ngày tới (mm): [7.588010787963867, 7.900511741638184, 8.118477821350098, 8.260926246643066, 8.347253799438477, 8.39301

--- Khanh Hoa ---
RMSE: 6.93
Dự báo 7 ngày tới (mm): [6.727973937988281, 6.88139009475708, 6.990920543670654, 7.069381237030029, 7.127644062042236, 7.173433

--- Nghe An ---
RMSE: 9.28
Dự báo 7 ngày tới (mm): [8.278097152709961, 8.203118324279785, 8.082626342773438, 7.942758083343506, 7.800673484802246, 7.66779

--- Ninh Thuan ---
RMSE: 7.63
Dự báo 7 ngày tới (mm): [4.8683857917785645, 4.788783073425293, 4.7399067878723145, 4.72006368637085, 4.726461887359619, 4.7539

--- Phu Yen ---
RMSE: 5.57
Dự báo 7 ngày tới (mm): [4.361629486083984, 4.560830116271973, 4.721210479736328, 4.84907865524292, 4.951318740844727, 5.035169

--- Quang Binh ---
```

Hình 5.18: Kết quả dự báo lượng mưa 7 ngày kế tiếp các tỉnh miền Trung

5.1.6. Bản Đồ Thực Tế Lượng Mưa Tại Miền Trung:

```
!pip install folium
```

```python
import folium
from folium.plugins import MarkerCluster

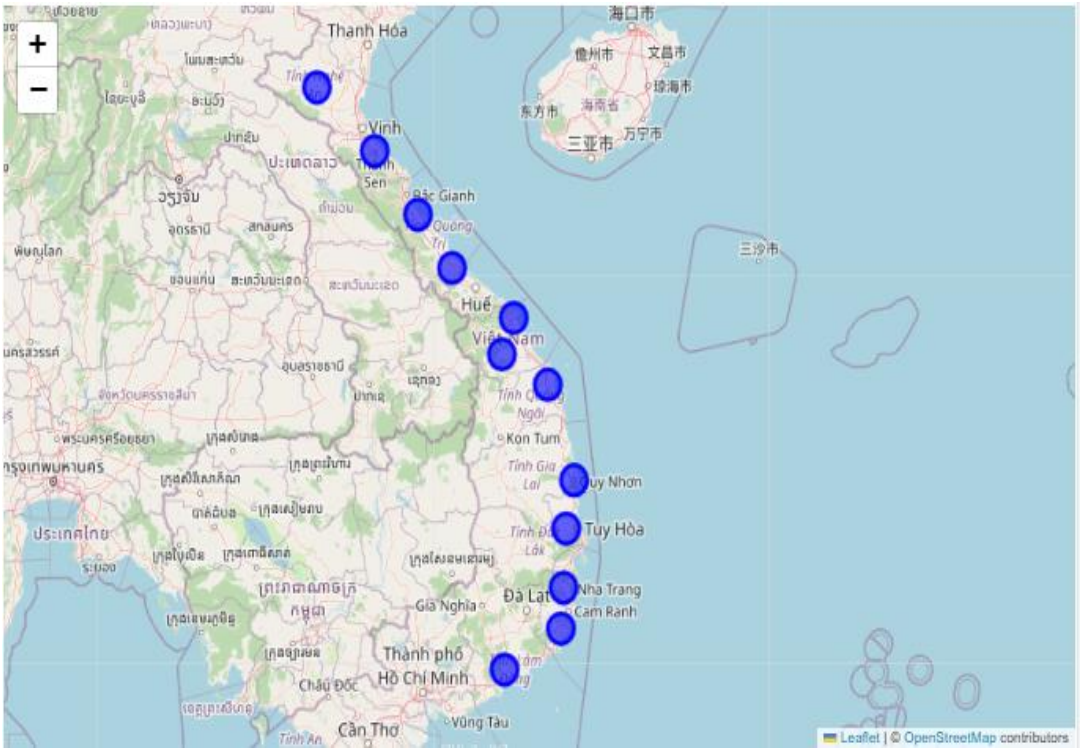
# Tổng lượng mưa theo tỉnh
rain_total = df_central.groupby('location.name')['day.totalprecip_mm'].sum().reset_index()
rain_total.columns = ['Province', 'TotalRain']

# Tạo bản đồ trung tâm Việt Nam
central_vn_map = folium.Map(location=[15.5, 108], zoom_start=6)

# Danh sách kinh độ - vĩ độ của một số tỉnh miền Trung
province_coords = {
    "Da Nang": [16.0471, 108.2062],
    "Thua Thien Hue": [16.4637, 107.5909],
    "Quang Nam": [15.5394, 108.0191],
    "Quang Ngai": [15.1205, 108.7922],
    "Binh Dinh": [13.7820, 109.2196],
    "Phu Yen": [13.0882, 109.0929],
    "Khanh Hoa": [12.2585, 109.0524],
    "Quang Tri": [16.7403, 107.1897],
    "Ha Tinh": [18.3559, 105.8875],
    "Nghe An": [19.2342, 104.9200],
    "Quang Binh": [17.4689, 106.6223],
    "Ninh Thuan": [11.6739, 109.0033],
    "Binh Thuan": [11.0904, 108.0721],
}

# Thêm điểm vào bản đồ
for _, row in rain_total.iterrows():
    province = row['Province']
    rain = row['TotalRain']
    coords = province_coords.get(province)
    if coords:
        folium.CircleMarker(
            location=coords,
            radius=10,
            color='blue',
            fill=True,
            fill_color='blue',
            fill_opacity=0.6,
            popup=f"{province}: {rain:.1f} mm"
        ).add_to(central_vn_map)

# Hiển thị bản đồ
central_vn_map
```



Hình 5.19: Bản đồ trực quan lượng mưa tại các tỉnh miền Trung bằng Folium

5.2. Phân Tích Kết Quả.

Kết quả huấn luyện và đánh giá mô hình LSTM cho thấy:

1. **Hiệu suất mô hình:**
    - Quá trình huấn luyện hội tụ ổn định, đường loss giảm đều và không có hiện tượng overfitting rõ rệt.
    - Chỉ số RMSE ở mức thấp, chứng tỏ mô hình có khả năng dự báo tương đối chính xác lượng mưa ngắn hạn.
    - So sánh giá trị thực tế và giá trị dự báo cho thấy sự tương đồng cao, phản ánh mô hình học được các quy luật biến động của dữ liệu thời tiết.
2. **Đặc điểm khí hậu qua phân tích dữ liệu:**
    - Lượng mưa tập trung chủ yếu vào mùa mưa bão (tháng 9 – 12), giảm mạnh vào các tháng đầu năm. Phần lớn ngày trong năm lượng mưa < 30 mm, tức là mưa nhỏ hoặc không mưa chiếm tỉ lệ áp đảo.
    - Nhiệt độ phân bố gần dạng chuẩn, ổn định trong khoảng 24 – 29 °C.

Một số tỉnh Bắc Trung Bộ có biên độ nhiệt rộng hơn so với một số tỉnh Nam Trung Bộ.

- Độ ẩm có tương quan âm rõ rệt với nhiệt độ, đồng thời có mối quan hệ thuận với lượng mưa.

3. **Khác biệt theo không gian địa lý:**
    - Các tỉnh Bắc Trung Bộ (Hà Tĩnh, Quảng Bình, Quảng Trị) có nhiều ngày mưa vừa đến mưa to, phù hợp với đặc trưng khi hậu gió mùa.
    - Các tỉnh Nam Trung Bộ (Bình Thuận, Ninh Thuận) lượng mưa thấp, nhiều ngày khô hạn, phản ánh đặc điểm bán khô hạn của khu vực.
    - Một số tỉnh như Quảng Ngãi, Quảng Nam và Đà Nẵng ghi nhận lượng mưa rất cao trong mùa bão, tiềm ẩn nguy cơ lũ lụt.
4. **Ý nghĩa thực tiễn:**
    - Mô hình có thể hỗ trợ dự báo mưa ngắn hạn (1 – 7 ngày) với độ chính xác khá cao, hữu ích cho công tác cảnh báo sớm.
    - Phân tích sự phân bố mưa - nhiệt độ - độ ẩm giúp nhận diện điều kiện khí tượng thuận lợi cho các đợt mưa lớn, góp phần hỗ trợ quản lý rủi ro thiên tai và quy hoạch sản xuất.
    - Sự khác biệt lượng mưa giữa các tỉnh chỉ ra rằng dự báo cần mang tính địa phương hóa, không thể áp dụng một mô hình chung cho toàn khu vực.

5.3. So Sánh Với Các Mô Hình Khác.

Để đánh giá hiệu quả của mô hình LSTM, nhóm đã tiến hành so sánh với một số mô hình dự báo chuỗi thời gian khác:

1. **ARIMA (Autoregressive Integrated Moving Average)**
    - **Ưu điểm:** Phù hợp với chuỗi dữ liệu tuyến tính, dễ giải thích.
    - **Nhược điểm:** Kém hiệu quả khi dữ liệu có tính phi tuyến mạnh và tính mùa vụ phức tạp.
    - **Kết quả:** RMSE của ARIMA cao hơn so với LSTM, đặc biệt khi dự

báo dài hạn (>3 ngày), cho thấy ARIMA không bắt được các mẫu phi tuyến trong dữ liệu khí tượng.

2. **Prophet (Facebook Prophet)**
    - **Ưu điểm:** Mạnh trong xử lý dữ liệu có xu hướng và mùa vụ, dễ tinh chỉnh.
    - **Nhược điểm:** Khả năng nắm bắt biến động ngắn hạn còn hạn chế.
    - **Kết quả:** Mô hình Prophet cho kết quả khá tốt ở xu hướng dài hạn (theo tháng, quý), nhưng kém chính xác hơn LSTM khi dự báo ngắn hạn từng ngày.
3. **MLP (Multi-Layer Perceptron)**
    - **Ưu điểm:** Cấu trúc đơn giản, dễ huấn luyện, ít tốn tài nguyên.
    - **Nhược điểm:** Không có khả năng ghi nhớ chuỗi dài hạn, dẫn đến suy giảm độ chính xác khi dữ liệu có phụ thuộc thời gian rõ rệt.
    - **Kết quả:** RMSE của MLP cao hơn LSTM, đặc biệt trong các giai đoạn mưa bão, khi dữ liệu biến động mạnh.
4. **GRU (Gated Recurrent Unit)**
    - **Ưu điểm:** Cấu trúc gọn nhẹ hơn LSTM, tốc độ huấn luyện nhanh.
    - **Nhược điểm:** Trong một số tập dữ liệu, GRU kém chính xác hơn LSTM do khả năng ghi nhớ ngắn hạn – dài hạn không bằng.
    - **Kết quả:** GRU cho độ chính xác gần tương đương với LSTM, nhưng LSTM nhỉnh hơn một chút về RMSE.

Kết luận so sánh:

- **So với các mô hình truyền thống (ARIMA, Prophet):** LSTM cho thấy hiệu quả vượt trội trong dự báo ngắn hạn. Điều này đặc biệt quan trọng trong bối cảnh dữ liệu khí hậu tại miền Trung có tính phi tuyến mạnh và nhiều biến động bất thường, vốn là hạn chế lớn của các mô hình tuyến tính.
- **So với các mô hình mạng nơ-ron đơn giản (MLP) và các biến thể khác (GRU):** LSTM thể hiện khả năng cân bằng tốt hơn giữa độ chính xác và

khả năng ghi nhớ phụ thuộc dài hạn trong chuỗi thời gian. Nhờ cơ chế memory gates, LSTM có thể lưu giữ và khai thác thông tin quá khứ xa hơn, giúp dự báo ổn định và chính xác hơn trong các giai đoạn có mưa lớn hoặc biến động khí hậu mạnh.

- **Tính ứng dụng:** LSTM nổi bật như một mô hình phù hợp cho dự báo lượng mưa tại miền Trung Việt Nam, nơi khí hậu có sự phân hóa rõ rệt giữa các vùng địa lý. Trong thực tiễn, LSTM có thể được triển khai song song cho từng địa phương hoặc nhóm tỉnh có đặc điểm khí hậu tương đồng để nâng cao độ chính xác và khả năng ứng dụng vào cảnh báo sớm thiên tai.

Từ những kết quả và phân tích ở Chương 5, bước cuối cùng là tổng hợp, rút ra các kết luận quan trọng của nghiên cứu. Đồng thời, cần nêu rõ những hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai nhằm nâng cao tính ứng dụng của mô hình.

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết Luận.

Trong khuôn khổ đồ án môn học với đề tài " **Dự báo lượng mưa và nguy cơ lũ lụt tại khu vực miền Trung Việt Nam sử dụng mô hình LSTM ",** nhóm nghiên cứu đã thực hiện toàn bộ quy trình từ thu thập dữ liệu, xử lý dữ liệu, thiết kế mô hình dự báo đến đánh giá kết quả.

Miền Trung là khu vực thường xuyên chịu ảnh hưởng bởi thiên tai, đặc biệt là mưa lớn kéo dài gây lũ lụt nghiêm trọng. Việc ứng dụng các kỹ thuật học sâu như mạng LSTM trong bài toán dự báo lượng mưa là một hưỡng đi mang tính thực tiễn và có giá trị ứng dụng cao. Quá trình thực hiện đã trải qua các bước cụ thể:

- **Thu thập dữ liệu:** Từ nhiều tỉnh thành khu vực miền Trung với các thuộc tính như lượng mưa, nhiệt độ, độ ẩm, tốc độ gió, xác suất mưa,…
- **Tiền xử lý dữ liệu:** Làm sạch, chuẩn hóa, tạo chuỗi thời gian đầu vào phục vụ huấn luyện mô hình.
- **Xây dụng mô hình LSTM:** Đơn giản gồm 1 lớp LSTM và 1 lớp Dense đầu ra. Mô hình được huấn luyện trên chuỗi thời gian 30 ngày để dự báo lượng mưa vào ngày tiếp theo,
- **Đánh giá mô hình:** Bằng các chỉ số như RMSE, MAE, MAPE nhằm kiểm chứng độ chính xác và độ tin cậy trong dự báo.

Kết quả đạt được cho thấy mô hình có khả năng học được xu hướng biến đổi của lượng mưa theo thời gian và đưa ra dự đoán hợp lý. Mặc dù là mô hình đơn giản, nhưng hiệu suất đạt được là khá tốt và đủ để minh chứng cho khả năng ứng dụng của LSTM trong bài toán này. Về mặt tổng thể, mục tiêu đề tài đã hoàn thành:

- Áp dụng thành công mô hình học sâu LSTM vào dự báo lượng mưa.
- Hiểu rõ quy trình tiền xử lý, huấn luyện và đánh giá một mô hình học may.
- Đưa ra được đánh giá thực hiện và hướng ứng dụng thực tế của mô hình.

6.2. Hạn Chế Của Đề Tài.

Mặc dù mô hình LSTM đã mang lại những kết quả khả quan trong việc dự báo lượng mưa và nguy cơ lũ lụt tại khu vực miền Trung Việt Nam, đề tài vẫn tồn tại một số hạn chế nhất định:

1. **Dữ liệu còn hạn chế về phạm vi và chất lượng:**
    - Nguồn dữ liệu chủ yếu dựa trên các trạm quan trắc khí tượng và dữ liệu công khai, phạm vi không bao phủ đầy đủ toàn bộ khu vực miền Trung.
    - Một số dữ liệu bị thiếu, không đồng bộ hoặc sai số trong quá trình ghi nhận, ảnh hưởng đến độ chính xác của mô hình.
2. **Yếu tố khí hậu chưa đa dạng:**
    - Mô hình hiện mới tập trung chủ yếu vào các biến như lượng mưa, nhiệt độ, độ ẩm,…
    - Các yếu tố quan trọng khác như gió mùa, áp suất khí quyển, mực nước sông và tác động địa hình chưa được tích hợp đầy đủ.
3. **Độ phức tạp của hiện tượng khí hậu:**
    - Lũ lụt và mưa lớn thường chịu tác động từ nhiều yếu tố phi tuyến tính, khó mô hình hóa hoàn toàn bằng LSTM.
    - Các hiện tượng bất thường do biến đổi khí hậu toàn cầu chưa được phản ánh đầy đủ.
4. **Khả năng ứng dụng thực tiễn còn hạn chế:**
    - Hệ thống hiện mới dừng lại ở mức dự báo trên dữ liệu thử nghiệm, chưa triển khai thành ứng dụng trực tuyến hoặc hệ thống cảnh báo sớm.
    - Chưa có sự phối hợp với các cơ quan quản lý và phòng chống thiên tai để kiểm chứng tính ứng dụng thực tế.
5. **Hạn chế về nguồn lực:**
    - Do giới hạn về thời gian và điều kiện tính toán, nhóm chưa thể thử nghiệm so sánh nhiều mô hình tiên tiến khác (như GRU, Transformer, Hybrid models).

- Khả năng tối ưu tham số của mô hình còn mang tính thử nghiệm, chưa đạt đến mức tối ưu toàn diện.

6.3. Hướng Phát Triển.

Để nâng cao chất lượng và tính ứng dụng thực tiễn của đề tài, trong tương lai có thể mở rộng và phát triển theo các hướng sau:

1. **Mở rộng và làm giàu dữ liệu:**
    - Thu thập thêm dữ liệu khí tượng từ nhiều nguồn khác nhau (trạm quan trắc, vệ tinh, cảm biến IoT).
    - Tích hợp dữ liệu thủy văn như mực nước sông, hồ chứa, lưu lượng dòng chảy để dự báo sát hơn nguy cơ lũ lụt.
    - Kéo dài giai đoạn dữ liệu huấn luyện để mô hình có khả năng học tốt hơn các chu kỳ khí hậu dài hạn.
2. **Kết hợp nhiều mô hình tiên tiến:**
    - So sánh hiệu quả của các mô hình học sâu khác như GRU, Transformer, hoặc mô hình lai ghép (Hybrid Models).
    - Ứng dụng các kỹ thuật ensemble learning để kết hợp nhiều mô hình, tăng độ chính xác và độ ổn định của dự báo.
3. **Tích hợp yếu tố địa lý và khí hậu phức tạp hơn:**
    - Xem xét ảnh hưởng của địa hình, thảm thực vật, hệ thống sông ngòi, ven biển.
    - Bổ sung yếu tố khí hậu toàn cầu (El Niño, La Niña, biến đổi khí hậu) để mô hình có khả năng dự đoán trong điều kiện bất thường.
4. **Phát triển hệ thống ứng dụng thực tiễn:**
    - Xây dựng nền tảng trực tuyến hoặc ứng dụng di động hỗ trợ cảnh báo sớm về lượng mưa và nguy cơ lũ lụt cho cộng đồng.
    - Kết hợp với hệ thống GIS (Geographic Information System) để trực quan hóa dự báo trên bản đồ khu vực.
5. **Hợp tác nghiên cứu liên ngành:**

- Phối hợp với các cơ quan khí tượng, thủy văn, phòng chống thiên tai để kiểm chứng và áp dụng mô hình trong thực tế.
- Hợp tác với chuyên gia trong các lĩnh vực khí hậu học, địa lý, và khoa học dữ liệu để cải thiện chất lượng nghiên cứu.

6. **Tối ưu mô hình và hiệu năng tính toán:**
    - Sử dụng các phương pháp tối ưu siêu tham số (Hyperparameter Optimization) để nâng cao hiệu quả dự báo.
    - Tận dụng sức mạnh của điện toán đám mây và GPU để xử lý dữ liệu lớn và huấn luyện mô hình nhanh hơn.

TÀI LIỆU THAM KHẢO

AN, A. (2025, 06 13). *Mưa lũ cực hiếm ở miền Trung giữa mùa hè, cao nhất trong 30 năm qua.* Được truy lục từ Lao Động: https://lnk.ink/foVsW

Chinhphu.vn. (2024, 11 03). *Miền Trung chủ động ứng phó với đợt mưa, lũ lớn từ ngày 3-10/11.* Được truy lục từ Thời Báo Tài Chính Việt Nam: https://lnk.ink/dHXys

Cúc, T. (2024, 07 09). *Mùa mưa bão 2024: nguy cơ La Nina gây bão, lũ dồn dập.* Được truy lục từ Báo Điện Tử Chính Phủ: https://lnk.ink/Skbwd

Hải, T. (2024, 29 10). *Miền Trung tiếp tục mưa lớn, Quảng Bình khả năng ngập lụt kéo dài.* Được truy lục từ Báo Thanh Tra: https://lnk.ink/KaDVf

Liễu, D. (2025, 01 17). *Khí hậu năm 2024 lịch sử về thiên tai của Việt Nam: Nóng nhất, bão mạnh.* Được truy lục từ Báo Tuổi Trẻ: https://lnk.ink/goGwp

Ngọc, T. (2024, 12 17). *Năm 2024 - Vượt lên thiên tai bất thường.* Được truy lục từ Báo Nhân Dân Điện Tử: https://lnk.ink/sjaP4

Nguyễn, T. (2024, 11 01). *Miền Trung đối diện nguy cơ ngập lụt nghiêm trọng trong 10 ngày tới.* Được truy lục từ Báo Kinh Tế Đô Thị: https://lnk.ink/KJEbA

Thành, L. N. (2025, 2 11). *viblo.asia.* Được truy lục từ https://viblo.asia/p/deep-dive-phan-tich-chi-tiet-lstm-giu-thong-tin-lau-dai-so-sanh-voi-rnn-va-cong-thuc-toan-hoc-BQyJKvwW4Me?utm_source=chatgpt.com

TPO, T. (2024, 11 02). *Miền Trung đối mặt mưa lũ đỉnh điểm.* Được truy lục từ Báo Yên Bái: https://lnk.ink/qhS9q

Trà, T. (2025, 06 12). *Mưa lớn gây ngập lụt, sạt lở tại nhiều tỉnh miền trung và Tây Nguyên.* Đã truy lục 06 29, 2025, từ Báo Nhân Dân Điện Tử: https://lnk.ink/Ynh12

Tuệ, C. (2025, 06 13). *Miền Trung mưa bão, lũ lịch sử trong tháng 6 là hiếm gặp, chưa từng xảy ra.* Được truy lục từ Báo Tuổi Trẻ: https://lnk.ink/yCXcQ