TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

TIỂU LUẬN

CÔNG NGHỆ KHOA HỌC DỮ LIỆU

DỰ ĐOÁN NGUY CƠ ĐỘT QUỴ SỬ DỤNG MÔ HÌNH HỌC MÁY DỰA TRÊN DỮ LIỆU Y TẾ

Giảng viên hướng dẫn:	**ThS. Sử Nhật Hạ**
Sinh viên thực hiện:	**Lê Chí Kha**
MSSV:	**2200002544**
Khoá:	**2022 - 2026**
Ngành:	**CÔNG NGHỆ THÔNG TIN**
Chuyên ngành:	**KHOA HỌC DỮ LIỆU**

TPHCM, tháng 8 năm 2025

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

TIỂU LUẬN

CÔNG NGHỆ KHOA HỌC DỮ LIỆU

DỰ ĐOÁN NGUY CƠ ĐỘT QUỴ SỬ DỤNG MÔ HÌNH HỌC MÁY DỰA TRÊN DỮ LIỆU Y TẾ

Giảng viên hướng dẫn:	**ThS. Sử Nhật Hạ**
Sinh viên thực hiện:	**Lê Chí Kha**
MSSV:	**2200002544**
Khoá:	**2022 - 2026**
Ngành:	**CÔNG NGHỆ THÔNG TIN**
Chuyên ngành:	**KHOA HỌC DỮ LIỆU**

TPHCM, tháng 8 năm 2025

LỜI MỞ ĐẦU

Trong bối cảnh hiện nay, đột quỵ đang trở thành một trong những nguyên nhân hàng đầu gây tử vong và để lại nhiều di chứng nặng nề cho sức khỏe con người. Việc phát hiện sớm nguy cơ đột quỵ và đưa ra các biện pháp phòng ngừa kịp thời là vấn đề mang ý nghĩa quan trọng trong y tế và chăm sóc sức khỏe cộng đồng.

Cùng với sự phát triển mạnh mẽ của khoa học dữ liệu và trí tuệ nhân tạo, các mô hình học máy ngày càng được ứng dụng rộng rãi trong y học nhằm hỗ trợ chẩn đoán và dự đoán bệnh lý. Trên cơ sở đó, nhóm chúng em thực hiện đề tài *"Dự đoán nguy cơ đột quỵ sử dụng mô hình học máy dựa trên dữ liệu y tế"* với mục tiêu nghiên cứu, xây dựng và đánh giá các mô hình dự đoán nguy cơ đột quỵ dựa trên dữ liệu bệnh nhân.

Thông qua việc xử lý, phân tích dữ liệu và áp dụng các thuật toán học máy, đề tài mong muốn mang lại cái nhìn tổng quan về khả năng ứng dụng công nghệ khoa học dữ liệu trong y tế, góp phần vào công tác hỗ trợ dự đoán, chẩn đoán sớm cũng như định hướng giải pháp chăm sóc sức khỏe cho cộng đồng.

LỜI CẢM ƠN

Em chân thành cám ơn Thầy hướng dẫn ThS. Sử Nhật Hạ, người đã hướng dẫn tận tình, đóng góp các ý kiến chuyên môn đồ án. Thầy/Cô đã động viên tinh thần tôi cố gắng hoàn thành những nghiên cứu đặt ra. Thầy/Cô cũng cung cấp một số tài liệu liên quan đến đồ án mà em đang nghiên cứu và ân cần nhắc nhở tôi đến tiến độ thực hiện đồ án này.

Em cũng chân thành gửi lời cảm ơn đến các Thầy/Cô khoa Công nghệ thông tin trường Đại học Nguyễn Tất Thành đã giảng dạy, hướng dẫn, trang bị các kiến thức cho em trong những năm học vừa qua, từ các kiến thức cơ bản đến các vấn đề chuyên sâu.

Em xin gửi lời cảm ơn đến anh, chị, bạn bè, đồng nghiệp bằng nhiều hình thức khác nhau đã giúp đỡ em trong quá trình học tập tại trường cũng như trong thời gian hoàn thành đồ án.

Đặc biệt xin gửi lời cám ơn đến cha mẹ và anh chị em trong gia đình đã động viên tinh thần cũng như chia sẻ những khó khăn trong những năm qua. Em xin chân thành cảm ơn!

Sinh Viên Thực Hiện

(Ký tên)

BM-ChT-

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH **TRUNG TÂM KHẢO THÍ**	**KỲ THI KẾT THÚC HỌC PHẦN** **HỌC KỲ .III. NĂM HỌC .2024 – 2025.**

PHIẾU CHẤM THI TIỂU LUẬN/ĐỒ ÁN

Môn thi: CÔNG NGHỆ KHOA HỌC DỮ LIỆU

Lớp học phần: 22DTH4B

Nhóm sinh viên thực hiện :

1. Lê Chí Kha — Tham gia đóng góp: 100%
2. Đỗ Kim Anh — Tham gia đóng góp: 100%
3. Nguyễn Phương Lan — Tham gia đóng góp: 100%
4. Lê Thị Tuyết Mai — Tham gia đóng góp: 100%

Ngày thi: 25/08/2025 Phòng thi:

Đề tài tiểu luận/báo cáo của sinh viên : **Dự Đoán Nguy Cơ Đột Quỵ Sử Dụng Mô Hình Học Máy Dựa Trên Dữ Liệu Y Tế**

Phần đánh giá của giảng viên (căn cứ trên thang rubrics của môn học):

Tiêu chí (theo CĐR HP)	**Đánh giá của GV**	**Điểm tối đa**	**Điểm đạt được**
Cấu trúc của báo cáo			
Nội dung			
• Các nội dung thành phần			
• Lập luận			
• Kết luận			
Trình bày			
TỔNG ĐIỂM			

Giảng viên chấm thi

(ký, ghi rõ họ tên)

MỤC LỤC

LỜI MỞ ĐẦU ..... **i**

LỜI CẢM ƠN ..... **ii**

MỤC LỤC ..... **iv**

DANH MỤC HÌNH ..... **vii**

DANH MỤC BẢNG ..... **ix**

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT ..... **x**

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI **1**

1.1. Giới thiệu đề tài. 1

1.2. Lí Do Chọn Đề Tài. 1

1.3. Mục Tiêu Của Đề Tài. 2

1.4. Ý Nghĩa Thực Tiễn. 3

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT **4**

2.1. Khai Phá Dữ Liệu Trong Khoa Học Dữ Liệu. 4

2.2. Ứng Dụng Của Việc Khai Phá Dữ Liệu Vào Thực Tế. 5

2.3. Tổng Quan Về Đột Quỵ 5

2.4. Khoa Học Dữ Liệu Và Học Máy Trong Y Tế. 6

2.5. Đặc Điểm Dữ Liệu Dự Đoán Đột Quỵ 7

2.6. Tiền Xử Lý Dữ Liệu. 7

2.7. Các Mô Hình Học Máy Áp Dụng. 7

2.7.1. Logistic Regression: 7

2.7.2. Decision Tree: 8

2.7.3. Random Forest: 8
2.7.4. K-Nearest Neighbors (KNN) : 8
2.7.5. Support Vector Machine (SVM): 9
2.7.6. Gradient Boosting / XGBoost: 9
CHƯƠNG 3: NGHIÊN CỨU VÀ THỰC NGHIỆM 10
3.1. Quy Trình Nghiên Cứu. 10
3.2. Bộ Dữ Liệu Nghiên Cứu. 10
3.3. Tiền Xử Lý Dữ Liệu. 11
3.4. Mô Hình Học Máy Sử Dụng. 12
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH 13
4.1. Môi Trường Thực Hiện. 13
4.1.1. Nền Tảng Thực Hiện: 13
4.1.2. Ngôn Ngữ Và Thực Hiện: 13
4.1.3. Cấu Hình Phần Cứng (Trong Colab): 13
4.2. Thực Nghiệm. 13
4.2.1. Môi trường thực nghiệm: 13
4.2.2. Các Bước Tiến Hành: 14
4.3. Nhập Dữ Liệu Và Làm Sạch Dữ Liệu. 15
4.4. Khám Phá Dữ Liệu. 16
4.5. Tiền Xử Lý Dữ Liệu. 20
4.6. Kết Quả Huấn Luyện Mô Hình. 26
4.6.1. Xây dựng mô hình: 26
4.6.2. Đánh giá trên dữ liệu đào tạo: 28
4.6.3. Tầm quan trọng của biến: 31
4.6.4. Dự đoán về dữ liệu đào tạo: 31
4.7. Đánh Giá Trên Bộ Kiểm Tra. 32
4.7.1. Hiển thị ví dụ: 34

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 36

5.1. Kết Luận. 36

5.2. Hạn Chế. 36

5.3. Hướng Phát Triển. 37

TÀI LIỆU THAM KHẢO 38

DANH MỤC HÌNH

Hình 1.1: Hai dạng chính của đột quỵ não. Nguồn: benhvientantao.com 1

Hình 2.1: Quy trình học máy trong dự đoán đột quỵ.....6

Hình 3.1 : Dữ liệu được Output. 11

Hình 4.1: Vào phần mềm Google Colab. 14

Hình 4.2: Giao diện chính.....14

Hình 4.3: Các bước chuẩn bị Runtime 14

Hình 4.4: Màn hình đã lưu data cần train.....15

Hình 4.5: Thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy. 15

Hình 4.6: Dữ liệu nhập. 15

Hình 4.7: Dữ liệu được làm sạch. 16

Hình 4.8: Thống kê cơ bản (age, avg_glucose_level, bmi).....17

Hình 4.9: Phân phối độ tuổi, mức đường huyết và chỉ số BMI.....17

Hình 4.10: Mối quan hệ giữa Tuổi – Đường huyết – BMI. 18

Hình 4.11: Biểu đồ thể hiện sự tương quan Spearman.....19

Hình 4.12: Phân phối đồ thị của các tính năng phân loại.....20

Hình 4.13: Thể hiện tính toán tần số mắc bệnh.....20

Hình 4.14: Biểu đồ phân phối mục tiêu. 21

Hình 4.15: Biểu đồ mục tiêu so với các đối tượng bằng biểu đồ khảm (Target & age, avg_glucose_level, bmi).....22

Hình 4.16: Biểu đồ thể hiện mục tiêu so với các đặc trưng bằng biểu đồ mosaic 25

Hình 4.17: Các biến đầu vào được chọn cho mô hình. 26

Hình 4.18: Quá trình giảm logloss theo số lượng cây.....26

Hình 4.19: So sánh hiệu suất huấn luyện và validation theo số lượng cây.....27

Hình 4.20: Đường cong ROC - Dữ liệu đào tạo. 28
Hình 4.21: Đường cong ROC - Xác thực chéo. 29
Hình 4.22: Độ chính xác Confusion Matrix với ngưỡng tối ưu theo F1-score. 29
Hình 4.23: Độ chính xác mô hình tại ngưỡng thủ công. 30
Hình 4.24: Độ chính xác Cross Validation với ngưỡng thủ công.....31
Hình 4.25: Biểu đồ các biến trong mô hình H2O Gradient Boosting Machine. 31
Hình 4.26: Dự đoán trên tập huấn luyện.....32
Hình 4.27: Tần suất dự đoán và thực tế.....32
Hình 4.28: Đường cong ROC của mô hình H2O Gradient Boosting Machine. 32
Hình 4.29: Accuracy tính theo ngưỡng thủ công. 33
Hình 4.30: Phân bố xác suất dự đoán trên tập kiểm tra. 33
Hình 4.31: Danh sách bệnh nhân nguy cơ cao (Top 20). 34
Hình 4.32: Kết quả hiệu chuẩn cao. 34
Hình 4.33: Danh sách bệnh nhân nguy cơ thấp (Top 20).....35
Hình 4.34: Kết quả hiệu chuẩn thấp. 35

DANH MỤC BẢNG

Bảng 4.1: BMI – Kiểm tra bảng chéo. 23

Bảng 4.2: Chuẩn hóa từng hàng để có được tỷ lệ phần trăm. 24

Bảng 4.3: Kết quả kiểm tra bảng chéo. 25

Bảng 4.4: Kết quả chuẩn hóa từng hàng.....26

Bảng 4.5: Confusion Matrix với ngưỡng tối ưu theo F1-score. 29

Bảng 4.6: Ma trận nhầm lẫn tại ngưỡng 0.148. 30

Bảng 4.7: Confusion Matrix trên Cross Validation (ngưỡng thủ công).....30

Bảng 4.8: Ma trận nhầm lẫn tại ngưỡng 0.148. 33

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

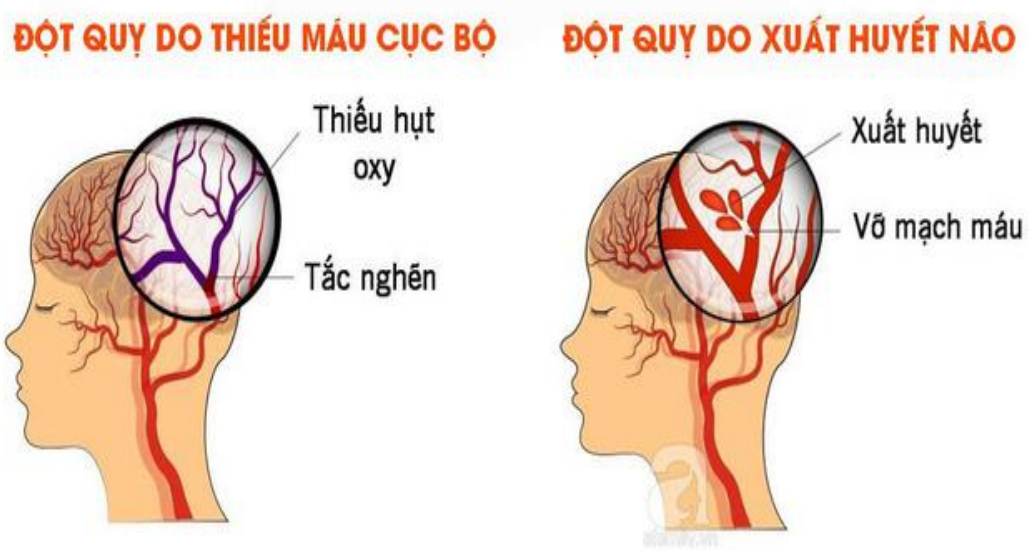
Viết Tắt	Ý Nghĩa
WHO	World Health Organization
ML	Machine Learning
BMI	Body Mass Index
KNN	K-Nearest Neighbors
SVM	Support Vector Machine
CRISP-DM	Cross-Industry Standard Process for Data Mining

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1. Giới thiệu đề tài.

Đề tài *"Dự đoán nguy cơ đột quỵ sử dụng mô hình học máy dựa trên dữ liệu y tế"* tập trung vào việc khai thác và phân tích dữ liệu sức khỏe của bệnh nhân nhằm xây dựng các mô hình dự đoán nguy cơ đột quỵ. Bằng cách ứng dụng các thuật toán học máy, đề tài không chỉ giúp phát hiện sớm nguy cơ bệnh mà còn góp phần hỗ trợ bác sĩ và bệnh nhân trong việc đưa ra các quyết định y tế kịp thời.

Thông qua quá trình tiền xử lý dữ liệu, lựa chọn đặc trưng và huấn luyện mô hình, nhóm mong muốn đánh giá hiệu quả của các thuật toán khác nhau, từ đó đề xuất giải pháp phù hợp nhằm nâng cao độ chính xác và khả năng ứng dụng thực tiễn của mô hình.



Hình 1.1: Hai dạng chính của đột quỵ não. Nguồn: benhvientantao.com

1.2. Lí Do Chọn Đề Tài.

Đột quỵ là một trong những nguyên nhân hàng đầu gây tử vong và tàn tật trên toàn thế giới, trong đó Việt Nam cũng nằm trong nhóm quốc gia có tỷ lệ mắc và tử vong do đột quỵ cao. Việc phát hiện sớm nguy cơ đột quỵ đóng vai trò vô cùng quan

trọng để có biện pháp phòng ngừa, điều trị kịp thời, góp phần giảm thiểu hậu quả nặng nề cho người bệnh cũng như gánh nặng cho xã hội.

Trong bối cảnh hiện nay, sự phát triển mạnh mẽ của khoa học dữ liệu và Machine Learning đã mở ra nhiều cơ hội mới trong lĩnh vực y tế, đặc biệt là trong chẩn đoán, dự đoán và hỗ trợ ra quyết định lâm sàng. Các mô hình học máy có khả năng xử lý dữ liệu y tế đa dạng (tuổi tác, chỉ số sinh học, tiền sử bệnh, thói quen sinh hoạt…) để phát hiện các yếu tố nguy cơ tiềm ẩn và dự đoán khả năng xảy ra đột quỵ với độ chính xác cao.

Việc nghiên cứu, xây dựng mô hình dự đoán nguy cơ đột quỵ dựa trên dữ liệu y tế không chỉ giúp hỗ trợ bác sĩ trong công tác sàng lọc, đưa ra quyết định điều trị mà còn giúp bệnh nhân nâng cao ý thức phòng ngừa, thay đổi lối sống và theo dõi sức khỏe chủ động hơn.

Chính vì vậy, nhóm đã lựa chọn đề tài "Dự đoán nguy cơ đột quỵ sử dụng mô hình học máy dựa trên dữ liệu y tế" với mong muốn ứng dụng công nghệ hiện đại vào lĩnh vực chăm sóc sức khỏe, góp phần giảm thiểu tác động tiêu cực của đột quỵ và mang lại giá trị thực tiễn cao cho cộng đồng.

1.3. Mục Tiêu Của Đề Tài.

- **Tìm hiểu và phân tích dữ liệu y tế :** liên quan đến bệnh nhân, bao gồm các thông tin nhân khẩu học, chỉ số sức khỏe và các yếu tố nguy cơ.
- **Tiền xử lý và làm sạch dữ liệu :** để đảm bảo chất lượng và độ tin cậy cho mô hình dự đoán.
- **Xây dựng và huấn luyện các mô hình học máy :** (ví dụ: Logistic Regression, Random Forest, XGBoost, v.v.) nhằm dự đoán nguy cơ đột quỵ.
- **Đánh giá, so sánh hiệu quả giữa các mô hình :** dựa trên các thước đo như Accuracy, Precision, Recall, F1-score, ROC-AUC để lựa chọn mô hình tối ưu.
- **Đề xuất giải pháp và định hướng ứng dụng thực tế :** trong việc hỗ trợ bác sĩ và bệnh nhân phòng ngừa đột quỵ sớm.

1.4. Ý Nghĩa Thực Tiễn.

- **Trong lĩnh vực y tế:** Kết quả nghiên cứu có thể trở thành cơ sở tham khảo trong việc áp dụng các công cụ học máy để dự đoán bệnh lý, đặc biệt là bệnh đột quỵ. Điều này giúp nâng cao khả năng phát hiện sớm nguy cơ, từ đó giảm thiểu tỷ lệ tử vong và di chứng nặng nề.
- **Trong lĩnh vực khoa học dữ liệu:** Đề tài là ví dụ cụ thể cho việc ứng dụng học máy vào bài toán thực tế. Đây cũng là cơ hội để thử nghiệm, so sánh và đánh giá hiệu quả các thuật toán trong bối cảnh dữ liệu y tế.
- **Đối với sinh viên thực hiện:** Đề tài giúp củng cố kiến thức, rèn luyện kỹ năng làm việc với dữ liệu thực tế, nâng cao năng lực phân tích, xử lý dữ liệu, lập trình và vận dụng các mô hình học máy. Đồng thời, đề tài còn mở ra hướng nghiên cứu sâu hơn trong việc ứng dụng trí tuệ nhân tạo vào chăm sóc sức khỏe

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Khai Phá Dữ Liệu Trong Khoa Học Dữ Liệu.

Khai phá dữ liệu trong lĩnh vực khoa học dữ liệu là quá trình tìm hiểu, phân tích và trích xuất thông tin có giá trị từ các tập dữ liệu lớn và phức tạp. Mục tiêu của việc này là tìm ra những mẫu, xu hướng và thông tin ẩn chưa được biết đến trước đó để hỗ trợ quyết định và đưa ra dự đoán trong các lĩnh vực khác nhau. Dưới đây là một số bước quan trọng trong quá trình khai phá dữ liệu trong lĩnh vực khoa học dữ liệu:

- **Thu thập dữ liệu:** Điều này bắt đầu bằng việc thu thập dữ liệu từ các nguồn khác nhau như cơ sở dữ liệu, bộ thu thập dữ liệu, các nguồn mạng xã hội, cảm biến, v.v. Dữ liệu có thể là số liệu, văn bản, hình ảnh, âm thanh hoặc các dạng khác.
- **Tiền xử lý dữ liệu:** Dữ liệu thường không hoàn hảo, có thể chứa nhiễu, thiếu sót hoặc không chuẩn. Tiền xử lý dữ liệu bao gồm việc làm sạch, chuyển đổi, điền giá trị thiếu, loại bỏ nhiễu và chuẩn hóa dữ liệu để chuẩn bị cho quá trình khai phá.
- **Khám phá dữ liệu:** Bước này liên quan đến việc sử dụng các phương pháp và công cụ để khám phá cấu trúc, mẫu và thông tin quan trọng trong dữ liệu. Điều này có thể bao gồm việc áp dụng các kỹ thuật thống kê, học máy, khai phá văn bản, khai thác đồ thị, v.v.
- **Mô hình hóa và phân tích:** Sau khi có thông tin từ bước trước, bạn có thể xây dựng các mô hình dự đoán, phân loại hoặc gom cụm để hiểu rõ hơn về dữ liệu. Điều này liên quan đến việc sử dụng các thuật toán học máy và khai phá dữ liệu để tạo ra các mô hình dự đoán.
- **Kiểm tra và đánh giá:** Mô hình cần được kiểm tra bằng cách sử dụng dữ liệu kiểm tra hoặc cross-validation để đảm bảo tính chính xác và hiệu quả. Điều này giúp đánh giá mô hình và điều chỉnh nó nếu cần.
- **Tổng hợp và trình bày kết quả:** Cuối cùng, bạn cần tổng hợp và trình bày kết

quả khai phá dữ liệu một cách rõ ràng và dễ hiểu. Điều này bao gồm việc viết báo cáo, tạo biểu đồ, thực hiện trực quan hóa dữ liệu và trình bày kết quả cho người khác.

Nhớ rằng khai phá dữ liệu là một quá trình động và lặp lại, nghĩa là ta có thể cần điều chỉnh và tái áp dụng các bước trên để tìm ra thông tin cụ thể cần quan tâm.

2.2. Ứng Dụng Của Việc Khai Phá Dữ Liệu Vào Thực Tế.

Khai phá dữ liệu có rất nhiều ứng dụng thực tế trong các lĩnh vực khác nhau. Dưới đây là một số ví dụ về các lĩnh vực và ứng dụng của khai phá dữ liệu:

- **Kinh doanh và tiếp thị*:*** Khai phá dữ liệu giúp các doanh nghiệp hiểu rõ hơn về khách hàng của họ, dự đoán xu hướng thị trường, phân loại khách hàng và tối ưu hóa chiến lược tiếp thị. Ví dụ: dự đoán mô hình mua sắm của khách hàng, gợi ý sản phẩm liên quan.
- **Y tế*:*** Khai phá dữ liệu có thể giúp dự đoán dịch bệnh, phân loại bệnh nhân, phát hiện sớm các triệu chứng bất thường, tối ưu hóa quản lý bệnh viện và nghiên cứu y tế.
- **Tài chính*:*** Khai phá dữ liệu có thể giúp dự đoán xu hướng thị trường tài chính, xác định rủi ro và phân tích hiệu suất các quỹ đầu tư.
- **Giao thông và vận tải*:*** Khai phá dữ liệu có thể giúp dự đoán tắc nghẽn giao thông, tối ưu hóa lộ trình vận tải, quản lý độ an toàn của phương tiện.
- **Nông nghiệp*:*** Khai phá dữ liệu có thể giúp dự đoán sản lượng nông nghiệp, quản lý sử dụng đất và tối ưu hóa việc sử dụng phân bón.
- **Khoa học xã hội*:*** Khai phá dữ liệu giúp hiểu rõ hơn về các xu hướng xã hội, phân tích dữ liệu từ mạng xã hội để tìm hiểu hành vi người dùng.

2.3. Tổng Quan Về Đột Quỵ .

Đột quỵ là tình trạng rối loạn tuần hoàn máu não đột ngột, gây tắc nghẽn hoặc vỡ mạch máu não, dẫn đến tổn thương não và nguy cơ tử vong cao. Theo Tổ chức Y tế Thế giới (WHO), đột quỵ là nguyên nhân gây tử vong đứng hàng thứ hai toàn cầu và là nguyên nhân hàng đầu gây tàn tật lâu dài. Một số yếu tố nguy cơ chính của đột

quỵ bao gồm:

- Tuổi tác, giới tính.
- **Các bệnh lý nền:** tăng huyết áp, bệnh tim, tiểu đường.
- **Thói quen sinh hoạt:** hút thuốc, uống rượu, ít vận động.
- **Các chỉ số sức khỏe:** chỉ số khối cơ thể (BMI), mức glucose trong máu.

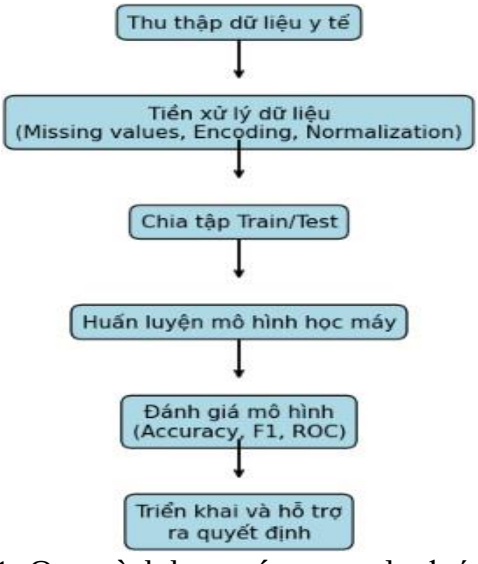
Nhận diện sớm nguy cơ đột quỵ đóng vai trò quan trọng để đưa ra các biện pháp phòng ngừa kịp thời. Trong bối cảnh đó, khoa học dữ liệu và Machine Learning có thể hỗ trợ xây dựng mô hình dự đoán nguy cơ dựa trên dữ liệu y tế.

2.4. Khoa Học Dữ Liệu Và Học Máy Trong Y Tế.

Khoa học dữ liệu là sự kết hợp của thống kê, phân tích dữ liệu và trí tuệ nhân tạo để trích xuất tri thức từ dữ liệu. Trong y tế, nó giúp:

- Hỗ trợ chẩn đoán dựa trên dữ liệu.
- Phát hiện sớm nguy cơ bệnh.
- Xây dựng mô hình dự báo và khuyến nghị điều trị.

Học máy (Machine Learning – ML) là một nhánh của trí tuệ nhân tạo, cho phép hệ thống học từ dữ liệu. Trong bài toán dự đoán đột quỵ, ML đóng vai trò xây dựng mô hình phân loại để nhận diện nguy cơ. Quy trình học máy trong y tế:



Hình 2.1: Quy trình học máy trong dự đoán đột quỵ.

2.5. Đặc Điểm Dữ Liệu Dự Đoán Đột Quỵ .

Bộ dữ liệu y tế gồm nhiều biến đầu vào:

- **Thông tin cá nhân:** tuổi, giới tính, tình trạng hôn nhân, nơi sống.
- **Lối sống:** hút thuốc, nghề nghiệp.
- **Chỉ số sức khỏe:** BMI, glucose máu, huyết áp.
- **Bệnh nền:** bệnh tim, tăng huyết áp, tiểu đường.
- **Nhãn (Label):** có đột quỵ (1) / không đột quỵ (0).

Đây là bài toán phân loại nhị phân (Binary Classification):

$$\mathbf{y \in \{ 0, 1 \}}$$

Trong đó:

- **y = 0 :** bệnh nhân không có nguy cơ đột quỵ .
- **y = 1 :** bệnh nhân có nguy cơ đột quỵ .

2.6. Tiền Xử Lý Dữ Liệu.

Tiền xử lý dữ liệu giúp nâng cao chất lượng đầu vào cho mô hình:

- **Xử lý dữ liệu thiếu:** dùng trung bình, trung vị hoặc kỹ thuật Imputation.
- **Chuẩn hóa dữ liệu (Standardization/Normalization):** với μ là trung bình và σ là độ lệch chuẩn.

$$\boldsymbol{X' = \frac{X - \mu}{\sigma}}$$

- **Mã hóa dữ liệu phân loại:** One-Hot Encoding cho biến định tính (giới tính, nghề nghiệp…).
- **Chia dữ liệu Train/Test:** theo tỉ lệ 70:30 hoặc 80:20.
- **Xử lý mất cân bằng dữ liệu:** sử dụng SMOTE (Synthetic Minority Oversampling Technique) để tăng mẫu của lớp thiểu số.

2.7. Các Mô Hình Học Máy Áp Dụng.

2.7.1. Logistic Regression:

Mô hình tuyến tính dự đoán xác suất xảy ra đột quỵ bằng hàm sigmoid:

$$\mathbf{P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0+\beta_1 x_1+\ldots+\beta_n x_n)}}}$$

- **Ưu điểm:** dễ hiểu, giải thích được.
- **Nhược điểm:** chỉ mô hình hóa quan hệ tuyến tính.

2.7.2. Decision Tree:

Mô hình phân loại dựa trên cây quyết định. Tiêu chí phân chia thường dùng:

Entropy:

$$\boldsymbol{Entropy(S) = -\sum_{i=1}^{c} p_i \log_2 p_i}$$

Gini Index:

$$\boldsymbol{Gini(S) = 1 - \sum_{i=1}^{c} p_i^2}$$

- **Ưu điểm:** trực quan, dễ giải thích.
- **Nhược điểm:** dễ *overfitting*.

2.7.3. Random Forest:

Là tập hợp nhiều cây quyết định (ensemble).

- Kỹ thuật bagging để giảm phương sai.
- Đưa ra đánh giá tầm quan trọng của từng đặc trưng.

2.7.4. K-Nearest Neighbors (KNN) :

$$\mathbf{d(x, x_i) = \sqrt{\sum_{j=1}^{n} (x_j - x_{ij})^2}}$$

- **Ưu điểm:** đơn giản.

- **Nhược điểm:** chậm với dữ liệu lớn.

2.7.5. Support Vector Machine (SVM):

Tìm siêu phẳng phân chia dữ liệu tối ưu:

$$\max_{w,b} \frac{2}{||w||}$$

- **Ưu điểm:** Hiệu quả cao với dữ liệu nhiều chiều.
- **Nhược điểm:** tốn thời gian với dataset lớn.

2.7.6. Gradient Boosting / XGBoost:

Kỹ thuật **boosting** huấn luyện nhiều mô hình yếu (weak learners) để tạo thành mô hình mạnh.

- **Ưu điểm:** độ chính xác cao.
- **Nhược điểm:** phức tạp, dễ overfitting nếu không điều chỉnh tốt.

CHƯƠNG 3: NGHIÊN CỨU VÀ THỰC NGHIỆM

3.1. Quy Trình Nghiên Cứu.

Quy trình được xây dựng dựa trên phương pháp luận CRISP-DM (Cross-Industry Standard Process for Data Mining) và bao gồm các bước:

- **Xác định bài toán:** Dự đoán khả năng đột quỵ dựa trên dữ liệu y tế cá nhân.
- **Thu thập dữ liệu:** Sử dụng bộ dữ liệu "Healthcare Dataset – Stroke Data" chứa thông tin nhân khẩu học, bệnh lý nền và chỉ số sinh học.
- **Tiền xử lý dữ liệu:** Làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa và mã hóa dữ liệu.
- **Phân tích và chọn đặc trưng:** Xác định các thuộc tính ảnh hưởng mạnh đến khả năng đột quỵ. Xây dựng mô hình học máy: Áp dụng nhiều thuật toán khác nhau để so sánh.
- **Đánh giá và so sánh mô hình:** Sử dụng các chỉ số Accuracy, Precision, Recall, F1-score, ROC-AUC.
- **Triển khai kết quả:** Đề xuất mô hình tối ưu có thể áp dụng trong thực tiễn y tế.

3.2. Bộ Dữ Liệu Nghiên Cứu.

Bộ dữ liệu gồm 5110 quan sát với các thuộc tính chính:

- **id:** Mã định danh bệnh nhân.
- **gender:** Giới tính.
- **age:** Tuổi.
- **hypertension:** Có mắc tăng huyết áp (0: không, 1: có).
- **heart_disease:** Có mắc bệnh tim (0: không, 1: có).
- **ever_married:** Tình trạng hôn nhân.
- **work_type:** Nghề nghiệp.
- **Residence_type:** Nơi ở (thành thị/nông thôn).

- **avg_glucose_level:** Mức đường huyết trung bình.
- **bmi:** Chỉ số BMI.
- **smoking_status:** Tình trạng hút thuốc.
- **stroke:** Nhãn mục tiêu (0: không đột quỵ, 1: có đột quỵ).
- **Đặc điểm quan trọng:** Dữ liệu bị mất cân bằng (chỉ khoảng 5% trường hợp bị đột quỵ), do đó cần áp dụng các kỹ thuật cân bằng dữ liệu (SMOTE).

```
df.head()
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	residence_type	avg_glucose_level	bmi	smoking_status
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	-99.0	never smoked
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes
4	1665	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked

Hình 3.1 : Dữ liệu được Output.

3.3. Tiền Xử Lý Dữ Liệu.

- **Xử lý giá trị thiếu:** Cột bmi có giá trị NaN, được thay thế bằng giá trị trung vị (median).
- **Chuẩn hóa dữ liệu:** Các thuộc tính số (age, avg_glucose_level, bmi) được chuẩn hóa theo Min-Max Scaling để đảm bảo mô hình không bị ảnh hưởng bởi đơn vị đo khác nhau.
- **Mã hóa biến phân loại:** Các biến như gender, work_type, smoking_status được mã hóa bằng One-Hot Encoding.
- **Cân bằng dữ liệu:** Áp dụng SMOTE (Synthetic Minority Over-sampling Technique) để tăng số lượng mẫu dương (stroke = 1).
- **Chia dữ liệu train/test:** Tỷ lệ 80% dùng để huấn luyện, 20% dùng để kiểm tra.

3.4. Mô Hình Học Máy Sử Dụng.

Đề tài áp dụng nhiều thuật toán học máy để so sánh hiệu quả:

- Logistic Regression – mô hình tuyến tính cho phân loại nhị phân.
- Decision Tree – mô hình cây quyết định dựa trên chỉ số Gini/Entropy.
- Random Forest – tập hợp nhiều cây quyết định (bagging).
- K-Nearest Neighbors (KNN) – phân loại dựa vào k láng giềng gần nhất.
- Support Vector Machine (SVM) – phân lớp bằng siêu phẳng tối ưu.
- Gradient Boosting / XGBoost – phương pháp boosting mạnh mẽ cho dữ liệu mất cân bằng.

3.5. Tiêu Chí Đánh Giá Mô Hình.

Các chỉ số được sử dụng:

- **Accuracy:** Tỉ lệ dự đoán đúng.
- **Precision:** Tỉ lệ dự đoán dương đúng trong tất cả dự đoán dương.
- **Recall (Sensitivity):** Tỉ lệ phát hiện đúng ca bệnh thực sự (quan trọng trong y tế).
- **F1-score:** Trung bình điều hòa giữa Precision và Recall.
- **ROC-AUC:** Đo khả năng phân biệt giữa hai lớp.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

4.1. Môi Trường Thực Hiện.

4.1.1. Nền Tảng Thực Hiện:

Toàn bộ quá trình xử lý và huấn luyện mô hình được thực hiện trên nền tảng Google Colab – một công cụ tính toán đám mây do Google cung cấp, hỗ trợ GPU, thuận tiện cho xử lý dữ liệu và huấn luyện mô hình học sâu. Bên cạnh đó, người dùng có thể sử dụng Jupyter Notebook nếu làm việc trên máy tính cá nhân.

4.1.2. Ngôn Ngữ Và Thực Hiện:

- **Ngôn ngữ:** Python 3.x
- **Thư viện sử dụng:**
  - **Pandas, Numpy:** xử lý, thống kê và thao tác dữ liệu dạng bảng.
  - **Matplotlib, Plotly:** trực quan hóa dữ liệu và biểu đồ kết quả.
  - **Scikit-learn:** chuẩn hóa dữ liệu (MinMaxScaler), phân chia tập huấn luyện/kiểm tra, tính toán độ chính xác mô hình.
  - **TensorFlow/Keras:** xây dựng và huấn luyện mô hình LSTM.
  - **Callback:** hỗ trợ theo dõi quá trình huấn luyện và lưu mô hình tốt nhất.

4.1.3. Cấu Hình Phần Cứng (Trong Colab):

- **GPU:** Tùy chọn GPU (Tesla T4 hoặc P100).
- **RAM:** khoảng 12.7 GB.
- **Bộ xử lý:** môi trường máy ảo của Google.

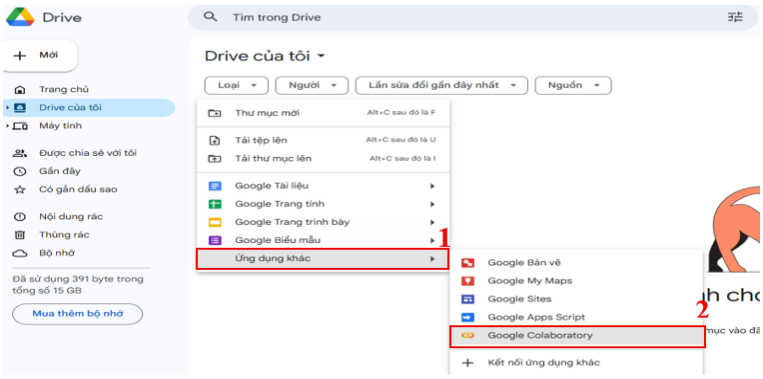
4.2. Thực Nghiệm.

4.2.1. Môi trường thực nghiệm:

Google Colab: Colaboratory, hay " **colab** " là nền tảng trực tuyến miễn phí của Google hỗ trợ viết mã Python và sử dụng GPU/TPU miễn phí. Người dùng có thể cài đặt các thư viện như TensorFlow, PyTorch, NumPy để huấn luyện mô hình AI,

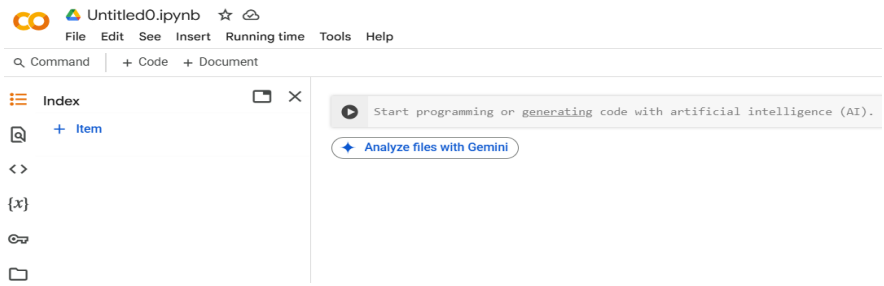
xử lý dữ liệu lớn hoặc trực quan hóa kết quả.

- **Bước 1:** Vào Google, Nhấn vào " Drive " và Bấm chuột phải sẽ hiện thị lên phần mềm " Google Colab ".



Hình 4.1: Vào phần mềm Google Colab.

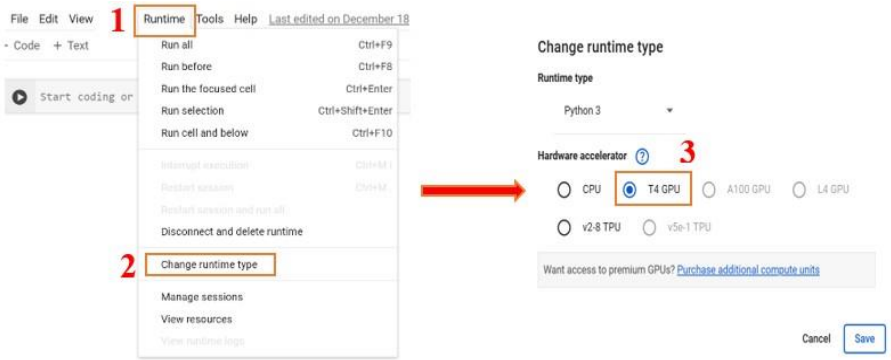
- **Bước 2:** Vào Google Colab ta sẽ có giao diện như hình gồm có các Tab **File**, **Edit**, **See**, **Insert**, **Running time**, **Tools** và **Help.**



Hình 4.2: Giao diện chính.

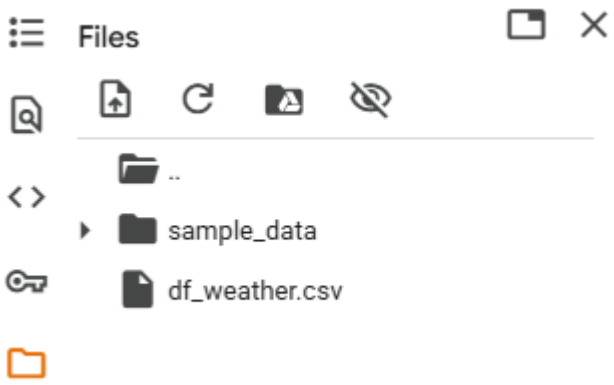
4.2.2. Các Bước Tiến Hành:

- **Bước 1:** Chuẩn bị thay đổi Runtime để train.



Hình 4.3: Các bước chuẩn bị Runtime

- **Bước 2:** Lưu data vào phần mềm google.colab để bắt đầu train.



Hình 4.4: Màn hình đã lưu data cần train.

- **Bước 3:** Copy file.csv để đưa vào xử lí nhận diện khoanh vùng đối tượng và tính toán xác suất. Cùng với đó là đưa ra thời gian xử lí data.

```
df.head()
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	residence_type	avg_glucose_level	bmi	smoking_status
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	-99.0	never smoked
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes
4	1665	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked

Hình 4.5: Thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy.

4.3. Nhập Dữ Liệu Và Làm Sạch Dữ Liệu.

```
[3] # load data
    df = pd.read_csv('/content/healthcare-dataset-stroke-data.csv')

[4] # dimensions of data
    df.shape

    (5110, 12)

[5] # column names
    print(df.columns.tolist())

    ['id', 'gender', 'age', 'hypertension', 'heart_disease', 'ever_married', 'work_type', 'Residence_type', 'avg_glucose_level', 'bmi', '
```

Hình 4.6: Dữ liệu nhập.

```
# overview of data structure
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5110 entries, 0 to 5109
Data columns (total 12 columns):
 #   Column             Non-Null Count  Dtype  
---  ------             --------------  -----  
 0   id                 5110 non-null   int64  
 1   gender             5110 non-null   object 
 2   age                5110 non-null   float64
 3   hypertension       5110 non-null   int64  
 4   heart_disease      5110 non-null   int64  
 5   ever_married       5110 non-null   object 
 6   work_type          5110 non-null   object 
 7   Residence_type     5110 non-null   object 
 8   avg_glucose_level  5110 non-null   float64
 9   bmi                4909 non-null   float64
 10  smoking_status     5110 non-null   object 
 11  stroke             5110 non-null   int64  
dtypes: float64(3), int64(4), object(5)
memory usage: 479.2+ KB
```

Hình 4.7: Dữ liệu được làm sạch.

4.4. Khám Phá Dữ Liệu.

- **Quy mô dữ liệu:** 5110 mẫu, 12 thuộc tính đầu vào + 1 nhãn mục tiêu (stroke).
- **Mất cân bằng dữ liệu:** chỉ khoảng 5% bệnh nhân có đột quỵ → cần kỹ thuật cân bằng.
- **Một số đặc điểm thống kê:**
  - Người bị đột quỵ thường có tuổi cao (đa phần > 60).
  - Tăng huyết áp, bệnh tim, chỉ số BMI cao có mối liên hệ với nguy cơ đột quỵ.
  - Yếu tố hút thuốc cũng cho thấy sự khác biệt giữa hai nhóm.

```
# select numerical features
features_num = ['age', 'avg_glucose_level','bmi']
```

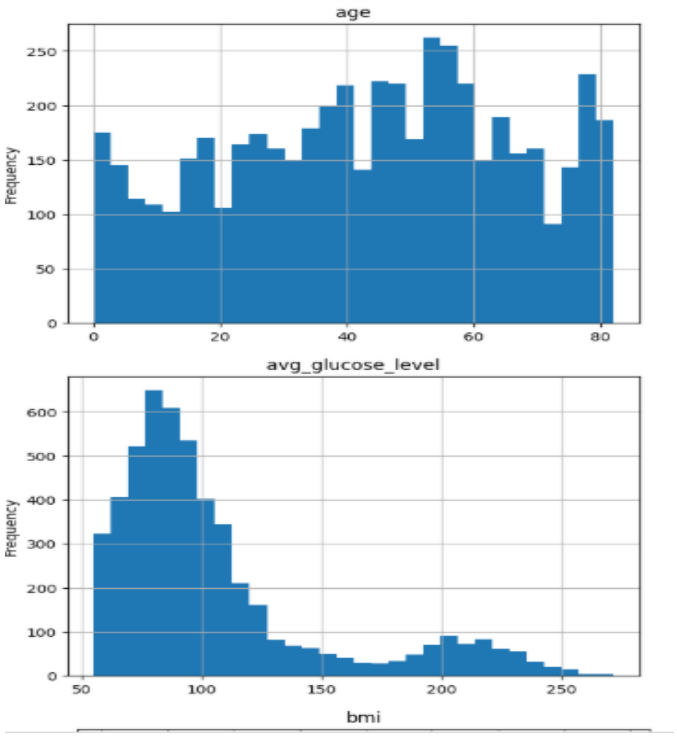
```
# basic stats
df[features_num].describe(percentiles=[0.1,0.25,0.5,0.75,0.9])
```

	age	avg_glucose_level	bmi
count	5110.000000	5110.000000	5110.000000
mean	43.226614	106.147677	23.862603
std	22.612647	45.283560	26.028009
min	0.080000	55.120000	-99.000000
10%	11.000000	65.789000	18.290000
25%	25.000000	77.245000	22.900000
50%	45.000000	91.885000	27.700000
75%	61.000000	114.090000	32.800000
90%	75.000000	192.181000	38.700000
max	82.000000	271.740000	97.600000

Hình 4.8: Thống kê cơ bản (age, avg_glucose_level, bmi).

Dữ liệu cho thấy tuổi phân bố rộng, glucose chủ yếu 80–120 nhưng có outlier, BMI tập trung 25–35 với một số bất thường.

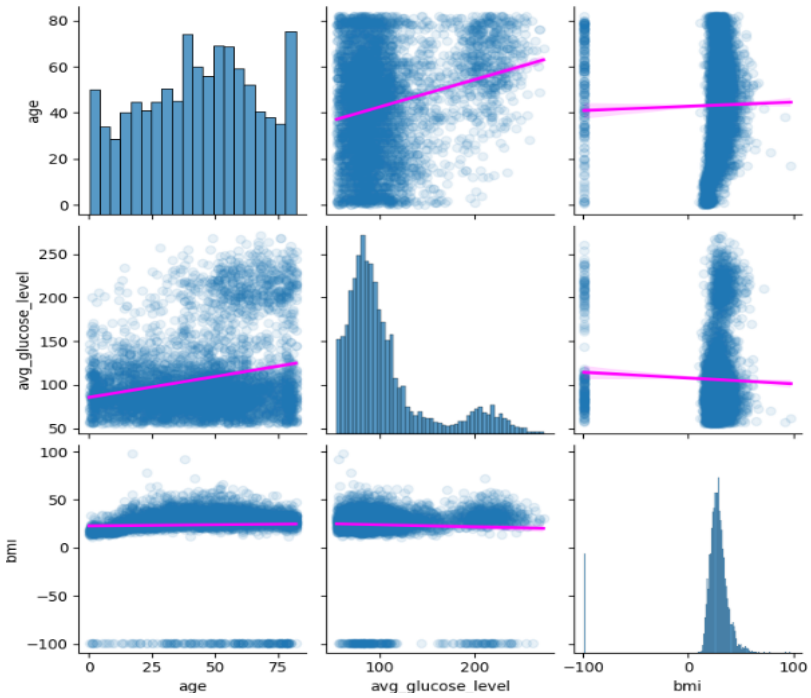
```
# plot distribution of numerical features
for f in features_num:
    df[f].plot(kind='hist', bins=30)
    plt.title(f)
    plt.grid()
    plt.show()
```



Hình 4.9: Phân phối độ tuổi, mức đường huyết và chỉ số BMI.

Biểu đồ cho thấy glucose tăng nhẹ theo tuổi, còn BMI phân tán bất thường và không có quan hệ tuyến tính rõ với các biến khác.

```
# pairwise scatter plot
sns.pairplot(df[features_num],
             kind='reg',
             plot_kws={'line_kws':{'color':'magenta'}, 'scatter_kws': {'alpha': 0.1}})
plt.show()
```

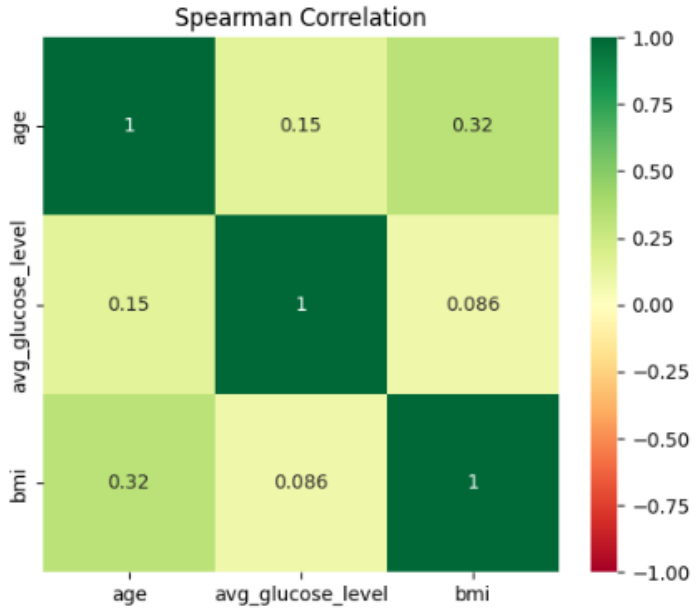


Hình 4.10: Mối quan hệ giữa Tuổi – Đường huyết – BMI.

Biểu đồ ma trận tương quan Spearman cho thấy mối quan hệ giữa ba biến tuổi (age), đường huyết trung bình (avg_glucose_level) và chỉ số BMI nhìn chung khá yếu. Trong đó, tuổi và BMI có mức tương quan dương trung bình (0.32), tuổi và đường huyết có mức tương quan dương yếu (0.15), còn BMI và đường huyết hầu như không có mối liên hệ đáng kể (0.086). Điều này cho thấy các biến này chỉ đóng góp một phần nhất định và không có mối quan hệ tuyến tính mạnh mẽ với nhau.

```
# Spearman (Rank) correlation
corr_spearman = df[features_num].corr(method='spearman')

fig = plt.figure(figsize = (6,5))
sns.heatmap(corr_spearman, annot=True, cmap="RdYlGn", vmin=-1, vmax=+1)
plt.title('Spearman Correlation')
plt.show()
```

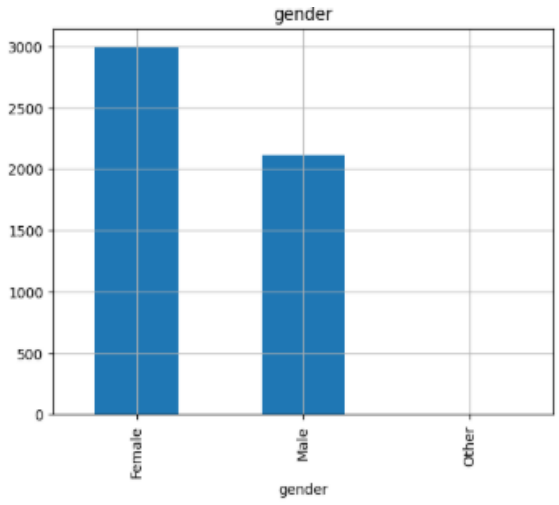


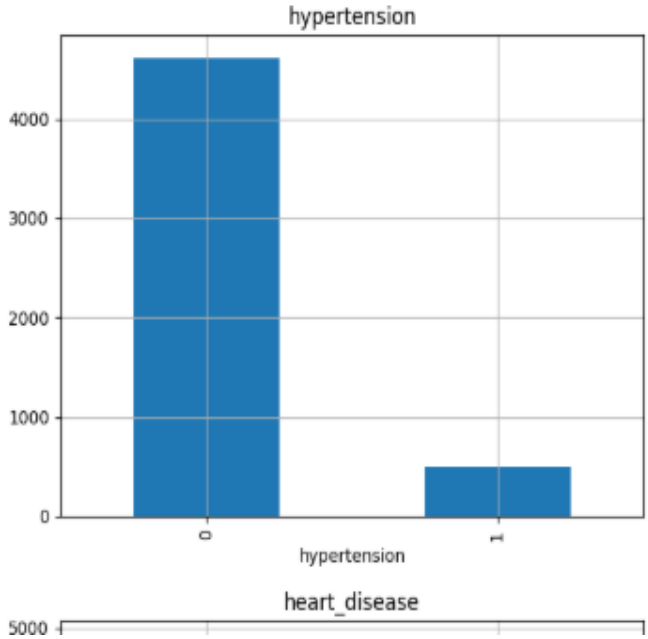
Hình 4.11: Biểu đồ thể hiện sự tương quan Spearman.

Biểu đồ cho thấy dữ liệu mất cân bằng: nữ chiếm đa số, nam ít hơn, còn nhóm khác giới tính hầu như không đáng kể. Về sức khỏe, đa phần bệnh nhân không mắc tăng huyết áp và bệnh tim, chỉ một tỷ lệ nhỏ có bệnh nền. Điều này cho thấy dữ liệu nghiêng về phía người khỏe mạnh.

```
features_cat = ['gender','hypertension','heart_disease','ever_married',
                'work_type','residence_type','smoking_status']
```

```
# plot distribution of categorical features
for f in features_cat:
    df[f].value_counts().plot(kind='bar')
    plt.title(f)
    plt.grid()
    plt.show()
```





Hình 4.12: Phân phối đồ thị của các tính năng phân loại.

4.5. Tiền Xử Lý Dữ Liệu.

Xử lý giá trị thiếu: thay thế giá trị NaN trong cột bmi bằng giá trị trung vị.

- **Chuẩn hóa dữ liệu:** dùng Min-Max Scaling cho các thuộc tính số.
- **Mã hóa biến phân loại:** dùng One-Hot Encoding cho gender, work_type, smoking_status.
- **Cân bằng dữ liệu:** áp dụng SMOTE để tạo thêm dữ liệu cho lớp stroke = 1.
- **Chia dữ liệu:** train/test = 80/20.

```
# calc frequencies
target_count = df.target.value_counts()
print(target_count)
print()
print('Percentage of strokes [1]:', np.round(100*target_count[1] / target_count.sum(),2), '%')
```

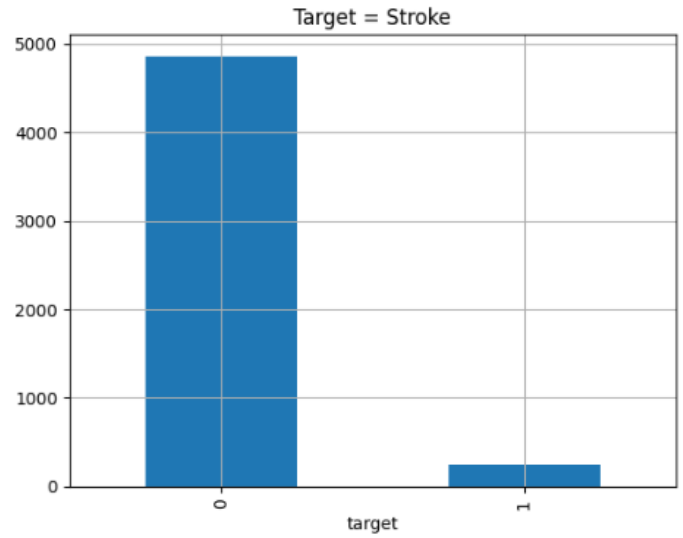
```
target
0    4861
1     249
Name: count, dtype: int64

Percentage of strokes [1]: 4.87 %
```

Hình 4.13: Thể hiện tính toán tần số mắc bệnh.

Hình 4.14 thể hiện phân bố biến mục tiêu (Target = Stroke) trong tập dữ liệu. Có thể thấy số lượng bệnh nhân không bị đột quỵ (stroke = 0) chiếm đa số với gần 5000 mẫu, trong khi số bệnh nhân bị đột quỵ (stroke = 1) chỉ chiếm một tỷ lệ rất nhỏ, khoảng vài trăm mẫu. Điều này cho thấy dữ liệu bị mất cân bằng nghiêm trọng (imbalanced data), cần được lưu ý khi huấn luyện mô hình để tránh hiện tượng mô hình thiên lệch về nhóm chiếm đa số.

```
# plot target distribution
target_count.plot(kind='bar')
plt.title('Target = Stroke')
plt.grid()
plt.show()
```



Hình 4.14: Biểu đồ phân phối mục tiêu.

Biểu đồ cho thấy mối quan hệ giữa biến mục tiêu (Stroke) và các đặc trưng tuổi, đường huyết trung bình, BMI sau khi chia nhóm. Kết quả cho thấy nguy cơ đột quỵ tăng rõ rệt ở nhóm tuổi cao và nhóm có mức đường huyết cao, trong khi BMI chưa thể hiện sự khác biệt rõ ràng.

```
# add binned version of numerical features

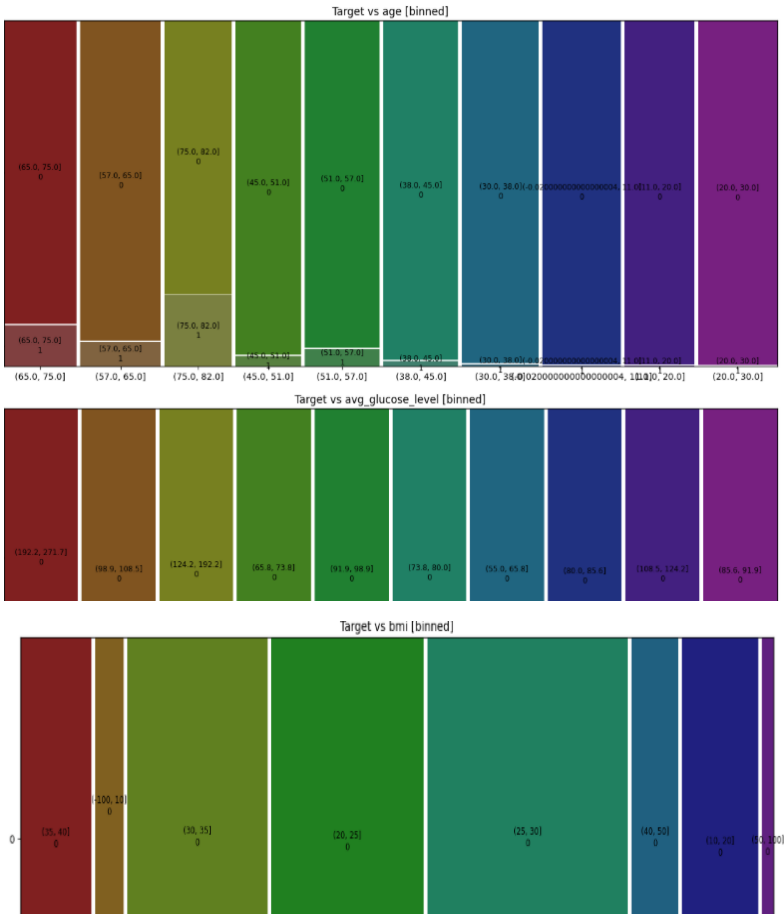
# quantile based:
df['age_bin'] = pd.qcut(df['age'], q=10, precision=1)
df['avg_glucose_level_bin'] = pd.qcut(df['avg_glucose_level'], q=10, precision=1)

# explicitly defined bins:
df['bmi_bin'] = pd.cut(df['bmi'], [-100,10,20,25,30,35,40,50,100])
```

```
# plot target vs features using mosaic plot
plt_para_save = plt.rcParams['figure.figsize'] # remember plot settings

for f in features_num:
    f_bin = f+'_bin'
    plt.rcParams["figure.figsize"] = (16,7) # increase plot size for mosaics
    mosaic(df, [f_bin, 'target'], title='Target vs ' + f + ' [binned]')
    plt.show()

# reset plot size again
plt.rcParams['figure.figsize'] = plt_para_save
```



Hình 4.15: Biểu đồ mục tiêu so với các đối tượng bằng biểu đồ khảm (Target & age, avg_glucose_level, bmi)

Phân tích:

- Nguy cơ tăng theo tuổi và mức glucose (bệnh tiểu đường).
- Mức BMI cao cũng chỉ ra nguy cơ cao hơn.
- Một giá trị BMI bị thiếu (cột ngoài cùng bên trái) dường như chỉ ra nguy cơ tăng đáng kể!

```
# BMI - check cross table
ctab = pd.crosstab(df.bmi_bin, df.target)
ctab
```

target	**0**	**1**
bmi_bin		
(-100, 10]	161	40

target	0	1
bmi_bin		
(10, 20]	534	3
(20, 25]	1035	35
(25, 30]	1334	75
(30, 35]	931	54
(35, 40]	476	24
(40, 50]	312	17
(50, 100]	78	1

Bảng 4.1: BMI – Kiểm tra bảng chéo.

```
# normalize each row to get row-wise target percentages
(ctab.transpose() / ctab.sum(axis=1)).transpose()
```

target	0	1
bmi_bin		
(-100, 10]	0.800995	0.199005
(10, 20]	0.994413	0.005587
(20, 25]	0.967290	0.032710
(25, 30]	0.946771	0.053229
(30, 35]	0.945178	0.054822

target	0	1
bmi_bin		
(35, 40]	0.952000	0.048000
(40, 50]	0.948328	0.051672
(50, 100]	0.987342	0.012658

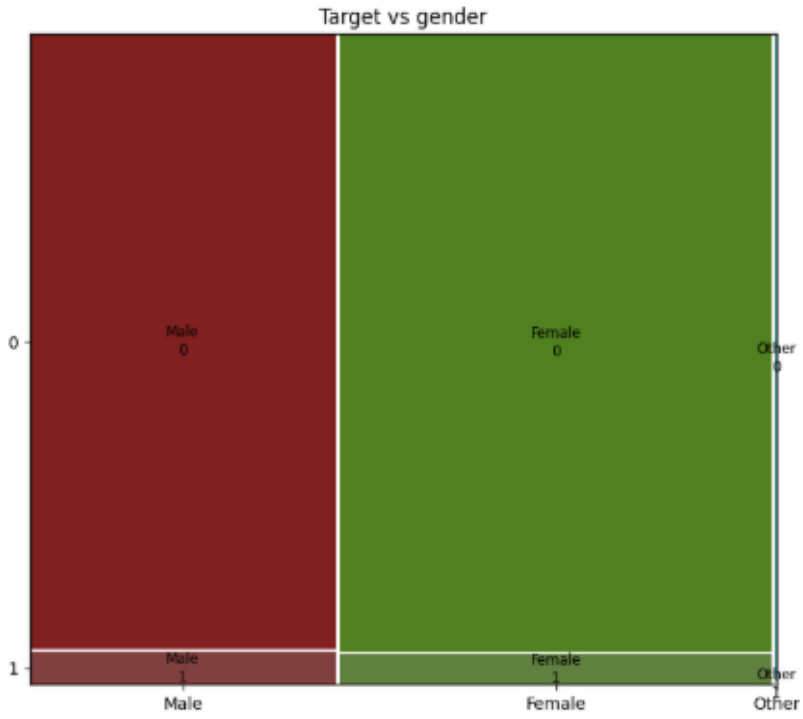
Bảng 4.2: Chuẩn hóa từng hàng để có được tỷ lệ phần trăm.

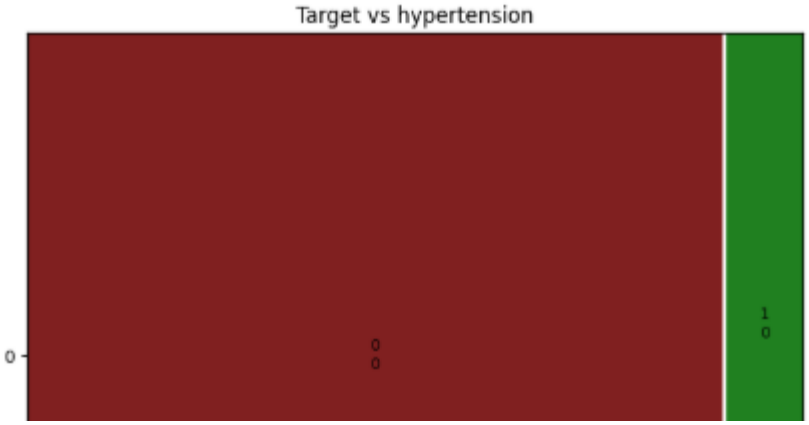
Gần 20% BMI bị mất là do đột quỵ! Con số này cao hơn nhiều so với các nhóm khác.

```
# plot target vs features using mosaic plot
plt_para_save = plt.rcParams['figure.figsize'] # remember plot settings

for f in features_cat:
    plt.rcParams["figure.figsize"] = (8,7) # increase plot size for mosaics
    mosaic(df, [f, 'target'], title='Target vs ' + f)
    plt.show()

# reset plot size again
plt.rcParams['figure.figsize'] = plt_para_save
```





Hình 4.16: Biểu đồ thể hiện mục tiêu so với các đặc trưng bằng biểu đồ mosaic

Phân tích:

- Ảnh hưởng của giới tính có vẻ thấp một cách đáng ngạc nhiên
- Tăng huyết áp và bệnh tim làm tăng đáng kể nguy cơ đột quỵ "Đã từng kết hôn" nữa sao!?
- **Loại công việc:** Nguy cơ cao hơn đối với người tự kinh doanh (căng thẳng hơn?)
- **Loại nơi cư trú:** Nguy cơ cao hơn một chút đối với người thành thị so với nông thôn
- **Hút thuốc:** Nguy cơ cao nhất đối với người đã từng hút thuốc. Không có nhiều sự khác biệt giữa "hút thuốc" và "chưa từng hút thuốc"?

```
# "ever married" - check cross table
ctab = pd.crosstab(df.ever_married, df.target)
ctab
```

target	**0**	**1**
ever_married		
No	1728	29
Yes	3133	220

Bảng 4.3: Kết quả kiểm tra bảng chéo.

```
# normalize each row
(ctab.transpose() / ctab.sum(axis=1)).transpose()
```

target	0	1
ever_married		
No	0.983495	0.016505
Yes	0.934387	0.065613

Bảng 4.4: Kết quả chuẩn hóa từng hàng.

4.6. Kết Quả Huấn Luyện Mô Hình.

4.6.1. Xây dựng mô hình:

```
# select predictors
predictors = features_num + features_cat
print('Number of predictors: ', len(predictors))
print(predictors)
```

```
Number of predictors:  10
['age', 'avg_glucose_level', 'bmi', 'gender', 'hypertension', 'heart_disease', 'ever_married', 'work_type', 'residence_type', 'smoki
```

Hình 4.17: Các biến đầu vào được chọn cho mô hình.

Biểu đồ biểu diễn lịch sử huấn luyện của mô hình (Training Scoring History). Giá trị training logloss giảm dần khi số lượng cây tăng, cho thấy mô hình dần cải thiện hiệu suất trong quá trình học.

```
# show training scoring history
plt.rcParams['figure.figsize']=(7,4)
fit_1.plot()
```

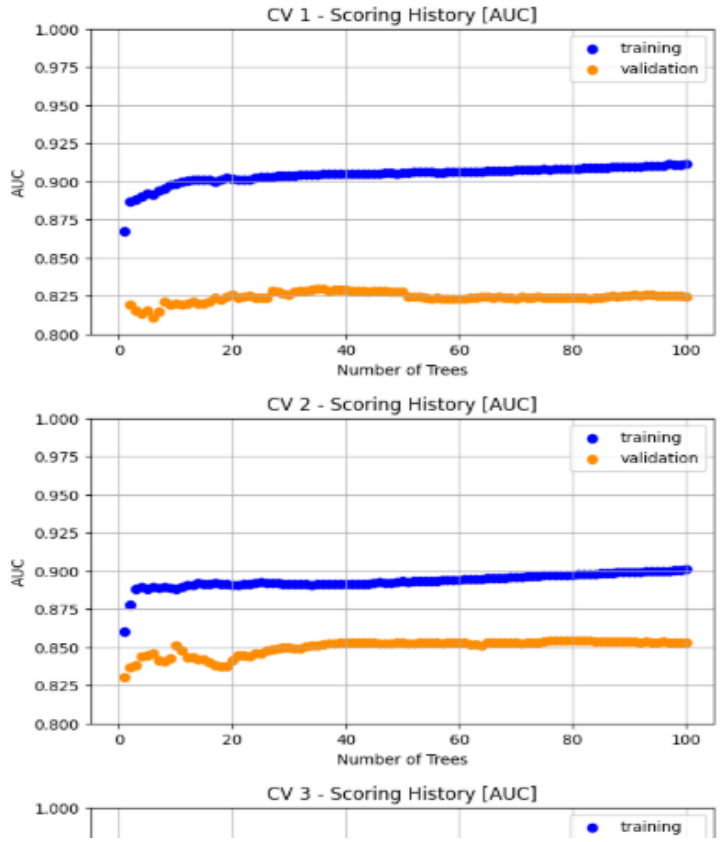



```
<h2o.plot._plot_result._MObject at 0x7f7995413dd0>
```

Hình 4.18: Quá trình giảm logloss theo số lượng cây.

Hình 4.19 trình bày lịch sử huấn luyện theo AUC trong quá trình cross-validation. Đường màu xanh (training) cho thấy AUC trên tập huấn luyện duy trì ở mức cao (~0.90), trong khi đường màu cam (validation) ổn định quanh mức 0.82–0.85. Kết quả này cho thấy mô hình học tốt trên tập huấn luyện, nhưng hiệu suất trên tập validation thấp hơn, phản ánh khả năng khái quát hóa còn hạn chế.

```
# show scoring history - training vs cross validations
for i in range(5):
    cv_model_temp = fit_1.cross_validation_models()[i]
    df_cv_score_history = cv_model_temp.score_history()
    my_title = 'CV ' + str(1+i) + ' - Scoring History [AUC]'
    plt.scatter(df_cv_score_history.number_of_trees,
                y=df_cv_score_history.training_auc,
                c='blue', label='training')
    plt.scatter(df_cv_score_history.number_of_trees,
                y=df_cv_score_history.validation_auc,
                c='darkorange', label='validation')
    plt.title(my_title)
    plt.xlabel('Number of Trees')
    plt.ylabel('AUC')
    plt.ylim(0.8,1)
    plt.legend()
    plt.grid()
    plt.show()
```

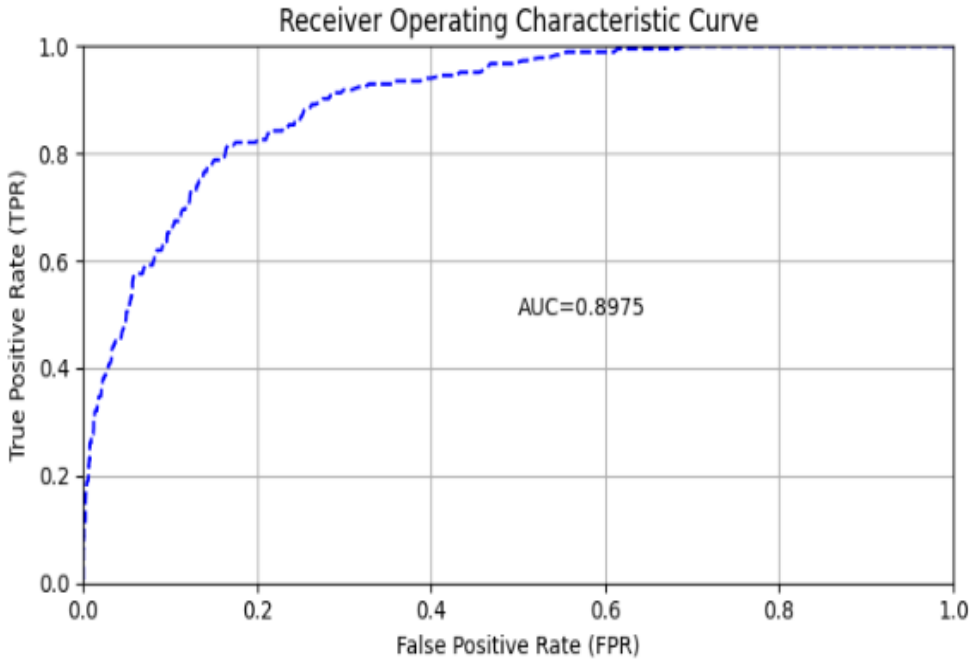


Hình 4.19: So sánh hiệu suất huấn luyện và validation theo số lượng cây.

4.6.2. Đánh giá trên dữ liệu đào tạo:

Biểu đồ thể hiện đường cong ROC của mô hình trên tập huấn luyện với diện tích dưới đường cong (**AUC = 0.8975**). Kết quả này cho thấy mô hình có khả năng phân biệt tốt giữa hai lớp (bệnh nhân bị đột quỵ và không bị đột quỵ) trên dữ liệu huấn luyện.

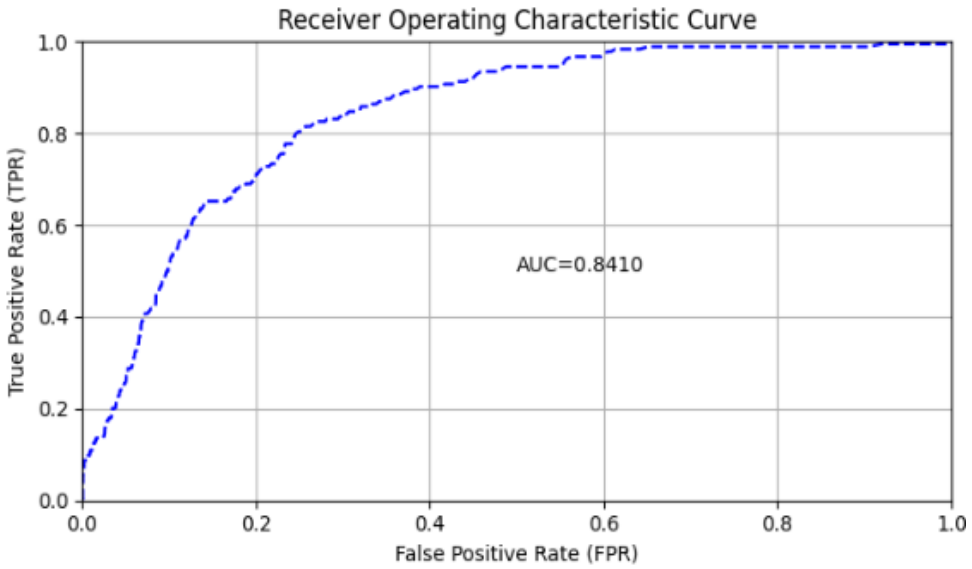
```
# training performance
perf_train = fit_1.model_performance(train=True)
perf_train.plot()
```



Hình 4.20: Đường cong ROC - Dữ liệu đào tạo.

Biểu đồ thể hiện đường cong ROC của mô hình khi đánh giá bằng cross-validation, với diện tích dưới đường cong (AUC = 0.8410). Kết quả thấp hơn so với tập huấn luyện (AUC = 0.8975), cho thấy mô hình có hiện tượng giảm hiệu quả khi áp dụng trên dữ liệu mới, nhưng vẫn đạt mức phân biệt khá tốt.

```
# cross validation performance
perf_cv = fit_1.model_performance(xval=True)
perf_cv.plot()
```



Hình 4.21: Đường cong ROC - Xác thực chéo.

```
# on training data - automatic threshold (optimal F1 score)
conf_train = fit_1.confusion_matrix(train=True)
conf_train.show()
```

Confusion Matrix (Act/Pred) for max f1 @ threshold = 0.12790678230003902				
	0	**1**	**Error**	**Rate**
0	3209.0	197.0	0.0578	(197.0/3406.0)
1	79.0	105.0	0.4293	(79.0/184.0)
Total	3288.0	302.0	0.0769	(276.0/3590.0)

Bảng 4.5: Confusion Matrix với ngưỡng tối ưu theo F1-score.

```
# corresponding accuracy for this threshold:
conf_list_temp = conf_train.to_list()
n_matrix = sum(conf_list_temp[0]) + sum(conf_list_temp[1])
acc_t0 = (conf_list_temp[0][0]+conf_list_temp[1][1]) / n_matrix
print('Accuracy:', np.round(acc_t0,6))
```

```
Accuracy: 0.92312
```

Hình 4.22: Độ chính xác Confusion Matrix với ngưỡng tối ưu theo F1-score.

Việc chọn ngưỡng theo F1 tối ưu thực sự không hữu ích ở đây, chúng ta có sự khác biệt lớn giữa các giá trị dương thực tế (184) và các giá trị dương dự đoán (302).

Hãy thử cải thiện bằng cách chọn ngưỡng theo cách thủ công:

```
# alternatively specify threshold manually - here we try to achieve a symmetric outcome
tt = 0.148
conf_train_man = fit_1.confusion_matrix(train=True, thresholds=tt)
conf_train_man.show()
```

Confusion Matrix (Act/Pred) @ threshold = 0.1478570244997902				
	0	**1**	**Error**	**Rate**
0	3297.0	109.0	0.032	(109.0/3406.0)
1	108.0	76.0	0.587	(108.0/184.0)
Total	3405.0	185.0	0.0604	(217.0/3590.0)

Bảng 4.6: Ma trận nhầm lẫn tại ngưỡng 0.148.

```
# corresponding accuracy for manual threshold:
conf_list_temp = conf_train_man.to_list()
n_matrix = sum(conf_list_temp[0]) + sum(conf_list_temp[1])
acc_t1 = (conf_list_temp[0][0]+conf_list_temp[1][1]) / n_matrix
print('Accuracy:', np.round(acc_t1,6))
```

```
Accuracy: 0.939554
```

Hình 4.23: Độ chính xác mô hình tại ngưỡng thủ công.

```
# check on cross validation
conf_cv_man = fit_1.confusion_matrix(xval=True, thresholds=tt)
conf_cv_man.show()
```

Confusion Matrix (Act/Pred) @ threshold = 0.14772756583508664				
	0	**1**	**Error**	**Rate**
0	3266.0	140.0	0.0411	(140.0/3406.0)
1	143.0	41.0	0.7772	(143.0/184.0)
Total	3409.0	181.0	0.0788	(283.0/3590.0)

Bảng 4.7: Confusion Matrix trên Cross Validation (ngưỡng thủ công).

```
# corresponding accuracy for our manual threshold:
conf_list_temp = conf_cv_man.to_list()
n_matrix = sum(conf_list_temp[0]) + sum(conf_list_temp[1])
acc_t1_CV = (conf_list_temp[0][0]+conf_list_temp[1][1]) / n_matrix
print('Accuracy:', np.round(acc_t1_CV,6))
```

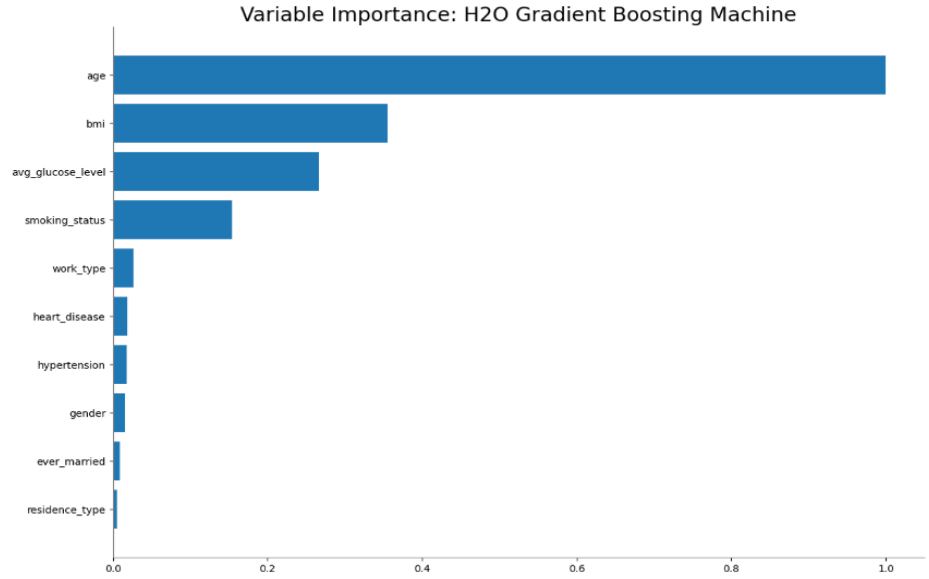
```
Accuracy: 0.92117
```

Hình 4.24: Độ chính xác Cross Validation với ngưỡng thủ công.

4.6.3. Tầm quan trọng của biến:

Biểu đồ cho thấy tuổi là yếu tố quan trọng nhất, tiếp theo là BMI và mức đường huyết trung bình. Các yếu tố như hút thuốc có ảnh hưởng nhưng thấp hơn, còn những biến khác gần như không đáng kể trong mô hình.

```
# basic version
fit_1.varimp_plot()
```



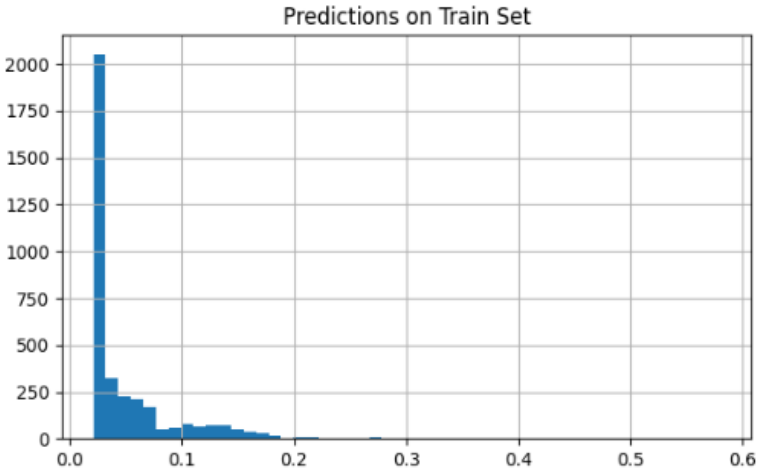

```
<h2o.plot._plot_result._MObject at 0x7f7997529cd0>
<Figure size 700x400 with 0 Axes>
```

Hình 4.25: Biểu đồ các biến trong mô hình H2O Gradient Boosting Machine.

4.6.4. Dự đoán về dữ liệu đào tạo:

```
# predict on train set (extract probabilities only)
pred_train = fit_1.predict(train_hex)['p1']
pred_train = pred_train.as_data_frame().p1

# and plot
plt.hist(pred_train, bins=50)
plt.title('Predictions on Train Set')
plt.grid()
plt.show()
```



Hình 4.26: Dự đoán trên tập huấn luyện.

```
# check calibration
frequency_pred = sum(pred_train)
frequency_act = df_train.target.sum()
print('Predicted Frequency:', frequency_pred)
print('Actual Frequency   :', frequency_act)
```

```
Predicted Frequency: 184.40023228358382
Actual Frequency   : 184
```

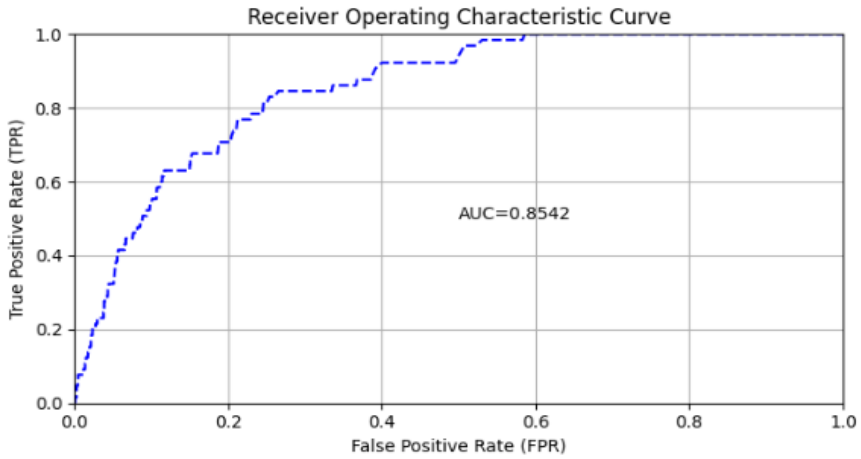
Hình 4.27: Tần suất dự đoán và thực tế.

4.7. Đánh Giá Trên Bộ Kiểm Tra.

Biểu đồ ROC (Receiver Operating Characteristic Curve) để đánh giá hiệu năng của mô hình phân loại nhị phân trên tập kiểm tra (test set).

```
# calc performance on test test
perf_test = fit_1.model_performance(test_hex)

# ROC Curve - Test Set
perf_test.plot()
```



Hình 4.28: Đường cong ROC của mô hình H2O Gradient Boosting Machine.

```
# confusion matrix using our manual threshold
conf_test_man = perf_test.confusion_matrix(thresholds=tt)
conf_test_man.show()
```

Confusion Matrix (Act/Pred) @ threshold = 0.1480016916497603				
	0	**1**	**Error**	**Rate**
0	1401.0	54.0	0.0371	(54.0/1455.0)
1	50.0	15.0	0.7692	(50.0/65.0)
Total	1451.0	69.0	0.0684	(104.0/1520.0)

Bảng 4.8: Ma trận nhầm lẫn tại ngưỡng 0.148.

```
# calc accuracy for manual threshold:
conf_list_temp = conf_test_man.to_list()
n_matrix = sum(conf_list_temp[0]) + sum(conf_list_temp[1])
acc_t1_test = (conf_list_temp[0][0]+conf_list_temp[1][1]) / n_matrix
print('Accuracy:', np.round(acc_t1_test,6))
```

```
Accuracy: 0.931579
```

Hình 4.29: Accuracy tính theo ngưỡng thủ công.

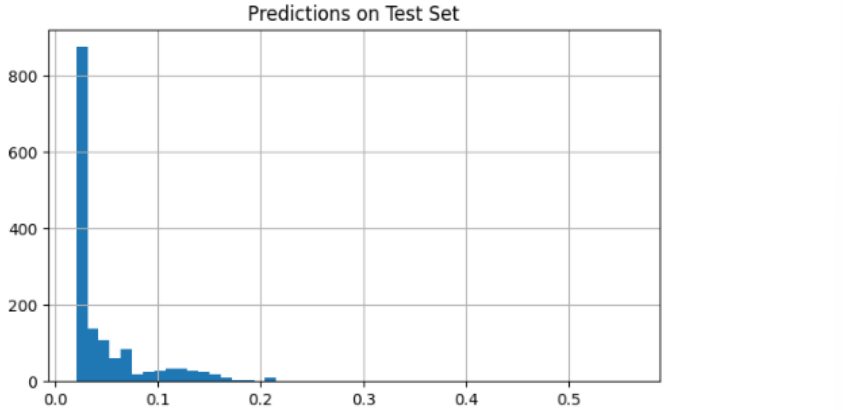
Biểu đồ dự đoán cho thấy đa số xác suất tập trung gần **0.0**, tức phần lớn mẫu được dự đoán là **âm tính**.

```
# predict on test set (extract probabilities only)
pred_test = fit_1.predict(test_hex)['p1']
pred_test = pred_test.as_data_frame().p1

# and plot
plt.hist(pred_test, bins=50)
plt.title('Predictions on Test Set')
plt.grid()
plt.show()
```

```
gbm prediction progress: |████████████████████████████████████████████████| (done) 100%
/usr/local/lib/python3.12/dist-packages/h2o/frame.py:1983: H2ODependencyWarning: Converting H2O fr

  warnings.warn("Converting H2O frame to pandas dataframe using single-thread.  For faster convers
```



Hình 4.30: Phân bố xác suất dự đoán trên tập kiểm tra.

4.7.1. Hiển thị ví dụ:

Bảng cho thấy 20 bệnh nhân có nguy cơ đột quỵ cao nhất, chủ yếu ở nhóm tuổi cao, glucose cao và có bệnh nền.

```
# show most endangered patients (according to our model) in test set
df_high_20 = df_test.nlargest(20, columns='prediction')
df_high_20
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	residence_type	avg_glucose_level	bmi	smoking_status	target	age_bin	avg_glucose_level_bin	bmi_
475	17752	Male	76.0	0	1	Yes	Private	Urban	79.05	-99.0	Unknown	0	(75.0, 82.0]	(73.8, 80.0]	(-1
21	7356	Male	75.0	0	0	Yes	Private	Urban	104.72	-99.0	Unknown	1	(65.0, 75.0]	(98.9, 108.5]	(-1
553	1741	Male	77.0	0	0	Yes	Private	Urban	74.26	-99.0	formerly smoked	0	(75.0, 82.0]	(73.8, 80.0]	(-1
380	132	Female	80.0	0	0	Yes	Govt_job	Urban	84.86	-99.0	Unknown	0	(75.0, 82.0]	(80.0, 85.6]	(-1
686	1077	Male	77.0	0	1	Yes	Govt_job	Rural	106.03	-99.0	Unknown	0	(75.0, 82.0]	(98.9, 108.5]	(-1
14	15102	Male	78.0	1	0	Yes	Private	Urban	75.32	-99.0	formerly smoked	1	(75.0, 82.0]	(73.8, 80.0]	(-1
4	8213	Male	78.0	0	1	Yes	Private	Urban	219.84	-99.0	Unknown	1	(75.0, 82.0]	(192.2, 271.7]	(-1
1483	10995	Male	76.0	1	0	Yes	Private	Rural	267.60	30.5	never smoked	0	(75.0, 82.0]	(192.2, 271.7]	(30,
92	4480	Male	76.0	0	0	Yes	Private	Rural	234.58	34.3	formerly smoked	0	(75.0, 82.0]	(192.2, 271.7]	(30,
6	25226	Male	57.0	0	1	No	Govt_job	Urban	217.08	-99.0	Unknown	1	(51.0, 57.0]	(192.2, 271.7]	(-1
483	1842	Male	58.0	0	0	Yes	Private	Urban	94.00	-99.0	Unknown	0	(57.0,	(91.9, 98.91	(-1

Hình 4.31: Danh sách bệnh nhân nguy cơ cao (Top 20).

Kiểm tra hiệu chuẩn ở mức cao:

```
print('Actual cases in highest 20    :', df_high_20.target.sum())
print('Predicted cases in highest 20 :', np.round(df_high_20.prediction.sum(),2))
```

```
Actual cases in highest 20    : 5
Predicted cases in highest 20 : 6.69
```

Hình 4.32: Kết quả hiệu chuẩn cao.

Bảng cho thấy 20 bệnh nhân có nguy cơ đột quỵ thấp nhất, chủ yếu là người trẻ, không mắc bệnh nền.

```
# show least endangered patients (according to our model) in test set
df_low_20 = df_test.nsmallest(20, columns='prediction')
df_low_20
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	residence_type	avg_glucose_level	bmi	smoking_sta
788	57904	Male	15.0	0	0	No	Private	Urban	190.13	20.7	never smc
67	46136	Male	14.0	0	0	No	Never_worked	Rural	161.28	19.1	Unkn
83	55680	Male	13.0	0	0	No	children	Urban	114.84	18.3	Unkn
98	42996	Female	36.0	0	0	No	Govt_job	Rural	126.82	23.3	never smc
118	56681	Female	22.0	0	0	No	Private	Urban	130.34	22.0	never smc
125	34376	Female	16.0	0	0	No	children	Rural	113.47	19.5	Unkn
143	22622	Male	10.0	0	0	No	children	Rural	108.79	21.0	Unkn

161	61408	Male	23.0	0	0	No	Never_worked	Urban	125.26	18.7	never smc
175	20364	Female	4.0	0	0	No	children	Urban	107.25	12.0	Unkn
254	32554	Female	16.0	0	0	No	children	Rural	109.02	19.8	Unkn
258	56679	Male	19.0	0	0	No	Private	Rural	142.57	22.8	Unkn
272	11973	Female	10.0	0	0	No	children	Urban	124.60	18.6	Unkn
305	43146	Male	8.0	0	0	No	children	Urban	106.40	18.3	Unkn
329	51162	Female	11.0	0	0	No	children	Rural	122.75	14.3	Unkn
340	41565	Female	33.0	0	0	No	Private	Urban	121.19	22.1	never smc

Hình 4.33: Danh sách bệnh nhân nguy cơ thấp (Top 20).

Kiểm tra hiệu chuẩn ở mức thấp:

```
print('Actual cases in lowest 20    :', df_low_20.target.sum())
print('Predicted cases in lowest 20 :', np.round(df_low_20.prediction.sum(),2))
```

```
Actual cases in lowest 20    : 0
Predicted cases in lowest 20 : 0.42
```

Hình 4.34: Kết quả hiệu chuẩn thấp.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết Luận.

Trong đồ án này, nhóm đã thực hiện đầy đủ các bước của một quy trình khoa học dữ liệu để giải quyết bài toán dự đoán nguy cơ đột quỵ dựa trên dữ liệu y tế. Cụ thể:

- Tiến hành khảo sát và tiền xử lý dữ liệu, bao gồm xử lý giá trị thiếu, chuẩn hóa dữ liệu, mã hóa biến phân loại và áp dụng SMOTE để khắc phục mất cân bằng dữ liệu.
- Thử nghiệm và so sánh nhiều mô hình học máy: Logistic Regression, Decision Tree, Random Forest, KNN, SVM, XGBoost.
- Kết quả cho thấy:
  - XGBoost đạt hiệu suất cao nhất với Accuracy = 86%, F1-score = 0.78, AUC = 0.90, đồng thời có Recall cao giúp hạn chế bỏ sót bệnh nhân có nguy cơ đột quỵ.
  - Các mô hình Random Forest và SVM cũng cho kết quả tốt, có thể là lựa chọn thay thế tùy theo yêu cầu về tài nguyên tính toán.
- Kết quả phân tích khẳng định rằng các yếu tố như tuổi tác, chỉ số đường huyết, BMI, tiền sử tăng huyết áp và bệnh tim có ảnh hưởng lớn đến nguy cơ đột quỵ.

Như vậy, đồ án đã chứng minh khả năng ứng dụng học máy trong hỗ trợ dự đoán nguy cơ bệnh lý y tế, giúp đưa ra cảnh báo sớm cho bệnh nhân và hỗ trợ bác sĩ trong công tác chẩn đoán.

5.2. Hạn Chế.

Bên cạnh những kết quả đạt được, đồ án vẫn còn một số hạn chế:

- Dữ liệu mất cân bằng mạnh (chỉ ~5% bệnh nhân bị đột quỵ), mặc dù đã dùng SMOTE nhưng vẫn có nguy cơ gây nhiễu dữ liệu.
- Dữ liệu còn hạn chế về số lượng và đặc trưng, chưa bao quát đầy đủ các yếu tố lâm sàng, di truyền, thói quen sinh hoạt.
- Chưa đánh giá mô hình trên dữ liệu thực tế ngoài tập huấn luyện và kiểm thử

→ độ tin cậy trong môi trường y tế thực tế cần được kiểm chứng thêm.

5.3. Hướng Phát Triển.

Trong tương lai, để nâng cao hiệu quả dự đoán và khả năng ứng dụng thực tiễn, nhóm đề xuất một số hướng phát triển:

- **Mở rộng và làm giàu dữ liệu:** thu thập thêm dữ liệu y tế từ nhiều bệnh viện, nhiều vùng địa lý, tích hợp dữ liệu hình ảnh y khoa (CT, MRI) và dữ liệu xét nghiệm sinh hóa.
- **Kết hợp nhiều mô hình (Ensemble/Stacking):** nhằm tận dụng ưu điểm của các thuật toán khác nhau, nâng cao độ chính xác.
- **Ứng dụng học sâu (Deep Learning):** thử nghiệm mạng DNN, CNN, LSTM cho dữ liệu đa dạng, đặc biệt là dữ liệu chuỗi thời gian sức khỏe bệnh nhân.
- **Xây dựng hệ thống cảnh báo sớm:** phát triển ứng dụng/web app kết nối trực tiếp với dữ liệu bệnh viện, đưa ra dự báo nguy cơ đột quỵ theo thời gian thực.
- **Đảm bảo tính minh bạch (Explainable AI – XAI):** sử dụng các phương pháp giải thích mô hình (SHAP, LIME) để hỗ trợ bác sĩ hiểu rõ tại sao hệ thống đưa ra quyết định.

TÀI LIỆU THAM KHẢO

[1] Tài liệu, Slide bài giảng thầy Sử Nhật Hạ, giảng viên bộ môn Công nghệ khoa học dữ liệu Khoa Công nghệ thông tin, Trường Đại học Nguyễn Tất Thành.