TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

.



ĐỀ TÀI: Ứng dụng học sâu để dự đoán loại trái cây dựa trên hình ảnh

Giảng viên hướng dẫn:	**Ths. Phạm Đình Tài**
Sinh viên thực hiện:	**Lê Chí Kha**
MSSV:	**2200002544**
Khoá:	**2022 - 2026**
Ngành:	**CÔNG NGHỆ THÔNG TIN**
Chuyên ngành:	**KHOA HỌC DỮ LIỆU**

TPHCM, tháng 12 năm 2024

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH

KHOA CÔNG NGHỆ THÔNG TIN

.



ĐỀ TÀI: Ứng dụng học sâu để dự đoán loại trái cây dựa trên hình ảnh

Giảng viên hướng dẫn: **Ths. Phạm Đình Tài**

Sinh viên thực hiện: **Lê Chí Kha**

MSSV: **2200002544**

Khoá: **2022 - 2026**

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

TPHCM, tháng 12 năm 2024

LỜI MỞ ĐẦU

Học sâu (Deep Learning), đặc biệt là các mạng nơ-ron tích chập (Convolutional Neural Networks - CNN), đã và đang tạo ra sự đột phá trong lĩnh vực thị giác máy tính và nhận dạng hình ảnh. Khả năng tự động học và trích xuất các đặc trưng từ hình ảnh giúp CNN trở thành công cụ hiệu quả trong các bài toán phân loại phức tạp, ví dụ như phân loại trái cây dựa trên hình ảnh.

Trong môi trường thực tiễn, nhận dạng và phân loại trái cây đóng vai trò quan trọng trong nhiều lĩnh vực. Chẳng hạn, trong nông nghiệp, công nghệ này giúp hỗ trợ kiểm soát chất lượng sản phẩm, phân loại trái cây theo kích cỡ và loại hình, đồng thời góp phần cải thiện hiệu suất lao động thông qua tự động hóa. Trong lĩnh vực thương mại, việc nhận diện trái cây tự động còn giúp nâng cao trải nghiệm người dùng thông qua việc dễ dàng kiểm tra sản phẩm và thanh toán tự động.

Mục tiêu của dự án là “ Ứng dụng học sâu để dự đoán loại trái cây dựa trên hình ảnh ” . Mô hình sẽ sử dụng mạng CNN, có khả năng học các đặc trưng phức tạp từ dữ liệu hình ảnh như màu sắc, hình dáng và kết cấu của từng loại trái cây. CNN là lựa chọn lý tưởng trong trường hợp này vì nó có thể giảm thiểu việc trích xuất đặc trưng thủ công và tận dụng sức mạnh của các lớp tích chập và lớp kết nối để phân loại hình ảnh chính xác.

Đồng thời, dự án cũng mang tính nghiên cứu và thực hành, giúp hiểu sâu hơn về cách thức hoạt động của học sâu trong các ứng dụng thực tiễn, từ khâu thu thập dữ liệu, tiền xử lý hình ảnh đến việc huấn luyện, tối ưu hóa mô hình và đánh giá hiệu suất của mô hình. Kết quả của dự án sẽ cung cấp các thông tin hữu ích để không chỉ hiểu rõ hơn về mô hình CNN mà còn khám phá các khả năng mở rộng của học sâu trong các ứng dụng công nghệ cao, đặc biệt là trong các ngành có liên quan đến thị giác máy tính và tự động hóa.Với sự cố gắng hết sức tìm hiểu, phân tích và thiết kế nhưng chắc chắn không tránh khỏi được những thiếu sót. Em rất mong được sự thông cảm và góp ý của các quý thầy cô.

LỜI CẢM ƠN

Em chân thành cám ơn Thầy hướng dẫn Ths. Phạm Đình Tài, người đã hướng dẫn tận tình, đóng góp các ý kiến chuyên môn đồ án. Thầy/Cô đã động viên tinh thần tôi cố gắng hoàn thành những nghiên cứu đặt ra. Thầy/Cô cũng cung cấp một số tài liệu liên quan đến đồ án mà em đang nghiên cứu và ân cần nhắc nhở tôi đến tiến độ thực hiện đồ án này.

Em cũng chân thành gửi lời cảm ơn đến các Thầy/Cô khoa Công nghệ thông tin trường Đại học Nguyễn Tất Thành đã giảng dạy, hướng dẫn, trang bị các kiến thức cho em trong những năm học vừa qua, từ các kiến thức cơ bản đến các vấn đề chuyên sâu.

Em xin gửi lời cảm ơn đến anh, chị, bạn bè, đồng nghiệp bằng nhiều hình thức khác nhau đã giúp đỡ em trong quá trình học tập tại trường cũng như trong thời gian hoàn thành đồ án.

Đặc biệt xin gửi lời cám ơn đến cha mẹ và anh chị em trong gia đình đã động viên tinh thần cũng như chia sẻ những khó khăn trong những năm qua. Em xin chân thành cảm ơn!

Sinh Viên Thực Hiện

(Ký tên)

NHẬN XÉT CỦA GIẢNG VIÊN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Điểm đồ án:

-Điểm 1:.....

-Điểm 2:.....

-Điểm tổng kết:.....

TPHCM, Ngày ..... tháng……năm 2024

Giảng viên 1 **Giảng viên 2**

BM-ChT-

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH **TRUNG TÂM KHẢO THÍ**	**KỲ THI KẾT THÚC HỌC PHẦN** **HỌC KỲ ..3.. NĂM HỌC ..2023.– .2024.**

PHIẾU CHẤM THI TIỂU LUẬN/ĐỒ ÁN

Môn thi: ĐỒ ÁN DEEPLEARNING TRONG KHOA HỌC DỮ LIỆU

Lớp học phần: 22DTH4D

Nhóm sinh viên thực hiện :

1. Lê Chí Kha — Tham gia đóng góp: 50%
2. Đỗ Kim Anh — Tham gia đóng góp: 50%

Ngày thi: 23 / 12 / 2024 Phòng thi: L.603

Đề tài tiểu luận/báo cáo của sinh viên : **Ứng dụng học sâu để dự đoán loại trái cây dựa trên hình ảnh**

Phần đánh giá của giảng viên (căn cứ trên thang rubrics của môn học):

Tiêu chí (theo CĐR HP)	**Đánh giá của GV**	**Điểm tối đa**	**Điểm đạt được**
Cấu trúc của báo cáo			
Nội dung			
• Các nội dung thành phần			
• Lập luận			
• Kết luận			
Trình bày			
TỔNG ĐIỂM			

Giảng viên chấm thi

(ký, ghi rõ họ tên)

MỤC LỤC

LỜI MỞ ĐẦU ..... **i**

LỜI CẢM ƠN ..... **ii**

NHẬN XÉT CỦA GIẢNG VIÊN ..... **iii**

DANH MỤC HÌNH ..... **vii**

DANH MỤC BẢNG ..... **ix**

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT ..... **x**

Chương 1. Giời Thiệu **1**

Chương 2. Cơ sở lý thuyết **3**

2.1. Kiến thức về Deeplearning. 3

2.1.1. Deep Learning là gì ? 3

2.1.2. Hoạt động Deeplearning. 3

2.2. Mạng nơ-ron tích chập (CNN) 4

2.2.1. Khái niệm về CNN. 4

2.2.2. Cấu trúc mạng CNN. 5

2.2.3. Hoạt động của CNN trong xử lý và phân tích hình ảnh. 5

2.3. Một số kiến trúc convolutional neural network thông dụng 7

2.3.1. Kiến trúc AlexNet 7

2.3.2. Kiến trúc VGG 16 8

2.3.3. Kiến trúc Inception/GoogleNet 8

2.4. Sơ lượt về phần mền YOLO. 9

Chương 3. Xây dựng chương trình **11**

3.1. Lưu đồ thuật toán nhận diện hình ảnh 12

3.2. Cơ sở dữ liệu 13

3.3. Cơ sở dữ liệu trái cây 14

Chương 4: Kết quả thực nghiệm và phân tích **16**

4.1. Môi trường thử nghiệm 16

4.2. Phần mềm YOLOv10 16

4.3. Đối tượng 17

4.4. Các bước tiến hành 17

4.5. Kết quả 19

Chương 5: Kết quả thảo luận và hướng phát triển **21**

5.1. Phân tích kết quả 21

5.1.1. So sánh độ chính xác giữa mô hình học sâu và các phương pháp truyền thống. 21

5.1.2. Lý do mô hình đạt hoặc chưa đạt mục tiêu đề ra. 22

a) Lý do mô hình đạt mục tiêu: 22

b) Lý do mô hình chưa đạt mục tiêu: 22

5.2. Hạn chế 23

5.3. Hướng phát triển trong tương lai 23

5.3.1. Mở rộng tập dữ liệu với nhiều loại trái cây hơn. 23

5.3.2. Áp dụng mô hình vào môi trường thực tế với điều kiện ánh sáng và góc chụp đa dạng. 23

5.3.3. Tích hợp vào các hệ thống tự động hóa như robot nông nghiệp hoặc ứng dụng di động. 24

DANH MỤC TÀI LIỆU THAM KHẢO **25**

DANH MỤC HÌNH

Hình 1.1 Dây chuyền nông sản tự động tại Việt Nam 1

Hình 2.1: Cấu trúc chính của CNN 4

Hình 2.2: Cấu trúc chi tiết của mạng CNN 5

Hình 2.3 : Kiến trúc AlexNet 7

Hình 2.4: Kiến trúc VGG 16..... 8

Hình 2.5: Kiến trúc Inception 8

Hình 2.6 : Inception 9

Hình 3.1: Các bước xây dựng hệ thống 11

Hình 3.2 : Các bước thực hiện chương trình phân loại hoa quả 11

Hình 3.3: Lưu đồ thuật toán nhận diện hình ảnh 12

Hình 3.4: Một số ảnh táo đạt, lỗi, xanh 13

Hình 3.5: Một số ảnh chuối đạt, lỗi, xanh 13

Hình 3.6: Một số ảnh cam đạt, lỗi, xanh 13

Hình 4.1: Giao diện chính của Colab 16

Hình 4.2: Màn hình khởi động phần mềm YOLO 16

Hình 4.3: Ảnh một số trái cây 17

Hình 4.5: Ảnh trái cam trên cây 17

Hình 4.7: Các bước chuẩn bị Runtime 17

Hình 4.8: Màn hình đã lưu một số ảnh cần train 18

Hình 4.9: Màn thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy 18

Hình 4.10: Thông báo hiển thị kết quả thành công 19

Hình 4.11: Kết quả cho 3 trái cam cạnh nhau 19

Hình 4.12: Kết quả một nải chuối 20

Hình 4.13: Kết quả một nhánh cây táo 20

DANH MỤC BẢNG

Bảng 3.1 : Các loại trái cây …….……15

Bảng 4.1: Tỷ lệ % của các vật được nhận diện ……..…….....20

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

Viết Tắt	Ý Nghĩa
CNN	**Convolutional Neural Networks**
AI	**Artificial Intelligence**
ReLU	**Rectified Linear Unit**
CPU	**Central Processing Unit**
GPU	**Graphic Processing Unit**
TPU	**Tensor Processing**
YOLO	**You Only Look Once**

Chương 1. Giời Thiệu

Ngày nay, với sự phát triển vượt bậc của cuộc cách mạng công nghiệp 4.0 và Internet nó kết nối mọi thứ, bao gồm cả công nghệ AI (trí tuệ nhân tạo). Việc áp dụng Công nghệ của cuộc cách mạng nông nghiệp này rất mạnh mẽ nâng cao chất lượng nông sản, kích thích khả năng cạnh tranh của nền kinh tế, Giảm công sức lao động và chi phí. Bài báo cáo sẽ trình bày tổng quan về thiết kế dây chuyền, thiết bị hiện đại có khả năng phân loại trái cây tự động theo nhu cầu sử dụng công nghệ xử lý hình ảnh kết hợp với mạng trí tuệ nhân tạo để phản hồi nhanh hơn



Hình 1.1 Dây chuyền nông sản tự động tại Việt Nam

Trên toàn thế giới, ở các nước phát triển như Úc, Nhật Bản và Mỹ áp dụng công nghệ hiện đại, tiên tiến những tiến bộ trong lĩnh vực nông nghiệp nói chung và lĩnh vực phân loại đặc biệt là nông sản. Nhờ ứng dụng này, cơ sở nông nghiệp Ngành công nghiệp của nó không sử dụng nhiều lao động, nhưng tốt hơn đạt được sự cạnh tranh nông nghiệp. Ở Việt Nam, ngành nông nghiệp chiếm không cao trong tổng sản phẩm quốc nội, nhưng đây là ngành công nghiệp quan

trọng, họ chủ yếu đóng góp vào việc cung cấp lương thực của đất nước nước và xuất khẩu. Vì vậy, công nghiệp hóa, hiện đại hóa Nông nghiệp, nông thôn được coi là mục tiêu quan trọng của chiến lược phát triển kinh tế nông nghiệp. ồ trong thực hiện nhiệm vụ công nghiệp hóa nông nghiệp, nông thôn sản xuất hoàn chỉnh dây chuyền phân loại sản phẩm nông nghiệp hoàn toàn tự động.

Ứng dụng công nghệ xử lý ảnh và mạng trí tuệ nhân tạo được tạo ra trong kỹ thuật nhận dạng trái cây xuất khẩu. Cùng với đó, thiết kế và chế tạo hệ thống dây chuyền phân loại trái cây xuất khẩu theo kích cỡ, kích thước, màu sắc (sống, chín, thối…), hình dạng (biến dạng bề ngoài, mặt trầy xước). Nghiên cứu nhằm phục vụ cho các doanh nghiệp, hộ gia đình sản xuất vừa và nhỏ. Bởi vì yếu tố quan trọng đối với ứng dụng rộng rãi có nghĩa là chi phí và quy trình đơn giản vận hành và xử lý.

Chương 2. Cơ sở lý thuyết

2.1. Kiến thức về Deeplearning.

2.1.1. Deep Learning là gì ?

Học sâu (Deep Learning) là khả năng máy tính thực hiện các tác vụ mà không cần lập trình rõ ràng...nhưng máy tính vẫn suy nghĩ và hoạt động như một cỗ máy. Khả năng thực hiện một số tác vụ khó như trích xuất dữ liệu từ hình ảnh hoặc video của nó không tốt bằng con người. Các mô hình học sâu, được thiết kế đặc biệt cho bộ não con người, cung cấp một giải phápmột cách tiếp cận đặc biệt phức tạp đối với học máy và sẵn sàng giải quyết những khó khăn này. Mạng lưới thần kinh sâu là các cấu trúc đa cấp phức tạp cho phép dữ liệu được truyền giữa các nút (chẳng hạn như nơ-ron) theo cách có tính liên kết cao. Kết quả là dữ liệu trải qua quá trình chuyển đổi phi tuyến tính dần dần trở nên trừu tượng. Mặc dù nó đòi hỏi lượng dữ liệu lớnKhông thể "cung cấp và xây dựng" một hệ thống như vậy, nhưng nó có thể bắt đầu tạo ra kết quả gần như ngay lập tức và nhu cầu tương tác của con người là tối thiểu sau khi chương trình được triển khai.

2.1.2. Hoạt động Deeplearning.

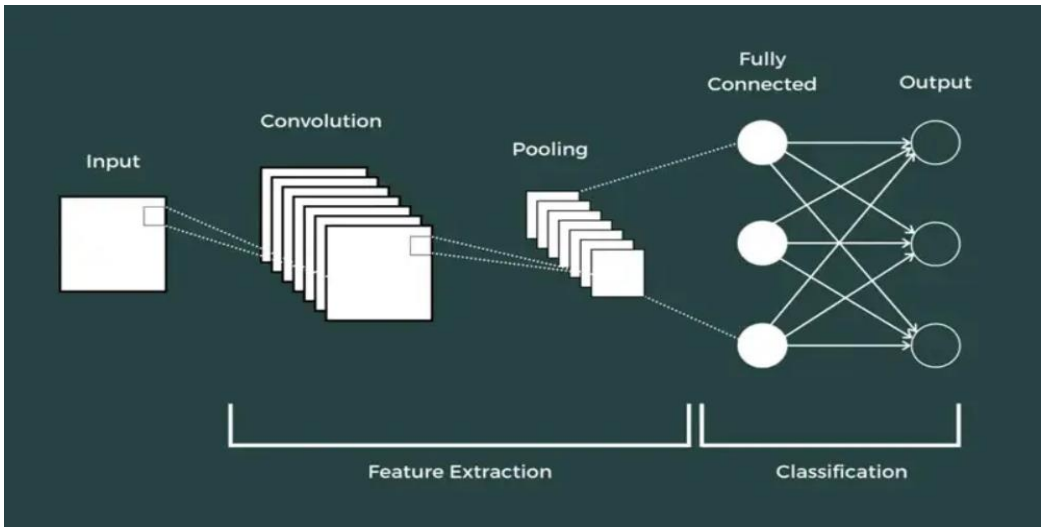
Học sâu là một kỹ thuật học máy, với hệ thống mạng lưới thần kinh nhân tạo được thiết kế để mô phỏng khả năng tư duy logic của bộ não con người. Có nhiều lớp khác nhau trong mạng lưới thần kinh này. Càng nhiều lớp, mạng càng "sâu". Mỗi lớp có nhiều nút mạng (node) được kết nối với các lớp lân cận khác. Mỗi kết nối nút mạng có một trọng số. Ngoài ra, mỗi nơ-ron có chức năng kích hoạt xác định đầu ra. Sau khi dữ liệu được đưa vào mạng nơ-ron, nó được truyền qua các lớp và kết quả được đưa trở lại lớp cuối cùng gọi là lớp đầu ra. Trong quá trình xây dựng mô hình mạng nơron, các trọng số sẽ thay đổi. Nhiệm vụ của mô hình là liên tục tìm ra một tập hợp các giá trị có trọng số để đưa ra đánh giá thỏa đáng. Các hệ thống deep learning thường yêu cầu phần cứng mạnh mẽ để xử lý lượng lớn dữ liệu và thực hiện các phép tính phức tạp. Một số

mô hình học sâu phải mất hàng tuần hoặc hàng tháng để triển khai trên các thiết bị phần cứng tiên tiến hiện nay.

2.2. Mạng nơ-ron tích chập (CNN) .

2.2.1. Khái niệm về CNN.

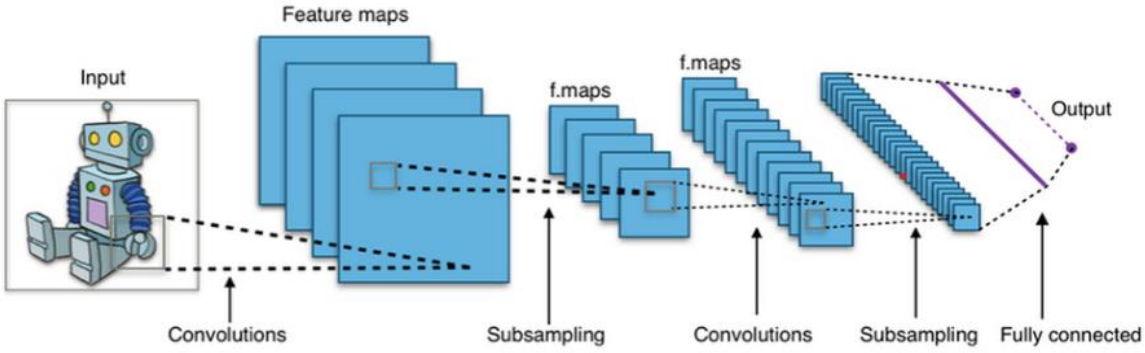
- Mạng nơ-ron tích chập là một loại mô hình mạng nơ-ron nhân tạo được sử dụng rộng rãi trong lĩnh vực thị giác máy tính và xử lý hình ảnh. CNN được thiết kế để nhận dạng và phân loại hình ảnh dựa trên cấu trúc của chúng. Tìm hiểu một số khái niệm cơ bản tính năng nổi bật của CNN là khả năng tự động học các đặc điểm phân cấp từ dữ liệu hình ảnh thông qua việc sử dụng các lớp tích chập và gộp.
    - **Convolutional Layer:** Lớp này sử dụng các bộ lọc để thực hiện tích chập trên hình ảnh đầu vào. Quá trình này giúp ghi lại các đặc điểm cục bộ trong ảnh.
    - **Pooling Layer:** Lớp này giúp giảm kích thước đầu ra của lớp tích chập bằng cách lấy giá trị tối đa (gộp tối đa) hoặc giá trị trung bình (gộp trung bình) của một vùng đầu ra cụ thể.
    - **Fully Connected Layer:** Sau khi đi qua lớp chập và lớp ghép, đầu ra được phân phối đến các lớp được kết nối đầy đủ để thực hiện phân loại.



Hình 2.1: Cấu trúc chính của CNN

2.2.2. Cấu trúc mạng CNN.

- Cấu trúc của Convolutional Neural Network (CNN) thường được chia thành một số lớp cơ bản, bao gồm:



Hình 2.2: Cấu trúc chi tiết của mạng CNN

- **Convolutional Layer:** Lớp này sử dụng các bộ lọc để thực hiện tích chập trên hình ảnh đầu vào, từ đó tạo ra các bản đồ đặc trưng chứa các đặc điểm cục bộ.
- **Activation Function:** Sau khi tính toán tích chập, một hàm kích hoạt như ReLU (Rectified Linear Unit) thường được sử dụng để tạo phi tuyến tính cho mạng.
- **Pooling Layer:** Lớp này giúp giảm kích thước của bản đồ đặc trưng của lớp chập bằng cách lấy giá trị tối đa (max pooling) hoặc giá trị trung bình (average pooling) của một vùng cụ thể của bản đồ đặc trưng.
- **Fully Connected Layer:** Sau khi đi qua lớp chập và lớp ghép, đầu ra được phân phối đến các lớp được kết nối đầy đủ để thực hiện phân loại.
- **Output Layer:** Lớp cuối cùng chứa các nơ-ron đại diện cho các lớp phân loại, thường sử dụng hàm softmax để tính xác suất phân loại.

2.2.3. Hoạt động của CNN trong xử lý và phân tích hình ảnh.

a) Input Layer: Hình ảnh trái cây được đưa vào mạng CNN dưới dạng ma trận các giá trị pixel, thường bao gồm ba kênh màu (RGB) hoặc đơn sắc

(grayscale), tùy theo yêu cầu của bài toán. Các giá trị pixel này biểu thị cường độ ánh sáng của từng pixel, đóng vai trò là đầu vào cho mạng để trích xuất các tính năng quan trọng như đường viền, họa tiết và hình dạng. Đây là bước quan trọng đầu tiên quan trọng trong quá trình phân tích và nhận dạng trái cây.

b) Convolutional Layer: Các lớp tích chập của mạng CNN sử dụng các bộ lọc nhỏ (kernel) quét hình ảnh đầu vào để phát hiện các đặc điểm cơ bản như hình dạng, màu sắc và kết cấu (ví dụ: vỏ, lá hoặc hình dạng của quả). Trích xuất các đặc điểm cấp thấp như cạnh, góc và họa tiết từ các vùng khác nhau của hình ảnh. Những đặc điểm này đóng vai trò quan trọng làm cơ sở cho mạng học hỏi và Nêu đặc điểm đặc trưng của quả.

c) Pooling Layer: Lớp gộp CNN giúp giảm kích thước của bản đồ đặc trưng sau lớp chập, giữ lại các đặc điểm quan trọng và giảm lượng thông tin cần xử lý. Thông qua các hoạt động như max pooling, lớp này làm giảm độ phân giải của bản đồ đặc trưng, tập trung vào các tính năng mạnh, tăng hiệu quả tính toán và giảm thiểu nguy cơ overfitting, từ đó cải thiện hiệu suất của mô hình.

d) Deep Convolutional Layers: Sau nhiều lớp tích chập và gộp, CNN tìm hiểu những đặc điểm phức tạp nhất, chẳng hạn như cấu trúc đặc trưng của từng loại quả (hình quả táo, quả chuối hoặc quả cam). Các lớp sâu này giúp mạng trích xuất và tổng hợp nhiều tính năng trừu tượng hơn, bao gồm hình dạng, kết cấu và tính năng, đóng vai trò quan trọng trong việc nhận dạng và phân loại chính xác bất kỳ loại trái cây nào

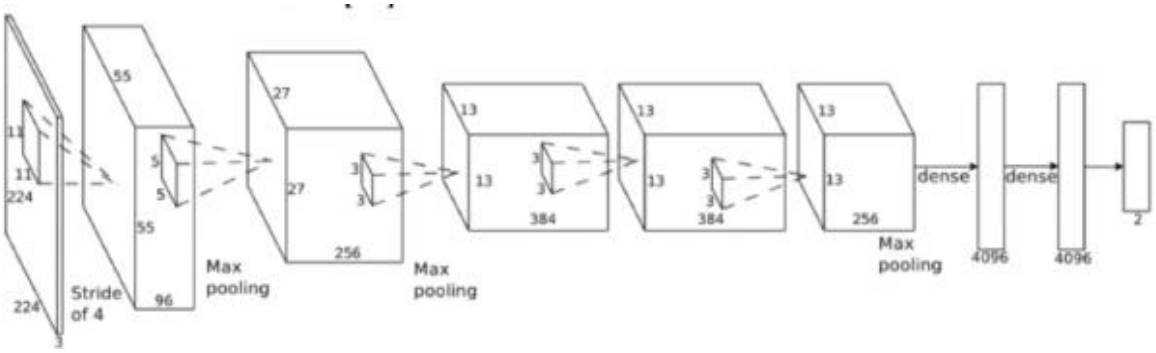
e) Fully Connected Layer: Các tính năng học được từ lớp tích chập và lớp gộp được đưa vào các lớp được kết nối đầy đủ để thực hiện phân loại. Vai trò của các lớp này là sử dụng các đặc điểm được trích xuất từ các lớp trước để liên kết và phân loại hình ảnh trái cây thành các nhóm cụ thể (như táo,

chuối, cam). Mỗi nơ-ron trong lớp này được kết nối với tất cả các nơ-ron trong lớp đầu tiên, tạo một lưới hoàn chỉnh để tối ưu hóa quá trình dự báo.

f) Output Layer: Lớp cuối cùng của mạng CNN đưa ra dự đoán cuối cùng, xác định loại trái cây trong ảnh. Nếu vấn đề là phân loại một số loại trái cây, lớp đầu ra sẽ sử dụng hàm softmax để tính xác suất cho mỗi loại. Vai trò của lớp này là thực hiện việc phân loại, giúp mạng xác định loại trái cây trong ảnh (ví dụ: táo, chuối, cam) dựa trên các đặc điểm đã học được từ các lớp trước.

2.3. Một số kiến trúc convolutional neural network thông dụng

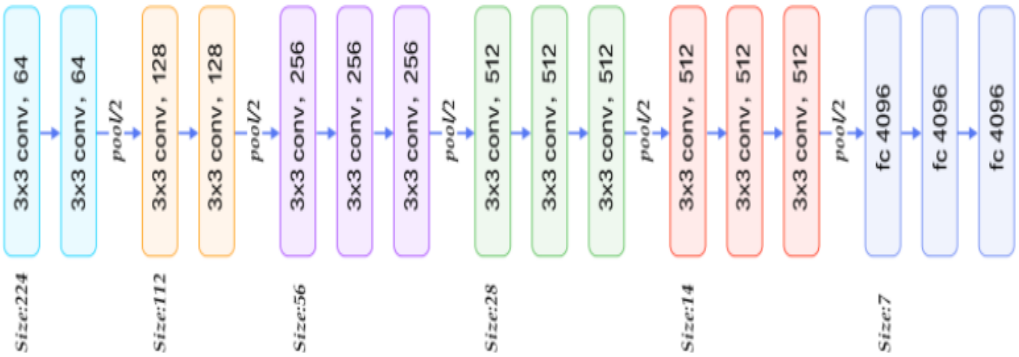
2.3.1. Kiến trúc AlexNet



Hình 2.3 : Kiến trúc AlexNet

Kiến trúc AlexNet lớn hơn nhiều so với CNN được sử dụng trong thị giác máy tính trước đây (trước năm 2010), ví dụ, kiến trúc LeNet của Yann LeCun năm 1998. Nó có 60 triệu tham số và 650.000 neural và mất khoảng từ 5 đến 6 ngày đào tạo trên hai GPU GTX 580 3GB. Ngày nay, với những tiến bộ đáng kinh ngạc của GPU, chúng ta có nhiều kiến trúc CNN có cấu trúc và làm được nhiều việc hơn và có hiệu quả trên các tập dữ liệu phức tạp. Nhưng vào năm 2012, việc đào tạo một mô hình với số lượng lớn tham số và nơ-ron là một vấn đề rất khó khăn. Mô hình gồm 5 tầng convolitional và 3 tầng fully connected với các tham số như trong hình vẽ trên

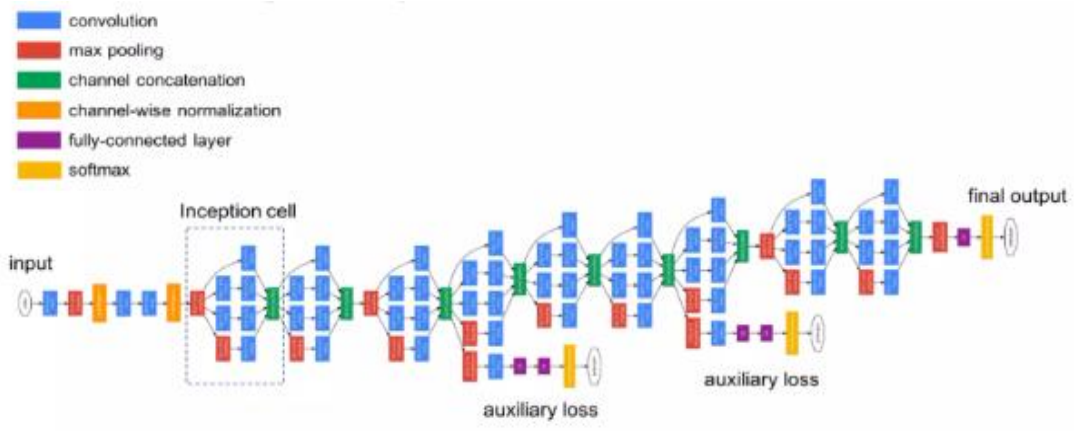
2.3.2. Kiến trúc VGG 16



Hình 2.4: Kiến trúc VGG 16

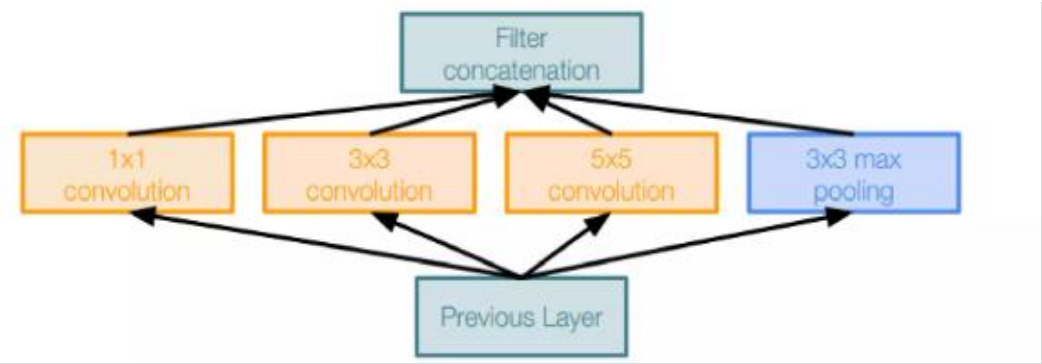
Kiến trúc VGG16, được phát triển bởi Simonyan và Zisserman vào năm 2014, là một trong những mô hình nổi bật tham gia cuộc thi ILSVRC 2014. Với thiết kế tinh gọn và hiệu quả, VGG16 đã xuất sắc giành vị trí á quân trong cuộc thi này. Mô hình bao gồm tổng cộng 16 tầng, trong đó có 13 tầng tích chập (convolutional) và 3 tầng kết nối đầy đủ (fully connected). Các tham số cụ thể của mô hình được trình bày trong sơ đồ trên, thể hiện sự cân đối giữa chiều sâu và khả năng tính toán, giúp VGG16 trở thành một nền tảng quan trọng trong lĩnh vực học sâu.

2.3.3. Kiến trúc Inception/GoogleNet



Hình 2.5: Kiến trúc Inception

Kiến trúc Inception (GoogleNet) được nhóm nghiên cứu Google giới thiệu vào năm 2014 trong bài báo "Going Deeper with Convolutions" và đã giành giải nhất trong cuộc thi ILSVRC 2014 nhờ thiết kế mang tính cách mạng. Điểm nổi bật của Inception là khối Inception, kết hợp các bộ lọc có kích thước khác nhau (1x1, 3x3, 5x5) và hợp nhất các hoạt động thành một khối duy nhất, giúp mô hình tìm hiểu các chức năng ở nhiều cấp độ chi tiết. Ở ĐÓ Tối ưu hóa máy tính, mô hình sử dụng tích chập 1x1 để giảm số lượng tham số. Với 22 lớp và đầu ra phụ giúp giảm hiện tượng mất độ dốc, GoogleNet cân bằng hiệu suất và độ chính xác một cách hoàn hảo. Thiết kế đa nhánh của mô hình đã mở ra một hướng đi mới, đặt nền móng cho những cải tiến sau này như Inception v3, v4 và Xception.



Hình 2.6 : Inception

2.4. Sơ lượt về phần mền YOLO.

YOLO (You Only Look Once) là thuật toán nhận dạng đối tượng nổi tiếng trong lĩnh vực trí tuệ nhân tạo và học sâu. YOLO hoạt động bằng cách chia hình ảnh thành các mạng và dự đoán các hộp giới hạn cũng như xác suất chứa đối tượng thông qua một lần quét, giúp quá trình xử lý nhanh hơn và hiệu quả hơn các phương pháp truyền thống như R-CNN. Từ phiên bản đầu tiên (YOLOv1) ra mắt vào năm 2015, thuật toán đã được update qua YOLOv2, YOLOv3, YOLOv4, YOLOv7, YOLOv8 lên các phiên bản hiện đại

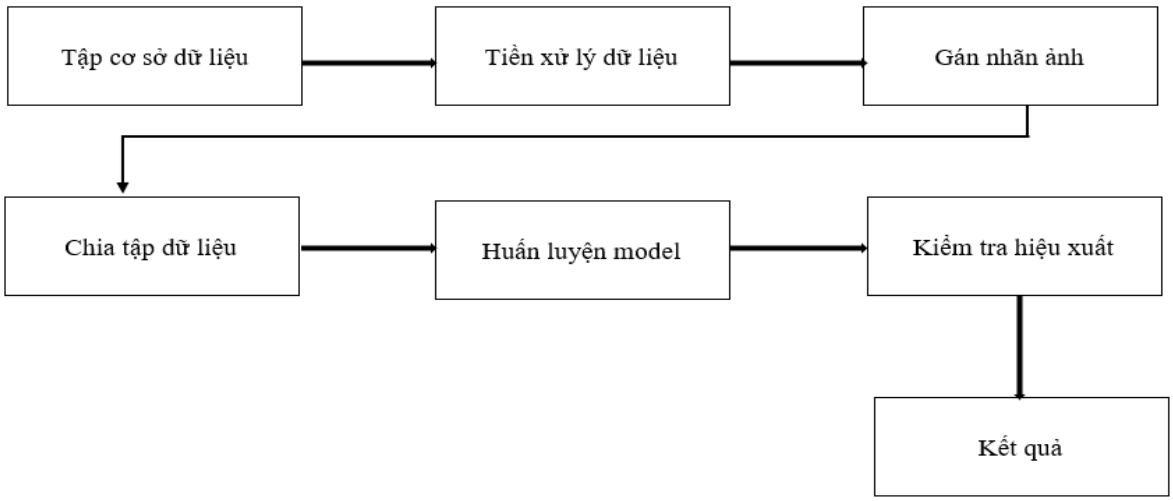
như YOLOv9, YOLOv10 và YOLOv11, cải thiện đáng kể tốc độ và độ chính xác. Tận dụng lợi thế của xử lý thời gian thực, YOLO được sử dụng rộng rãi trong các lĩnh vực như giám sát an ninh, xe tự hành, robot, y tế và nhiều lĩnh vực khác, đặc biệt là khám phá và phân loại dữ liệu từ hình ảnh và video.

Chương 3. Xây dựng chương trình

Xây dựng hệ thống phân loại cà chua bao gồm:bước bổ sung (bao gồm các khối chức năng: khối tài nguyên, Khối PLC, khối băng tải, khối tách, khối biến đổi và khối yên ngựaloại cà chua).



Hình 3.1: Các bước xây dựng hệ thống



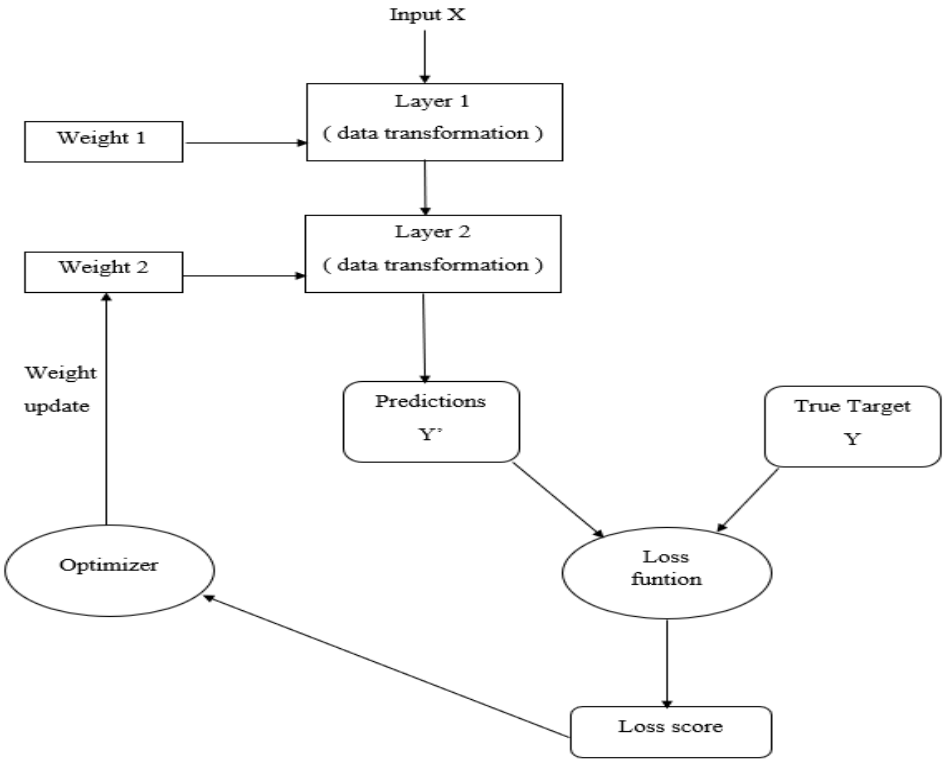
Hình 3.2 : Các bước thực hiện chương trình phân loại hoa quả

- Bài toán phân loại quả gồm 5 bước chính:
  - **Bước 1:** Ảnh quả (chín, xanh, sâu bệnh, mốc) được các em lấy và thu thập từ Internet.
  - **Bước 2:** Để huấn luyện mô hình, cần có hình ảnh đầu vào đã được các em xử lý trước về kích thước và độ sáng, .
  - **Bước 3:** Để huấn luyện mô hình, cần có hình ảnh đầu vào được đánh dấu và được thực hiện gắn thẻ dựa trên công cụ hỗ trợ YOLO và trên roboflow.com.

- **Bước 4:** Huấn luyện mô hình. Sau khi kết thúc quá trình chuẩn bị data, bước này thiết lập các tham số của mô hình và tiến hành huấn luyện. Mô hình chính xác nhất sẽ được lưu và sử dụng cho bước 5.
- **Bước 5:** Hiện đang sử dụng mẫu đã lưu ở bước 4 thực phân loại quả Táo trong hệ thống thực tế và kiểm tra hiệu suất và ra kết quả

3.1. Lưu đồ thuật toán nhận diện hình ảnh

- **Layer 1 (data transformation):** Lớp chuyển đổi dữ liệu khởi tạo.
- **Layer 2 (data transformation):** Lớp chuyển đổi dữ liệu sau tinh chỉnh trọng số.
- **Prediction Y':** Kết quả dự đoán thu được.
- **True Target Y:** Mô hình mẫu từ kết quả huấn luyện.
- **Weights 1 & Weights 2:** Trọng số khởi tạo ngẫu nhiên & Trọng số đã tinh chỉnh.
- **Optimizer:** Chương trình tối ưu hóa trọng số.
- **Loss function & Loss score :** Hàm tổn thất & Kết quả tổn thất



Hình 3.3: Lưu đồ thuật toán nhận diện hình ảnh

3.2. Cơ sở dữ liệu

Dữ liệu gồm một số ảnh RGB các quả táo, cam, chuối gồm chín, xanh, bị bệnh, bị mốc. Các ảnh trong cơ sở dữ liệu là Thu thập trên internet. Có hai loại quả: quả đạt yêu cầu và quả không đạt yêu cầu.

Ví Dụ 1: Một số trái táo cần nhận dạng.



Hình 3.4: Một số ảnh táo đạt, lỗi, xanh

Ví dụ 2: Một số trái chuối cần nhận dạng.



Hình 3.5: Một số ảnh chuối đạt, lỗi, xanh

Ví dụ 3: Một số trái cam cần nhận dạng.



Hình 3.6: Một số ảnh cam đạt, lỗi, xanh

3.3. Cơ sở dữ liệu trái cây

Cơ sở dữ liệu trái cây chứa hình ảnh, nhãn và các đặc điểm như màu sắc, kích thước, hình dạng, phục vụ các bài toán **machine learning** và **deep learning** như phân loại hình ảnh, nhận dạng đối tượng, và đánh giá chất lượng trái cây. Các bộ dữ liệu nổi tiếng gồm **Fruits 360** (hơn 90.000 hình ảnh, 131 loại trái cây), **ImageNet**, và **COCO**. Cơ sở dữ liệu này ứng dụng trong **nông nghiệp thông minh**, **phân loại tự động**, và **thương mại**. Quy trình xây dựng bao gồm thu thập, ghi nhãn và tiền xử lý dữ liệu để huấn luyện mô hình AI.

Dưới đây là bảng ví dụ các loại trái cây có thể được tìm thấy trong **bộ dữ liệu Fruits 360** và các bộ dữ liệu phổ biến khác:

STT	Tên Trái Cây	Tên Tiếng Anh	Đặc Điểm Chính
1	Táo	Apple	Màu đỏ, xanh; hình tròn
2	Cam	Orange	Màu cam; hình cầu, vỏ sần
3	Chuối	Banana	Màu vàng; hình dài, cong
4	Nho	Grape	Màu tím/đen/xanh; nhỏ, hình tròn
5	Dâu tây	Strawberry	Màu đỏ; nhỏ, hình trái tim
6	Lê	Pear	Màu xanh/vàng; hình chuông
7	Dứa (Thơm)	Pineapple	Màu vàng; vỏ sần, lá nhọn
8	Chanh	Lemon	Màu vàng; hình bầu dục
9	Kiwi	Kiwi	Vỏ nâu lông; ruột xanh
10	Xoài	Mango	Màu vàng/cam; hình bầu dục
11	Mận	Plum	Màu tím/đỏ; nhỏ, hình tròn
12	Dưa hấu	Watermelon	Vỏ xanh; ruột đỏ, hạt đen
13	Đu đủ	Papaya	Màu cam; hình dài, hạt đen
14	Thanh long	Dragon Fruit	Vỏ hồng, ruột trắng/đỏ, hạt đen

STT	Tên Trái Cây	Tên Tiếng Anh	Đặc Điểm Chính
15	Cà chua	Tomato	Màu đỏ; hình tròn, mọng nước
16	Quýt	Mandarin	Màu cam; nhỏ, vỏ dễ bóc
17	Bưởi	Grapefruit	Màu cam/hồng; to hơn cam
18	Việt quất	Blueberry	Màu xanh đậm; nhỏ, hình tròn
19	Mâm xôi	Raspberry	Màu đỏ; nhỏ, kết cấu lỗ rỗ
20	Lựu	Pomegranate	Màu đỏ; hạt nhỏ, mọng nước

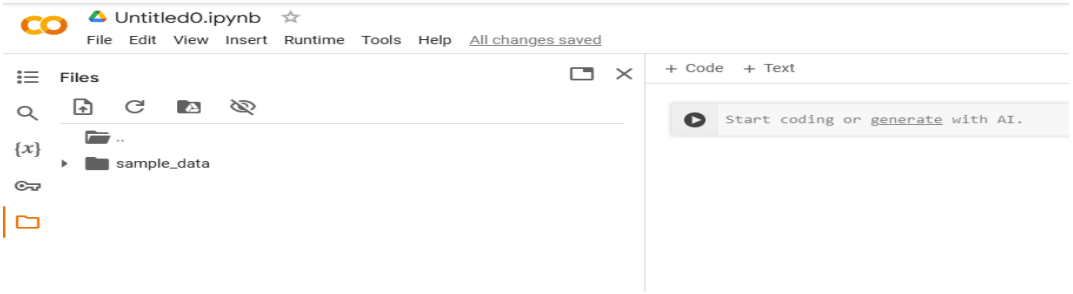
Bảng 3.1 : Các loại trái cây

Chúng ta mô tả cơ sở dữ liệu Fruit dưới dàng $D = \{x^{(i)}, y^{(i)}\}_1^m$. Trong đó: x là ảnh trái cây với 3 kênh màu RGB, x € $\mathbb{R}^{100 \times 100 \times 3}$, y là nhãn của ảnh x, y € [1…20], m là số lượng dữ liệu huấn luyện.

Chương 4: Kết quả thực nghiệm và phân tích

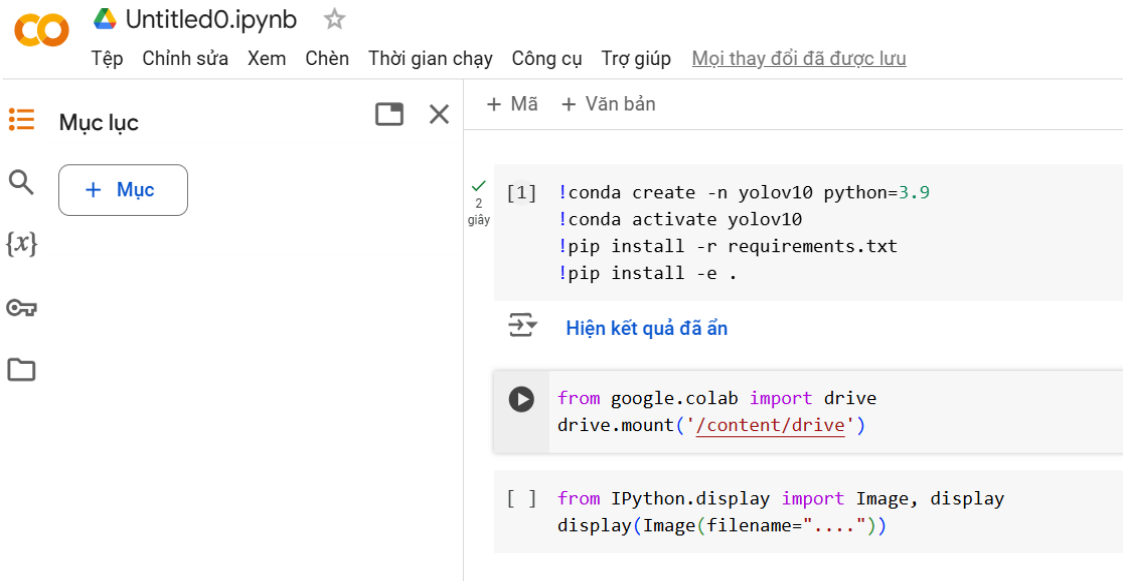
4.1. Môi trường thử nghiệm

Google Colab: Colaboratory, hay " colab " là nền tảng trực tuyến miễn phí của Google giúp lập trình và thực nghiệm các dự án **Machine Learning** và **Deep Learning** trên đám mây. Colab hỗ trợ viết mã Python, sử dụng GPU/TPU miễn phí. Người dùng có thể cài đặt các thư viện như **TensorFlow, PyTorch, NumPy** để huấn luyện mô hình AI, xử lý dữ liệu lớn hoặc trực quan hóa kết quả. Với khả năng chạy mã trên phần cứng mạnh mẽ mà không cần cấu hình máy tính cá nhân, Colab là công cụ lý tưởng cho các dự án **AI/ML** trong học thuật, nghiên cứu và phát triển.



Hình 4.1: Giao diện chính của Colab

4.2. Phần mềm YOLOv10



Hình 4.2: Màn hình khởi động phần mềm YOLO

4.3. Đối tượng

Một số hình ảnh thu thập được như trong hình



Hình 4.3: Ảnh một số trái cây



Hình 4.4: Ảnh trái táo còn trên cây



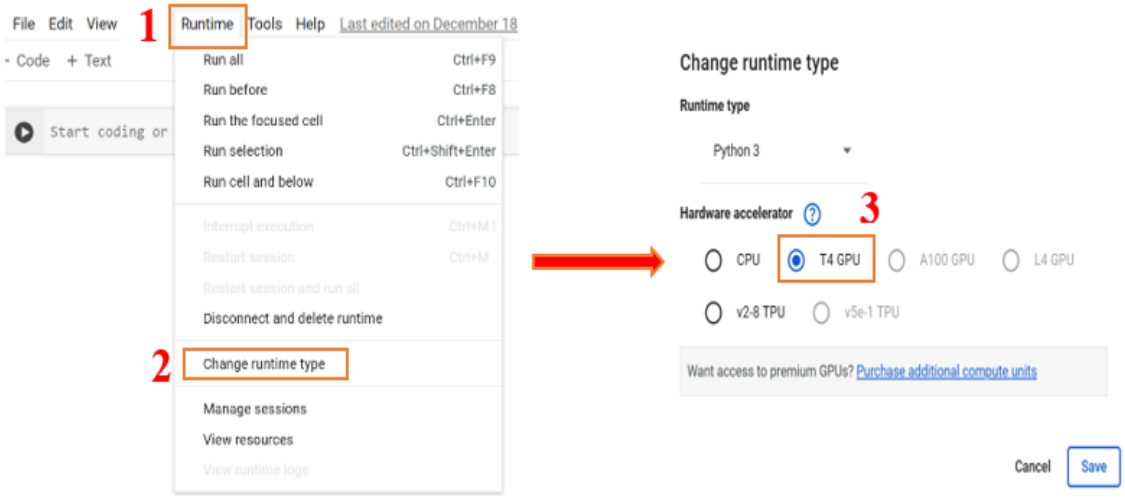
Hình 4.5: Ảnh trái cam trên cây



Hình 4.6: Ảnh trái chuối trên cây

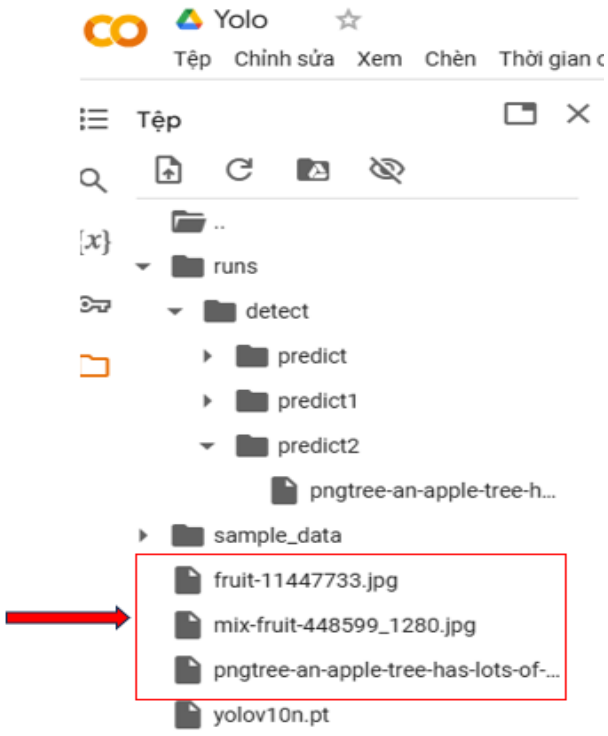
4.4. Các bước tiến hành

Bước 1: Chuẩn bị thay đổi Runtime để train



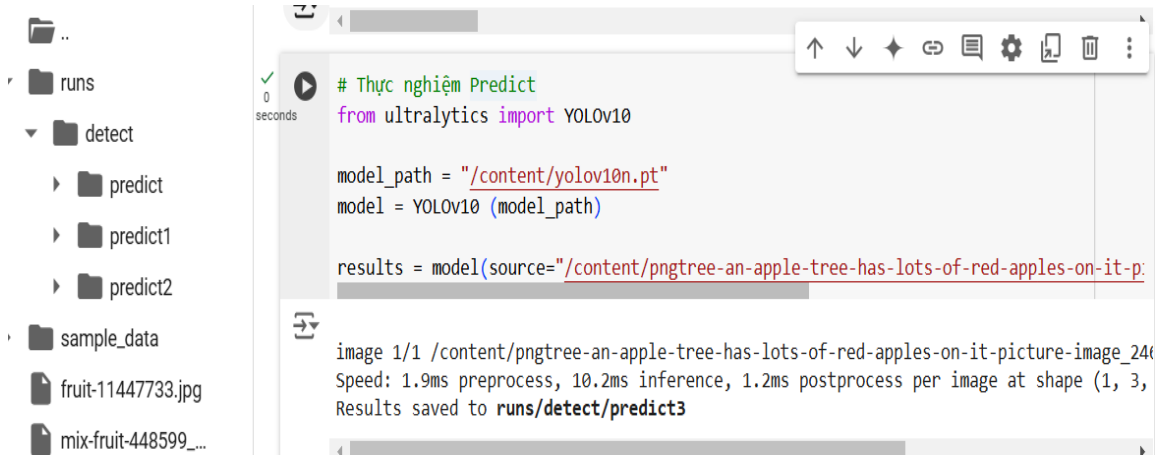
Hình 4.7: Các bước chuẩn bị Runtime

Bước 2: Lưu ảnh vào phần mềm google.colab để bắt đầu train.



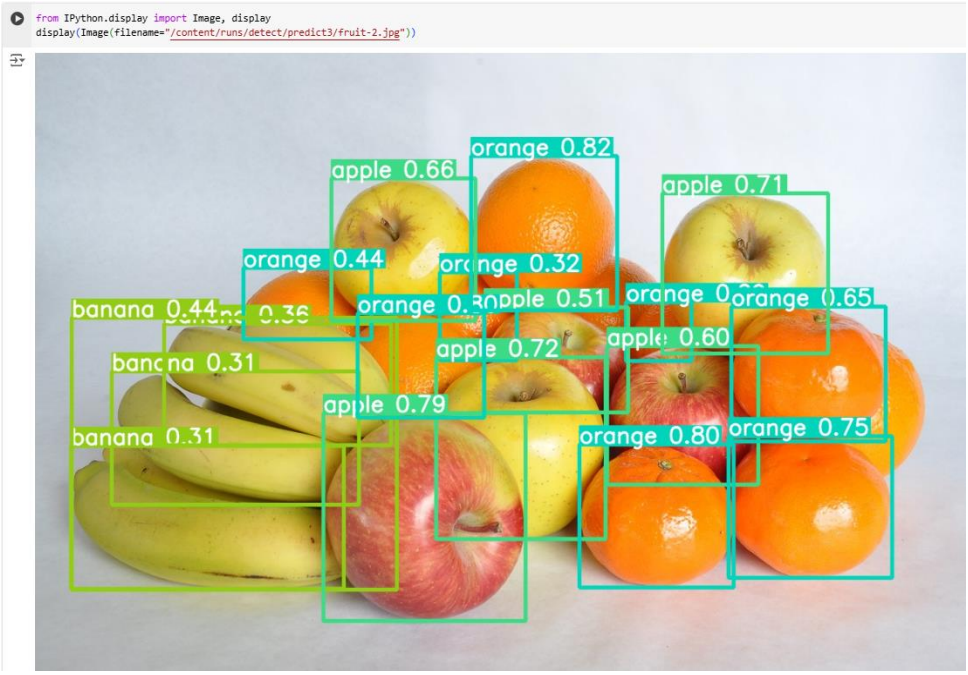
Hình 4.8: Màn hình đã lưu một số ảnh cần train

Bước 3: Copy link ở phần ảnh được để đưa vào xử lí nhận diện khoanh vùng đối tượng và tính toán xác suất. Kết quả được lưu vào đường dẫn runs/detect. Cùng với đó là đưa ra thời gian xử lí bức ảnh.



Hình 4.9: Màn thông báo khoanh vùng đối tượng và tính toán tỉ lệ tin cậy

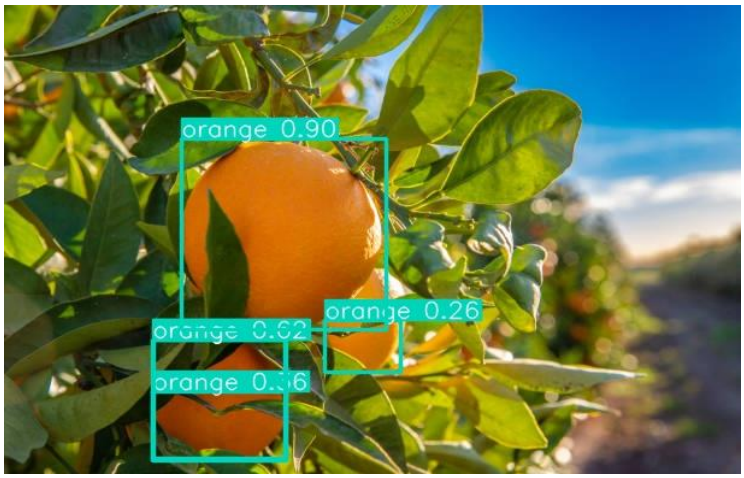
Bước 4: Hiển thị kết quả lên màn hình từ file có đường dẫn runs/detect/predict:



Hình 4.10: Thông báo hiển thị kết quả thành công

4.5. Kết quả

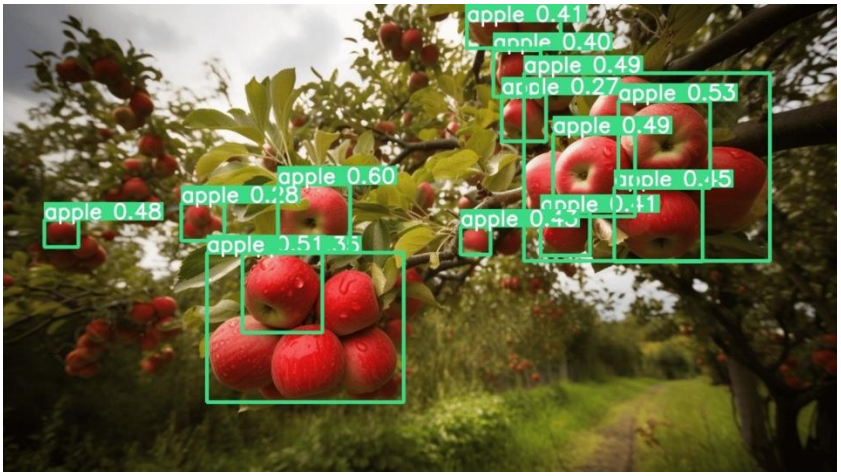
Thể hiện khả năng vượt trội trong việc xác định chính xác vị trí đối tượng, kể cả trong các tác vụ thời gian thực, với tỷ lệ phát hiện đúng ấn tượng như minh họa ở hình 4.10, 4.11, 4.12 và bảng 1. Đối với các vật thể rõ nét, mô hình đạt độ chính xác lên tới 90%, trong khi ở những hình ảnh chứa nhiều đối tượng, độ chính xác vẫn duy trì ở mức cao khoảng 50%.



Hình 4.11: Kết quả cho 3 trái cam cạnh nhau



Hình 4.12: Kết quả một nải chuối



Hình 4.13: Kết quả một nhánh cây táo

TT	Đặc điểm hình ảnh	Tỷ lệ nhận dạng quả
1	**Dạng chùm**	31% - 82%
2	**Dạng đơn**	26% - 90%
3	**Tại vườn**	11% - 60%

Bảng 4.1: Tỷ lệ % của các vật được nhận diện

Chương 5: Kết quả thảo luận và hướng phát triển

5.1. Phân tích kết quả

5.1.1. So sánh độ chính xác giữa mô hình học sâu và các phương pháp truyền thống.

- **Mô hình học sâu:** Các mô hình deep learning, đặc biệt là mạng nơ ron tích chập (CNN), được sử dụng phổ biến để phân loại trái cây nhờ khả năng tự động trích xuất và học hỏi các đặc điểm từ hình ảnh. Các mô hình như AlexNet, VGGNet, ResNet và MobileNet giúp nhận dạng các tính năng từ cấp độ cơ bản đến phức tạp. Ngoài ra, Transfer Learning từ các mô hình được đào tạo trên ImageNet cũng được sử dụng để cải thiện hiệu suất. Quá trình này bao gồm xử lý dữ liệu, xây dựng mô hình, đào tạo và đánh giá. Các mô hình deep learning nổi bật bởi độ chính xác cao và khả năng khái quát hóa tốt, nhưng chúng đòi hỏi nguồn lực đáng kể và khó giải thích. Chúng đã được ứng dụng vào các ứng dụng di động để tự động phân loại, phân tích chất lượng nông sản và nhận dạng trái cây.
- **Phương pháp truyền thống:** Các phương pháp phân loại trái cây dựa trên hình ảnh truyền thống bao gồm trích xuất đặc điểm thủ công (hình dạng, kích thước, màu sắc, kết cấu) và sử dụng các thuật toán học máy cơ bản như KNN, SVM và Naive Bayes. Quá trình bao gồm các bước: thu thập dữ liệu, xử lý ảnh, trích xuất đặc trưng, phân loại và đánh giá hiệu suất. Phương pháp này phù hợp cho dữ liệu nhỏ không yêu cầu phần cứng mạnh mà phụ thuộc vào kỹ năng thiết kế cụ thể và có độ chính xác thấp hơn so với các mô hình deep learning trên dữ liệu phức tạp hoặc không đồng nhất

➢ Từ đó suy ra các mô hình deep learning, đặc biệt là mạng nơ-ron tích chập (CNN), có độ chính xác cao hơn các phương pháp truyền thống nhờ khả năng tự động trích xuất các tính năng và học từ dữ liệu phức tạp. Các mô hình như AlexNet, VGGNet và Transfer Learning từ ImageNet giúp cải thiện hiệu suất.

Ngược lại, các phương pháp truyền thống dựa vào việc trích xuất đặc trưng thủ công và các thuật toán như KNN, SVM và Naive Bayes, nhưng có độ chính xác thấp hơn, đặc biệt khi dữ liệu có tính biến đổi hoặc phức tạp. Các phương pháp truyền thống phù hợp với dữ liệu nhỏ nhưng thường kém hiệu quả hơn trên dữ liệu phức tạp so với các mô hình deep learning.

5.1.2. Lý do mô hình đạt hoặc chưa đạt mục tiêu đề ra.

a) Lý do mô hình đạt mục tiêu:

Các mô hình deep learning đặc biệt là CNN có độ chính xác cao nhờ khả năng tự động trích xuất và học các tính năng phức tạp từ hình ảnh, giúp nhận dạng chính xác các loại trái cây trong các điều kiện khác nhau. Mô hình còn có khả năng khái quát hóa tốt, xử lý các dữ liệu khác nhau và phân loại chính xác ngay cả trong những thay đổi của môi trường. Ngoài ra, việc sử dụng phương pháp học chuyển giao mô hình được đào tạo trên các bộ dữ liệu lớn như ImageNet, giúp cải thiện hiệu suất và giảm thời gian đào tạo.

b) Lý do mô hình chưa đạt mục tiêu:

Mô hình học sâu có thể không đạt được mục tiêu nếu dữ liệu không đủ chất lượng hoặc đa dạng và không thể hiện được tất cả các điều kiện môi trường, dẫn đến giảm độ chính xác. Ngoài ra, mô hình cần tài nguyên tính toán cao như GPU và thời gian đào tạo dài, nếu nguồn lực bị hạn chế, kết quả có thể không tối ưu. Mô hình cũng có thể gặp vấn đề dư thừa nếu nó quá phức tạp hoặc không được tối ưu hóa tốt, làm giảm tính tổng quát. Cuối cùng việc thiếu dữ liệu tăng cường có thể gây khó khăn cho việc phân loại chính xác mô hình trong các điều kiện thay đổi, chẳng hạn như ánh sáng, góc máy hoặc phông nền phức tạp.

5.2. Hạn chế

Mô hình deep learning trong phân loại trái cây dựa trên hình ảnh có độ chính xác cao nhưng vẫn còn một số hạn chế. Đầu tiên, chúng yêu cầu tài nguyên tính toán đáng kể, đặc biệt là GPU, dẫn đến chi phí cao và khó triển khai trên phần cứng hạn chế. Thứ hai, việc thu thập và chuẩn bị dữ liệu lớn, chất lượng cao là một thách thức và mô hình có thể gặp khó khăn trong việc khái quát hóa nếu dữ liệu thử nghiệm cho thấy những thay đổi về điều kiện ánh sáng, góc camera hoặc hình nền. Ngoài ra, các mô hình deep learning thường là những "hộp đen" khó diễn giải, có thể khiến chúng khó đánh giá và cải thiện. Thời gian huấn luyện dài và khả năng bị ảnh hưởng bởi nhiễu trong dữ liệu cũng là những vấn đề cần được quan tâm. Mặc dù mạnh mẽ nhưng học sâu đòi hỏi phải cân nhắc cẩn thận nguồn lực và điều kiện bố trí.

5.3. Hướng phát triển trong tương lai

5.3.1. Mở rộng tập dữ liệu với nhiều loại trái cây hơn.

Để mô hình deep learning đạt được độ chính xác cao hơn, cần thu thập bộ dữ liệu phong phú hơn với nhiều loại trái cây và điều kiện chụp ảnh đa dạng. Điều này liên quan đến việc thu thập hình ảnh từ các góc độ, kích cỡ, màu sắc và điều kiện môi trường khác nhau. Ứng dụng thêm dữ liệu như xoay ảnh, thay đổi độ sáng, độ tương phản, việc phản chiếu hoặc làm mờ hình ảnh sẽ giúp mô hình học được các đặc điểm tổng quát, tăng khả năng nhận biết chính xác trong các tình huống khác nhau**.**

5.3.2. Áp dụng mô hình vào môi trường thực tế với điều kiện ánh sáng và góc chụp đa dạng.

Một trong những thách thức chính trong việc triển khai các mô hình deep learning là triển khai chúng trong điều kiện thực tế, nơi ánh sáng và góc camera có thể thay đổi liên tục. Để giải quyết vấn đề này, người mẫu phải được huấn

luyện với các dữ liệu khác nhau về điều kiện ánh sáng (ngoài trời, trong nhà, ánh sáng yếu, ánh sáng mạnh) và các góc chụp (góc nhìn từ trên xuống, nhìn từ bên....). Các kỹ thuật như học chuyển giao và tinh chỉnh có thể được áp dụng để tối ưu hóa mô hình cho các điều kiện trong thế giới thực này, đồng thời sử dụng tính năng tăng cường dữ liệu để tăng tính khái quát hóa.

5.3.3. Tích hợp vào các hệ thống tự động hóa như robot nông nghiệp hoặc ứng dụng di động.

Các mô hình deep learning có thể được tích hợp vào các hệ thống tự động hóa như robot nông nghiệp hay ứng dụng di động để nâng cao hiệu quả phân loại và nhận dạng trái cây. Trong robot nông nghiệp, mô hình này có thể được sử dụng để nhận dạng trái cây trong quá trình thu hoạch tự động, giúp tăng năng suất và giảm sai sót. Ứng dụng di động cũng có thể nó tích hợp các mô hình deep learning giúp người dùng dễ dàng nhận biết và phân loại trái cây chỉ qua hình ảnh chụp bằng điện thoại. Tuy nhiên, việc triển khai mô hình trên các thiết bị này yêu cầu tối ưu hóa hiệu suất và tài nguyên, đảm bảo mô hình chạy nhanh và hiệu quả trong thời gian thực mà không cần phần cứng mạnh mẽ.

DANH MỤC TÀI LIỆU THAM KHẢO

[1] https://www.slideshare.net/slideshow/lun-vn-thc-s-ng-dng-hc-su-trong-phn-loi-tri-cy/257437280.

[2] https://www.slideshare.net/slideshow/luan-van-nhan-dang-va-phan-loai-hoa-qua-trong-anh-mau-hay/188759825.

[3] https://tanca.io/blog/deep-learning-la-gi-hieu-tong-quan-ve-deep-learning-va-ung-dung.

[4] https://scholar.google.com/.

[5] https://tapchinganhang.gov.vn/neural-network-deep-learning-va-cac-ung-dung-trong-cuoc-song.htm.

[6] https://vi.wikipedia.org/wiki/YOLO.

[7] https://github.com/THU-MIG/yolov10.

[8] https://www.miai.vn/2024/05/30/tim-hieu-chay-thu-va-train-du-lieu-custom-voi-yolov10-mi-ai/.